

TFG - XplicaVoz

Jorge Aured Zarzoso, Germán Bravo Quintián,
Rafael López Rodríguez, Iván Pastor Sacristán

23 de marzo de 2026

Índice

1. Introducción	3
2. Estado del arte	3
2.1. Modelos de clasificación	3
2.1.1. Perceptrón multicapa - MLP	4
2.1.2. Wav2Vec2	4
2.1.3. Random Forest	5
2.1.4. LightGBM	7
2.1.5. Support Vector Machines (SVM)	11
2.1.6. AASIST	14
2.1.7. Regresión Logística	16
2.1.8. K-Nearest Neighbors (k-NN)	17
2.2. Modelos de explicación	18
2.2.1. SHAP	19
2.2.2. LIME	19
2.2.3. Grad-CAM	19
2.2.4. Integrated Gradients	19
2.2.5. DICE	20
2.2.6. SincNet	20
2.2.7. ProtoPNet	20
3. Metodología	21
3.1. Dataset	21
3.2. Extracción de características	22
3.3. Métricas de evaluación	26
3.4. Modelos	28
3.4.1. Random Forest	28
3.4.2. LightGBM	38
3.4.3. Support Vector Machine (SVM)	42
3.4.4. AASIST	45

4. Trabajo Individual	51
4.0.1. Iván Pastor Sacristán	51
4.0.2. Jorge Aured Zarzoso	52

1. Introducción

En los últimos años, hemos visto un aumento considerable en el uso de la IA para suplantar la identidad de alguien de forma maliciosa clonando su voz. Estos son los conocidos *deepfakes*. El reconocimiento de dichos *deepfakes* es de vital importancia, pues suponen una gran amenaza. Por otro lado, las técnicas de detección de *deepfakes* no han avanzado al mismo ritmo, y esto lo vemos en la gran cantidad de estafas que se producen de este tipo.

Además, las personas ya no somos capaces de diferenciar entre una voz real y una generada, como se ve en [? ?], donde hacen sendos estudios exponiendo a personas reales a diversos audios, algunos reales, algunos generados y algunos que clonan voces reales. En dichos estudios, se ve que los que son 100 % generados nos cuesta poco detectarlos, pero entre los reales y los clones no diferenciamos bien, y rondamos el 60 % de precisión clasificando dichas voces en reales o falsas. Por esto, no podemos fiarnos más de nuestras capacidades a la hora de diferenciar cuando una voz es real o no.

En este texto, se proponen varias técnicas que podrían ser útiles para la detección de audios generados por IA. Para esta tarea es fundamental sacar las características de la voz, así como gráficas, para poder entrenar los modelos con dichos datos. Entre los audios debe haber tanto reales como generados, y estar medianamente equilibrados, para que los modelos aprendan las diferencias, y así sepan clasificar un audio que nunca han visto.

Pero el rendimiento del modelo de clasificación no es lo único que nos interesa. Hoy en día, los modelos de IA se han convertido en *cajas negras*, donde no sabemos cómo hace las predicciones, dando lugar a problemas de confianza de los humanos respecto de dichas predicciones, como es en el ámbito médico o ingenieril, donde las decisiones que tomen las IAs deben ser precisas, puesto que la vida de las personas puede estar en juego. Para solventar este problema, ha surgido la IA explicable (XAI), la cual toma dichos modelos *caja negra* y da una explicación de qué características de los datos afectan más a la decisión del modelo. En esta investigación, vamos a aplicar XAI para ver qué afecta más a la clasificación de los audios dentro de los distintos grupos que mencionamos antes.

2. Estado del arte

2.1. Modelos de clasificación

La detección de audio deepfake se fundamenta en la capacidad de los algoritmos para discriminar entre patrones biométricos naturales y artefactos generados sintéticamente. Dado que los métodos de falsificación varían en complejidad desde técnicas de concatenación simple hasta modelos de difusión avanzados, es necesario abordar el problema mediante diversos enfoques de aprendizaje automático.

A continuación se describen los modelos de clasificación que se usan actualmente para

este estudio de audios fake, abarcando desde algoritmos estadísticos clásicos y modelos basados en árboles, hasta arquitecturas de aprendizaje profundo más complejas.

2.1.1. Perceptrón multicapa - MLP

Un perceptrón multicapa es una red neuronal que se utiliza en aprendizaje supervisado en el campo del aprendizaje automático. El MLP está compuesto por múltiples capas de neuronas interconectadas, en las que las salidas de las neuronas de una capa se convierten en entradas para la siguiente capa. La primera capa se llama capa de entrada, la última capa se llama capa de salida y las capas intermedias se llaman capas ocultas. El MLP presenta una gran capacidad para modelar relaciones no lineales y para generalizar. Como punto negativo del uso de este modelo, podemos remarcar la necesidad de un gran conjunto de datos de entrenamiento para evitar el sobreajuste. Por último, cabe resaltar que los MLP's fueron los precursores de otras redes neuronales más complejas como la redes convolucionales y las redes recurrentes. (Fuente: <https://gamco.es/glosario/perceptron-multicapa-mlp/>)

2.1.2. Wav2Vec2

Wav2Vec2 es un modelo de aprendizaje profundo end-to-end para procesamiento de voz que permite obtener representaciones acústicas de alta calidad directamente desde la señal cruda de audio, sin necesidad de características manuales. Fue propuesto por Meta en 2020.

Como parte del entrenamiento, el modelo aprende unidades de habla discreta mediante un gumbel softmax (técnica utilizada en redes neuronales para aproximar el muestreo de distribuciones categóricas discretas de forma diferenciable) para representar las representaciones latentes en la tarea contrastiva.

Tras el preentrenamiento en el habla no etiquetada, el modelo se ajusta con datos etiquetados con una pérdida de Clasificación Temporal Conexiónista (CTC: algoritmo y función de pérdida utilizado en redes neuronales profundas para entrenar modelos de aprendizaje automático en tareas de modelado de secuencias cuando los datos de entrada y salida no están alineados) para ser utilizada en tareas posteriores de reconocimiento de voz.

El modelo se compone de un codificador de características convolucional multicapa que toma la entrada cruda de audio y devuelve representaciones latentes de voz para T instantes de tiempo. Luego son pasados a un transformer para construir representaciones capturando información de toda la secuencia.

El codificador de características consiste en muchos bloques convolucionales seguidos de una capa de normalización y una función de activación GELU (Gaussian Error Linear Unit: pondera las entradas por su probabilidad bajo una distribución gaussiana suavizando su activación cerca de 0).

También realiza representaciones contextualizadas con Transformers siendo que la salida del codificador se pasa a una red que sigue la arquitectura de un Transformer, y usa una capa convolucional que actúa como un embedding posicional relativo.

Por último, Wav2Vec2 consta de un módulo de cuantización que discretiza la salida del codificador a un conjunto finito de representaciones del habla. Esta cuantización se hace con la técnica de Gumbel Softmax (Gumbel Softmax: técnica de reparameterización que aproxima muestras de una distribución categórica discreta mediante una función continua y diferenciable).

El entrenamiento del modelo se basa en un preentrenamiento con enmascaramiento en donde se toma la señal de audio y se transforma en representaciones latentes mediante un encoder. Esto se hace por bloques consecutivos de tamaño M que pueden solaparse.

Para cada paso de tiempo enmascarado, el modelo debe identificar la representación latente cuantizada correcta. Para ello, usa una pérdida contrastiva basada en la similitud del coseno.

También se realiza un fine-tuning supervisado para reconocimiento automático del habla usando CTC como función de pérdida y aplicando una versión de SpecAugment (técnica de aumento de datos diseñada específicamente para el reconocimiento automático de voz) para evitar sobreajuste.

Fuente(<https://arxiv.org/pdf/2006.11477>)

2.1.3. Random Forest

Random Forest es un algoritmo de aprendizaje automático basado en la combinación de múltiples árboles de decisión, propuesto por Leo Breiman en 2001 [?]. Pertenecce a la familia de métodos *ensemble*, que mejoran el rendimiento agregando las predicciones de varios modelos más simples.

Arquitectura y funcionamiento

El algoritmo construye un “bosque” de árboles de decisión donde cada árbol se entrena de forma ligeramente diferente, introduciendo aleatoriedad controlada en dos niveles:

- **Bootstrap aggregating (bagging):** Cada árbol se entrena con una muestra aleatoria del conjunto de datos original, permitiendo repeticiones. Esto significa que algunos ejemplos aparecen varias veces en el entrenamiento de un árbol, mientras que otros (alrededor de un tercio) quedan fuera (*out-of-bag*) y sirven para validación interna.
- **Selección aleatoria de características:** En cada división de un nodo del árbol, solo se considera un subconjunto aleatorio de todas las características disponibles. Esto evita que unas pocas características muy fuertes dominen todas las decisiones.

Proceso de clasificación

Cuando llega una nueva muestra de audio con sus características (formantes, MFCC, etc.), cada árbol del bosque realiza su propia clasificación. La predicción final

se decide por mayoría:

- Si la mayoría de los árboles clasifican el audio como deepfake, la predicción final es deepfake.
- Si la mayoría lo clasifica como real, la predicción final es real.

Este mecanismo de votación reduce drásticamente la varianza del modelo: aunque un árbol individual pueda cometer errores, el consenso del bosque suele ser acertado. Esto se puede ver en la siguiente imagen: 1

Hiperparámetros

Vamos a hablar de los hiperparámetros que tiene Random Forest y para qué sirven o qué representan, ya que conocerlos es crucial a la hora de usar un modelo.

- **n_estimators**: Define la cantidad de árboles de decisión que conforman el bosque aleatorio. A medida que aumentamos este número, el modelo tiende a mejorar su rendimiento porque se promedian más predicciones individuales, lo que reduce la varianza y el riesgo de sobreajuste. Sin embargo, a partir de cierto punto (generalmente entre 100 y 500 árboles) los beneficios se vuelven marginales, mientras que el tiempo de entrenamiento y predicción sigue incrementándose linealmente, por lo que es recomendable encontrar un equilibrio entre rendimiento y eficiencia computacional.
- **max_depth**: Controla la profundidad máxima que pueden alcanzar los árboles individuales dentro del bosque. Si no se establece un límite (None), los árboles crecerán hasta que todas las hojas sean puras o contengan el mínimo de muestras permitido, lo que puede llevar a un sobreajuste en datos de entrenamiento. Por el contrario, valores pequeños limitan la complejidad del modelo, actuando como una forma de regularización que previene el sobreajuste pero podría aumentar el sesgo si la profundidad es demasiado restrictiva.
- **min_samples_split**: Determina el número mínimo de muestras requeridas para dividir un nodo interno durante la construcción del árbol. Valores más altos hacen que el árbol sea más conservador al crear nuevas ramas, ya que necesita más evidencia (muestras) para justificar una división. Esto ayuda a prevenir el sobreajuste al evitar que el modelo aprenda patrones demasiado específicos de grupos pequeños de datos, aunque valores excesivamente altos podrían impedir que el modelo capture patrones importantes.
- **max_features**: Especifica cuántas características debe considerar cada árbol al buscar la mejor división en cada nodo. Al limitar las características disponibles, se fuerza a los árboles a ser más diversos entre sí, lo que reduce la correlación entre ellos y mejora la capacidad de generalización del conjunto. Para clasificación, el valor recomendado suele ser la raíz cuadrada del número total de características ($\sqrt{n}$), mientras que para regresión se suele usar un tercio del total. Valores más pequeños aumentan la aleatoriedad y la diversidad, mientras que valores más grandes hacen que los árboles sean más similares entre sí.




Figura 1: Voto por mayoría en el “bosque”.

- **max_samples:** Cuando se utiliza muestreo bootstrap (que es el comportamiento por defecto), este parámetro controla el tamaño de la muestra aleatoria que se toma del conjunto de datos original para entrenar cada árbol. Valores inferiores a 1.0 (por ejemplo, 0.7) significan que cada árbol se entrena solo con el 70 % de los datos, lo que aumenta la diversidad entre los árboles y fortalece la capacidad de generalización del bosque. Este parámetro es especialmente útil cuando se trabaja con conjuntos de datos muy grandes o cuando se sospecha que los árboles individuales están demasiado correlacionados.

Ventajas específicas para detección de deepfakes

- **Robustez ante ruido:** Las características de audio pueden contener variaciones por condiciones de grabación; Random Forest maneja bien estos datos ruidosos.
- **No requiere normalización:** A diferencia de redes neuronales o SVM, no es necesario escalar las características, lo que simplifica el pipeline.
- **Interpretabilidad:** El algoritmo proporciona una medida de importancia de cada característica, permitiendo identificar qué parámetros acústicos son más discriminativos entre voz real y sintética.
- **Resistencia al overfitting:** La combinación de bagging y aleatoriedad evita que el modelo memorice el conjunto de entrenamiento.

2.1.4. LightGBM

LightGBM (*Light Gradient Boosting Machine*) es un framework de gradient boosting desarrollado por Microsoft en 2017 [?] que optimiza el proceso de entrenamiento

mediante innovaciones en la forma de construir los árboles y muestrear los datos. Mientras que Random Forest construye árboles de forma independiente y paralela, LightGBM los construye secuencialmente, donde cada nuevo árbol se especializa en corregir los errores de los anteriores.

Arquitectura y funcionamiento

El proceso de boosting funciona de la siguiente manera:

1. Se entrena un primer árbol simple que intenta clasificar las instancias según las etiquetas.
2. Se identifican las que este primer árbol clasificó incorrectamente.
3. Se entrena un segundo árbol enfocado específicamente en esos casos difíciles.
4. Se combinan ambos árboles para mejorar la precisión global.
5. El proceso se repite construyendo decenas o cientos de árboles, cada uno corrigiendo los residuos de los anteriores.

Innovaciones clave

- **Crecimiento por hoja (*leaf-wise*):** Los árboles tradicionales crecen nivel por nivel (balanceados). LightGBM, en cambio, crece expandiendo la hoja que más puede reducir el error en cada paso, lo que produce árboles más profundos en las regiones problemáticas y más eficientes en las fáciles.
- **Muestreo basado en gradientes (*GOSS*):** Durante el entrenamiento, LightGBM identifica qué instancias tienen mayor error y las prioriza. Las instancias con error pequeño se muestrean aleatoriamente para reducir el costo computacional. Esto permite entrenar con datasets grandes sin procesar toda la información redundante.
- **Agrupación de características (*EFB*):** LightGBM agrupa las características que no suelen tomar valores iguales a 0 para reducir la dimensionalidad, acelerando el entrenamiento sin pérdida de información significativa.

Proceso de clasificación

Cuando una nueva instancia llega para ser clasificada:

- Pasa secuencialmente por todos los árboles construidos.
- Cada árbol aporta una corrección o ajuste a la predicción anterior.
- La suma ponderada de todas las contribuciones produce la clasificación final (probabilidad de pertenecer a una clase).

Hiperparámetros

Vamos a explicar los hiperparámetros más importantes en los modelos LightGBM.

- **max_depth**: Limita explícitamente la profundidad máxima que pueden alcanzar los árboles durante el entrenamiento. Es especialmente importante cuando se trabaja con conjuntos de datos pequeños, ya que los árboles poco profundos tienen menos probabilidad de sufrir sobreajuste. Si max_depth es menor o igual a cero, significa que no hay límite para la profundidad máxima, lo que puede ser arriesgado con datos limitados.
- **num_leaves**: Controla la complejidad del modelo en LightGBM, ya que determina el número máximo de hojas por árbol. A diferencia de otros algoritmos que crecen por niveles, LightGBM utiliza un crecimiento por hojas (leaf-wise), lo que significa que elige la hoja con la mayor pérdida delta para crecer, permitiendo una convergencia más rápida y mayor precisión. Sin embargo, este enfoque puede provocar sobreajuste si no se configura adecuadamente. En la práctica, el valor de num_leaves debe ser menor que 2 elevado a la max_depth para evitar que los árboles crezcan demasiado profundo. Por ejemplo, si max_depth=7, establecer num_leaves en 70 u 80 suele dar mejor precisión que usar 127.
- **min_data_in_leaf**: Define la cantidad mínima de observaciones que debe contener una hoja para que sea creada. Configurarla con un valor grande (cientos o miles para datasets grandes) evita que los árboles crezcan demasiado profundo y aprendan patrones demasiado específicos de grupos muy pequeños de datos. Sin embargo, si el valor es excesivamente alto, puede provocar underfitting al impedir que el modelo capture patrones importantes. Su valor óptimo depende del número de muestras de entrenamiento y de num_leaves.
- **learning_rate**: También conocido como shrinkage_rate o eta η , este parámetro controla la velocidad a la que se actualizan los pesos del modelo después de cada iteración de boosting. Valores pequeños (por ejemplo, 0.01 o 0.05) hacen que el modelo aprenda más lentamente pero generalmente logran mejor precisión, aunque requieren más iteraciones (num_iterations) para converger. Por el contrario, valores altos (cerca de 1.0) aceleran el aprendizaje pero aumentan el riesgo de sobreajuste y pueden hacer que el modelo oscile alrededor del óptimo sin alcanzarlo. La práctica común es usar learning_rate bajos junto con un mayor número de iteraciones.
- **n_estimators**: Determina el número máximo de iteraciones de boosting que se realizarán, lo que equivale al número de árboles que se construirán. Para problemas de clasificación multiclase, LightGBM construye internamente num_class * num_iterations árboles. El valor predeterminado suele ser 100, pero puede aumentarse para mejorar el rendimiento, siempre ajustando también la tasa de aprendizaje. Una estrategia inteligente es combinarlo con early_stopping_rounds, que detiene el entrenamiento si la métrica de validación no mejora durante varias rondas consecutivas, ahorrando tiempo computacional y previniendo sobreajuste.
- **feature_fraction**: Especifica la fracción de características que se seleccionarán

aleatoriamente para construir cada árbol. Por ejemplo, `feature_fraction=0.8` significa que cada árbol utilizará aleatoriamente el 80 % de las variables disponibles. Esto aumenta la diversidad entre los árboles, reduce la correlación entre ellos y ayuda a prevenir el sobreajuste, además de acelerar el entrenamiento al considerar menos splits posibles. Valores típicos oscilan entre 0.5 y 0.9, siendo 1.0 el valor por defecto que significa que se usan todas las características.

- **bagging_fraction:** Similar a `feature_fraction`, pero aplicado al muestreo de datos en lugar de características. Este parámetro selecciona aleatoriamente una fracción de los datos sin reemplazo para entrenar cada árbol, lo que también se conoce como bagging. Para que sea efectivo, debe acompañarse de `bagging_freq`, que especifica cada cuántas iteraciones se realiza un nuevo muestreo. Por ejemplo, con `bagging_fraction=0.7` y `bagging_freq=5`, cada 5 iteraciones se toma una muestra aleatoria del 70 % de los datos. Esta técnica reduce el tiempo de entrenamiento y ayuda a combatir el sobreajuste.
- **reg_alpha y reg_lambda:** Estos parámetros aplican regularización L1 (lasso) y L2 (ridge) respectivamente para controlar la complejidad del modelo y prevenir el sobreajuste. La regularización añade una penalización a la función de pérdida por tener valores de parámetros grandes, lo que favorece modelos más simples y generalizables. Por defecto valen 0, lo que significa que no se aplica regularización. Aumentar estos valores puede ser especialmente útil cuando se sospecha de sobreajuste o cuando se trabaja con muchas características redundantes.
- **min_gain_to_split:** Establece la ganancia mínima necesaria para realizar una división en un nodo del árbol. Por defecto es 0, lo que significa que cualquier mejora, por pequeña que sea, justifica una división. Aumentar este valor hace que el modelo sea más conservador, ya que solo se dividirán nodos cuando la reducción en la pérdida sea significativa. Esto puede acelerar el entrenamiento al reducir el número de divisiones y también actuar como regularización, previniendo que el modelo aprenda patrones muy sutiles que podrían ser ruido.
- **objective:** Define la tarea de aprendizaje que debe realizar el modelo y la función de pérdida que se optimizará durante el entrenamiento. Es uno de los parámetros más importantes porque determina fundamentalmente cómo se evalúa el error y cómo se actualizan los pesos. Para problemas de regresión, los valores más comunes son 'regression' (error cuadrático medio L2), 'regression_l1' (error absoluto L1, más robusto ante outliers) y 'huber' (combinación híbrida de L1 y L2 para datos con ruido). Para clasificación binaria se usa 'binary' (pérdida logística), para clasificación multiclase se usa 'multiclass' y para ranking se usa 'lambda_rank'. En la práctica, elegir el objective correcto según el problema es el primer paso antes de ajustar cualquier otro parámetro.
- **metric:** Especifica qué métrica se utilizará para evaluar el rendimiento del modelo durante el entrenamiento, tanto para mostrar progreso como para implementar early stopping. A diferencia del objective (que es la función que el modelo optimiza), la métrica es solo para evaluación y puede ser diferente de la función de pérdida. LightGBM incluye múltiples métricas predefinidas: para regresión

están 'mse', 'mae', 'rmse'; para clasificación binaria 'binary_logloss' (pérdida logarítmica) y 'binary_error' (tasa de error); para clasificación multiclase 'multi_logloss' y 'multi_error'; y para ranking 'ndcg' y 'map'. Algunas métricas como 'auc' son mayores cuanto mejores, mientras que otras como 'rmse' son mejores cuanto menores.

- **boosting_type:** Determina el algoritmo específico que LightGBM utilizará para construir los árboles secuencialmente. Las opciones principales son: 'gbdt' (Gradient Boosting Decision Tree), que es el método tradicional y el valor por defecto, donde cada árbol corrige los errores del anterior; 'dart' (Dropouts meet Multiple Additive Regression Trees), que utiliza un enfoque inspirado en dropout de redes neuronales, apagando aleatoriamente algunos árboles durante el entrenamiento para reducir el sobreajuste; 'goss' (Gradient-based One-Side Sampling), que acelera el entrenamiento muestreando selectivamente las instancias con gradientes grandes; y 'rf' (Random Forest), que cambia el comportamiento a un verdadero bosque aleatorio donde los árboles se construyen independientemente sin boosting. La elección afecta tanto la velocidad de entrenamiento como la precisión y el riesgo de sobreajuste.

Ventajas específicas para detección de deepfakes

- **Alta precisión:** El enfoque secuencial de corrección de errores suele superar a Random Forest en problemas complejos como la detección de deepfakes.
- **Eficiencia computacional:** El muestreo inteligente permite entrenar con grandes volúmenes de audios en menos tiempo que otros métodos de boosting.
- **Manejo de desequilibrios:** Si existen desbalances entre clases, LightGBM incorpora mecanismos para ponderar las muestras adecuadamente.
- **Early stopping:** Se puede configurar para que detenga el entrenamiento cuando añadir más árboles no mejora la validación, evitando overfitting.

2.1.5. Support Vector Machines (SVM)

Las Máquinas de Vectores de Soporte (*Support Vector Machines*, SVM) son un conjunto de algoritmos de aprendizaje supervisado desarrollados por Vladimir Vapnik y su equipo en AT&T Bell Laboratories durante la década de 1990 [?]. Originalmente diseñadas para clasificación binaria, las SVM se han convertido en uno de los métodos más robustos y teóricamente fundamentados del aprendizaje automático.

Fundamento conceptual: El hiperplano óptimo

El objetivo fundamental de una SVM es encontrar un hiperplano que separe las dos clases (en nuestro caso, voces reales y voces generadas por IA) con el máximo margen posible. Para comprender este concepto, es útil visualizar un problema simple en dos dimensiones:

- Imaginemos que representamos cada audio como un punto en un plano, donde los ejes son dos características (por ejemplo, el primer formante y el primer MFCC).
- Las voces reales se agrupan en una región del plano y las generadas por IA en otra.
- Un hiperplano en dos dimensiones es simplemente una línea recta que intenta separar ambos grupos.

La clave de SVM reside en que no cualquier línea divisora es válida: el algoritmo busca aquella que maximiza la distancia (margen) entre la línea y los puntos más cercanos de cada clase. Estos puntos críticos, que “sostienen” el margen, reciben el nombre de **vectores de soporte** (*support vectors*), de donde el algoritmo toma su nombre.

Funcionamiento del algoritmo

El proceso de entrenamiento de una SVM puede entenderse en los siguientes pasos:

1. **Identificación de vectores de soporte:** El algoritmo examina todos los puntos de entrenamiento (instancias) e identifica aquellas que son más difíciles de clasificar, es decir, las que están más cerca de la frontera entre clases.
2. **Maximización del margen:** A partir de estos vectores de soporte, la SVM calcula el hiperplano que maximiza la distancia a ambos lados. Este margen máximo proporciona la mejor capacidad de generalización: cuanto más ancho sea el margen, menor será la probabilidad de error al clasificar nuevas instancias.
3. **Clasificación de nuevas muestras:** Una vez entrenado el modelo, para clasificar una nueva instancia, simplemente se calcula a qué lado del hiperplano se sitúa.

El truco del kernel: Separando lo inseparable

Uno de los mayores desafíos en la clasificación es que las instancias rara vez son linealmente separables en el espacio original de características. Es decir, no existe una línea recta (o hiperplano) que pueda separarlas perfectamente. Para abordar esta limitación, las SVM introducen el concepto de **kernel** o núcleo.

El *truco del kernel* (*kernel trick*) funciona de la siguiente manera conceptual:

- Los datos originales (no separables linealmente) se transforman implícitamente a un espacio de mayor dimensionalidad mediante una función matemática.
- En este nuevo espacio, es posible que los datos sí sean linealmente separables.
- La magia del kernel es que realiza esta transformación sin necesidad de calcular explícitamente las coordenadas en el espacio de alta dimensión, lo que sería computacionalmente costoso.

Los kernels más comúnmente utilizados son:

- **Kernel lineal:** Asume que los datos son aproximadamente separables por un hiperplano. Útil cuando el número de características es muy grande.

- **Kernel polinomial:** Crea fronteras de decisión curvas mediante combinaciones polinómicas de las características originales.
- **Kernel RBF (*Radial Basis Function*):** Es el más utilizado en muchos problemas. Proyecta los datos a un espacio de dimensionalidad infinita, permitiendo fronteras de decisión altamente complejas y no lineales. Se basa en la similitud entre muestras medida por distancia euclidiana:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$$

donde γ controla la influencia de cada muestra: un valor pequeño considera vecindarios amplios (frontera más suave), mientras que un valor grande se enfoca en vecindarios reducidos (frontera más ajustada a los datos).

Hiperparámetros

Vamos a ver cuáles son los hiperparámetros más importantes en los SVM.

- **C:** Controla el equilibrio entre tener un margen amplio y clasificar correctamente los puntos de entrenamiento. Un valor bajo de C busca un margen grande aunque se cometan algunos errores (modelo más generalista). Un valor alto de C penaliza fuertemente los errores, ajustándose más a los datos de entrenamiento (riesgo de overfitting).
- **kernel:** Es la función que transforma los datos a un espacio de mayor dimensión donde puedan ser separables linealmente. Los kernels más comunes son: lineal (recomendado para datos con muchas características o problemas aproximadamente lineales), polinomial (permite curvas más complejas mediante el grado del polinomio), y RBF o radial (el más utilizado por defecto, capaz de crear límites de decisión muy flexibles y adaptarse a diferentes formas de los datos). La elección del kernel determina fundamentalmente la capacidad del modelo para encontrar patrones complejos.
- **gamma γ :** Específico de kernels no lineales (RBF, sigmoide o polinomial). define cuánta influencia tiene un solo punto de entrenamiento: valores bajos significan que cada punto tiene un alcance amplio, produciendo límites de decisión más suaves y generales; valores altos hacen que cada punto influya solo en su vecindario cercano, lo que puede generar límites muy ajustados a los datos de entrenamiento pero con alto riesgo de sobreajuste.
- **degree:** Cuando se utiliza el kernel polinomial, este parámetro especifica el grado del polinomio usado para transformar los datos. Un grado mayor permite capturar relaciones más complejas y no lineales, pero también aumenta el riesgo de sobreajuste y el costo computacional. Normalmente se utilizan grados bajos (2, 3 o 4) porque valores muy altos tienden a producir modelos inestables y difíciles de generalizar.

- **coef0**: Este parámetro es relevante para los kernels polinomial y sigmoide, donde actúa como un término independiente en la función del kernel. En el kernel polinomial, coef0 controla cuánto influyen los términos de menor grado respecto a los de mayor grado; en el sigmoide, ayuda a definir la forma de la función de activación. Aunque no es tan crítico como C o gamma, puede necesitar ajuste para optimizar el rendimiento del modelo.
- **probability**: Este parámetro booleano determina si el modelo SVM debe calibrarse para proporcionar estimaciones de probabilidad junto con las predicciones de clase. Activarlo (True) permite obtener la probabilidad de pertenencia a cada clase mediante validación cruzada interna, lo cual es útil para interpretar la confianza del modelo. Sin embargo, este proceso aumenta significativamente el tiempo de entrenamiento y puede afectar ligeramente la precisión de las clasificaciones.

Ventajas específicas para detección de deepfakes

- **Fundamento teórico sólido**: A diferencia de otros métodos heurísticos, SVM está basada en la teoría de optimización convexa, lo que garantiza que la solución encontrada es óptima (máximo margen global).
- **Eficaz en espacios de alta dimensión**: Las características de audio pueden generar vectores de gran dimensionalidad (decenas o cientos de coeficientes). SVM maneja bien esta situación sin colapsar por la maldición de la dimensionalidad.
- **Robustez ante overfitting**: La maximización del margen proporciona una regularización natural que mejora la generalización, crucial cuando se trabaja con datasets limitados de voces deepfake.
- **Versatilidad mediante kernels**: La capacidad de elegir diferentes kernels permite adaptar el modelo a la estructura no lineal de los datos de audio sin necesidad de transformaciones manuales.
- **Interpretabilidad limitada pero útil**: Aunque no tan interpretable como los árboles de decisión, el análisis de los vectores de soporte puede revelar qué audios son más representativos o ambiguos en la frontera de decisión.

2.1.6. AASIST

AASIST (*Audio Anti-Spoofing usign Integrated Spectro-Temporal graph attention networks*) es un modelo propuesto por Jee-weon Jung, Hee-Soo Heo, Hemlata Tak, Hye-jin Shim, Joon Son Chung, Bong-Jin Lee, Ha-Jin Yu y Nicholas Evans en 2022. La principal motivación para el desarrollo de este clasificador surge de que los artefactos que sirven para diferenciar audios falsificados de audios bona fide se suelen encontrar en intervalos temporales o espectrales. Por esto, en la práctica se usaban ensembles costosos, desde el punto de vista computacional, donde cada subsistema se centraba en ciertos artefactos. AASIST consigue reemplazar ese enfoque por un único sistema que combina información espectro-temporal buscando robustez ante diversos tipos de ataques.

Arquitectura y funcionamiento

El modelo tiene las siguientes fases:

1. Extracción de características a partir del audio crudo:
 - Se usa un **encoder** basado en RawNet2 que acaba generando un mapa de características F , $F \in \mathbb{R}^{C \times S \times T}$ siendo C , número de canales, S , número de bins espectrales y T , longitud temporal.
 - Para ello, primero, se pasa el audio por una primera capa *sinc-convolution* con 70 filtros. La diferencia frente al RawNet2 original, es que en AASIST se interpreta la salida de esta capa como una “imagen” 2D de 1 canal.
 - A continuación, esta primera representación se pasa por seis bloques residuales con **pre-activación** que van comprimiendo y transformando la información útil para tener una representación lo más compacta posible.
2. Posteriormente, se generan dos **grafos completos** que modelan, de forma independiente, los dominios temporal y espectral, siendo G_t y G_s respectivamente. A cada grafo, se le aplica “**graph pooling**” para reducir el número de nodos, conservando los más relevantes lo que permite bajar el coste computacional posterior.
3. Ambos grafos se combinan en un tercer grafo, G_{st} con $N_t + N_s$ nodos entre los que se generan todas las aristas nuevas posibles en ambas direcciones, manteniendo las aristas de los grafos anteriores.
4. Bloque HS-GAL + pooling:
 - Se aplica **atención heterogénea** usando uno de los tres vectores de proyección según la relación entre los tipos de los nodos entre los que se hace la relación.
 - Un (**stack node**), conectado de forma unidireccional a todos los nodos, que va acumulando la información espectro-temporal entre sucesivas capas HS-GAL.
 - Tras cada HS-GAL, se aplica otra vez la técnica “**graph pooling**” con el mismo objetivo anterior.
5. A continuación de crear el grafo G_{st} , se aplica la operación MGO(*Max Graph Operation*) que usa las técnicas del punto anterior. De forma paralela, se procesan dos ramas en las que se ejecutan consecutivamente dos secuencias HS-GAL-pooling. Dentro de cada rama, el “stack node” se propaga de la primera HS-GAL a la segunda. Finalmente, se combinan las salidas de ambas ramas usando un máximo elemento a elemento.
6. Por último, usando las operaciones “**max**” y “**average**” sobre cada subgrafo final(temporal y espectral), se generan 4 vectores que se combinan con el “stack node” y se pasan a la capa de salida.

Innovaciones clave

- **HS-GAL**: una capa de atención, que permite ir integrando simultaneamente ambos grafos, combinada con un “stack” node para ir acumulando información espectro-temporal
- **MGO**: un método con dos ramas aplicando paralelamente HS-GAL más una fase de “pooling” lo que permite que cada secuencia pueda aprender distintos grupos de artefactos.
- **Nuevo esquema de readout**: permite concatenar la información contenida en el “stack node” con las estadísticas sacadas de la operaciones “max” y “average” finales.

Ventajas específicas para detección de deepfakes

- **Integración espectro-temporal**: al modelar conjuntamente los grafos temporal y espectral en un grafo heterogéneo, permite encontrar información cruzada que se podría perder si se tratara por separado.
- **Stack node**: esta técnica “acumulativa” ayuda a encontrar artefactos de spoofing cuando no están presentes en un solo nodo y se encuentran distribuidos en varios instantes o bandas.
- **Readout**: al juntar estadísticas globales(average) con evidencia puntual fuerte(max), facilita la detección de diferentes patrones de “spoofing”.
- **Ramas paralelas**: en MGO, se introducen dos ramas procesando en paralelo, permitiendo captar pistas complementarias.

2.1.7. Regresión Logística

A pesar de su nombre, la Regresión Logística es un algoritmo de clasificación lineal utilizado para predecir la probabilidad de que una instancia pertenezca a una categoría específica. Es un modelo fundamental en el aprendizaje estadístico debido a su simplicidad, eficiencia y facilidad de interpretación.

Fundamento conceptual: La función Sigmoides

A diferencia de la regresión lineal, que predice valores continuos, la regresión logística utiliza la función logística o sigmoide para confinar el resultado de una ecuación lineal entre 0 y 1. La fórmula matemática es:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Donde z es la combinación lineal de las características de entrada ($w^T x + b$). El valor resultante se interpreta como la probabilidad de pertenencia a la clase positiva. Si la probabilidad es superior a un umbral (generalmente 0.5), se clasifica como “Real”, de lo contrario, como “Deepfake”.

Proceso de entrenamiento

El modelo aprende los pesos (w) minimizando una función de pérdida denominada **Log-Loss** o entropía cruzada binaria. Este proceso se realiza mediante algoritmos de optimización como el Gradiente Descendente. Durante el entrenamiento, el modelo ajusta los coeficientes para penalizar fuertemente las predicciones que se alejan de la etiqueta real.

Ventajas específicas para detección de deepfakes

- **Interpretabilidad directa:** Los coeficientes asignados a cada característica (como el pitch o los MFCC) indican directamente la importancia y la dirección de la influencia de cada parámetro en la detección del fraude.
- **Eficiencia:** Es computacionalmente muy ligero, lo que permite procesar grandes volúmenes de datos de audio en tiempo real con recursos mínimos.
- **Línea base robusta:** Sirve como un excelente modelo de referencia (*baseline*) para comparar el rendimiento de arquitecturas más complejas.

2.1.8. K-Nearest Neighbors (k-NN)

El algoritmo de los K-Vecinos más Cercanos (k-NN) es un método de aprendizaje supervisado basado en instancias. A diferencia de otros modelos, k-NN no construye un modelo explícito durante el entrenamiento, sino que almacena todas las instancias de entrenamiento para realizar la clasificación en el momento de la consulta.

Arquitectura y funcionamiento

El principio de k-NN es la proximidad: asume que las muestras de audio con características acústicas similares pertenecerán a la misma categoría.

1. **Cálculo de distancia:** Cuando se presenta una nueva muestra de audio, el algoritmo calcula la distancia (generalmente la distancia euclidiana) entre esa muestra y todas las demás del conjunto de entrenamiento.
2. **Selección de vecinos:** Se seleccionan los k ejemplares más cercanos (donde k es un número entero definido por el usuario).
3. **Votación mayoritaria:** La muestra se asigna a la clase que sea más frecuente entre sus k vecinos.

El papel del parámetro k

La elección de k es crítica: un valor muy pequeño (ej. $k = 1$) hace que el modelo sea sensible al ruido en el audio, mientras que un valor muy grande puede suavizar demasiado las fronteras de decisión.

Ventajas específicas para detección de deepfakes

- **Sin suposiciones sobre los datos:** No asume que las características del audio sigan una distribución lineal, lo que le permite capturar patrones complejos en la distribución de artefactos sintéticos.

- **Eficacia con características bien definidas:** Si la extracción de características logra separar bien las clases, k-NN es extremadamente preciso.
- **Aprendizaje incremental:** Es fácil añadir nuevos ejemplos de ataques de audio sintético al sistema sin necesidad de reentrenar todo el modelo.

Como hemos visto, se ha presentado un espectro diverso de clasificadores que permiten abordar la detección de spoofing desde diferentes ángulos. Los modelos lineales y de vecinos cercanos, como la **Regresión Logística** y **k-NN**, ofrecen una base sólida y eficiente para el análisis de características acústicas predefinidas. Por otro lado, métodos como **Random Forest** y **LightGBM** incrementan la robustez del sistema ante datos ruidosos y relaciones no lineales.

Por último, modelos como **Wav2Vec2** y **AASIST** procesan la señal de audio cruda y modelar relaciones espectro-temporales mediante grafos y mecanismos de atención. La combinación de estos enfoques permite no solo alcanzar altas tasas de precisión, sino también adaptarnos según la disponibilidad de recursos computacionales. Esta base taxonómica de modelos constituye el núcleo operativo sobre el cual se aplicarán posteriormente las técnicas de explicabilidad.

2.2. Modelos de explicación

La adopción de modelos de aprendizaje profundo ha permitido alcanzar una precisión sin precedentes en la detección de audio sintético. Sin embargo, estos sistemas operan frecuentemente como “cajas negras”, lo que dificulta su aplicación en ámbitos críticos como en forense o ciberseguridad. La Inteligencia Artificial Explicable (XAI) surge como la solución técnica para dotar a estos modelos de transparencia, permitiendo a los expertos entender el “por qué” de cada clasificación.

A continuación, se describen las técnicas de explicabilidad actuales, organizados según el siguiente enfoque técnico:

- **Métodos de Atribución y Perturbación:** Se analizan técnicas post-hoc como **SHAP** y **LIME**, que permiten identificar qué características acústicas individuales son determinantes para el modelo, así como **Grad-CAM** e **Integrated Gradients**, fundamentales para visualizar la relevancia en el plano tiempo-frecuencia.
- **Razonamiento Contrafáctico:** Se explora el modelo **DiCE**, una herramienta que permite entender la frontera de decisión mediante la creación de escenarios hipotéticos (“¿qué cambios harían que este audio fake pareciera real?”).
- **Modelos Interpretables por Diseño (Ante-hoc):** Se profundiza en arquitecturas cuya transparencia es intrínseca, como **SincNet**, que utiliza filtros con significado físico, y **ProtoPNet**, que basa su decisión en la comparación con prototipos o ejemplos conocidos.

2.2.1. SHAP

Basado en la teoría de juegos cooperativos, SHAP asigna a cada característica acústica un valor de importancia que representa su contribución marginal. El valor de Shapley ϕ_i para una característica i se calcula como:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)]$$

Este método es preferido en el análisis forense debido a su consistencia matemática y su capacidad para ofrecer tanto explicaciones locales como una visión global de la importancia de los descriptores (como los coeficientes MFCC o el pitch).

2.2.2. LIME

LIME aproxima localmente la superficie de decisión de un modelo de caja negra mediante un modelo lineal interpretable. En el dominio del audio, el proceso se define mediante la perturbación de la entrada x (espectrogramas o marcos temporales) para observar las variaciones en la salida $f(x)$. La explicación g se obtiene minimizando:

$$\xi(x) = \arg \min_{g \in G} L(f, g, \pi_x) + \Omega(g)$$

donde L es la pérdida de fidelidad, π_x define la vecindad de la muestra y $\Omega(g)$ mide la complejidad del modelo sustituto.

2.2.3. Grad-CAM

Utiliza los gradientes de la última capa convolucional para producir un mapa de calor que resalta las regiones del espectrograma que influyen en la decisión. Aunque es eficaz para detectar sesgos en el conjunto de datos, su baja resolución espacial a menudo dificulta la identificación de discontinuidades de fase de micro-segundos, típicas de los vocoders neuronales.

2.2.4. Integrated Gradients

Integrated Gradients (IG) se basa en integrar los gradientes de la función del modelo a lo largo de una trayectoria que conecta una entrada de referencia (“baseline”) x' con la entrada real x . Este modelo permite capturar cómo varía la sensibilidad del modelo respecto a cada característica a lo largo del recorrido, evitando problemas como la saturación del gradiente en el punto de entrada.

Siendo F la función del modelo, i una característica específica que se está observando, x' el “baseline” y α que parametriza el camino continuo entre x y x' :

$$IG_i(x) = (x_i - x'_i) \times \int_{\alpha=0}^1 \frac{\partial f(x' + \alpha(x - x'))}{\partial x_i} d\alpha$$

Tres propiedades clave de IG que justifican teóricamente su uso son:

- **Sensibilidad:** si x y x' difieren únicamente en una característica y la predicción varía, entonces esa característica debe tener una atribución no nula.
- **Invariancia de implementación:** si dos modelos implementan la misma función aunque varíen las arquitecturas o la organización de parámetros, entonces las atribuciones de IG serán iguales.
- **Completitud:** la suma de las atribuciones de todas las características es igual a la diferencia entre la predicción del modelo para x y x' .

En audio, el “baseline” se representa como ruido blanco o como silencio, nosotros hemos optado por esta última opción.

2.2.5. DICE

Modelos como DiCE permiten generar ejemplos sintéticos mínimos que cambiarían la predicción del modelo. Esto es vital para analistas forenses, ya que permite identificar qué características de “naturalidad” le faltan a una muestra para ser considerada auténtica, proporcionando una comprensión causal del fenómeno de los deepfakes.

2.2.6. SincNet

SincNet sustituye las capas de convolución estándar por filtros de banda basados en la función Sinc. El modelo solo aprende las frecuencias de corte f_1 y f_2 , permitiendo una interpretación física directa de los rangos espectrales (como formantes o armónicos) que el sistema utiliza para discriminar la voz real de la sintética.

2.2.7. ProtoPNet

Estos modelos clasifican la señal encontrando similitudes con “prototipos” aprendidos durante el entrenamiento. Ante un audio sospechoso, el modelo proporciona una explicación del tipo: “Este segmento se clasifica como deepfake porque se asemeja a este patrón de artefacto espectral observado en el modelo de síntesis WaveNet”.

Tras ver las diversas metodologías, se puede concluir que la detección de audio deepfake no depende de un único enfoque, sino de la combinación estratégica de diferentes niveles de explicabilidad. Los modelos analizados ofrecen una visión complementaria del problema:

- **Precisión vs. Explicabilidad:** Mientras que métodos post-hoc como **SHAP**, **LIME** e **Integrated Gradients** permiten auditar modelos de alta complejidad sin sacrificar su rendimiento, técnicas como **SincNet** y **ProtoPNet** proponen un cambio de paradigma hacia la transparencia por diseño (*ante-hoc*), donde el razonamiento del modelo es inseparable de su arquitectura.
- **Análisis Multidimensional:** La inclusión de **Grad-CAM** permite a los analistas visualizar anomalías en el espectro sonoro, mientras que herramientas como **DiCE** aportan un valor único al proporcionar simulaciones causales. Estas últimas

son fundamentales para identificar qué rasgos de “naturalidad” están ausentes en una señal sintética.

En definitiva, el conjunto de técnicas presentadas establece el marco de referencia para este proyecto. La integración de estos métodos garantiza que el sistema resultante no solo actúe como un clasificador binario, sino como una herramienta de soporte a la decisión, capaz de proporcionar evidencias técnicas robustas.

3. Metodología

3.1. Dataset

Para encontrar un dataset público que tuviera voces tanto reales como clonadas y que además fueran por pares (i.e. un audio de voz real cuya transcripción es "Hoy he comido en un restaurante chino" un audio clonando dicha voz diciendo lo mismo) ha sido complicado. Hemos echado un ojo a bastantes datasets. Vamos a comentar los que hemos tenido en cuenta.

1. HABLA [?]: Este dataset cuenta con una gran cantidad de audios tanto reales, como generados (con técnicas como TTS) y voces clonadas (con técnicas como Cycle-GAN). Lo hemos descartado para una primera iteración del proyecto, pero no lo descartamos para una próxima iteración.
2. audioMNIST [?]: Este dataset cuenta con 30 mil audios de los números del 0 al 9 en inglés. Lo hemos descartado porque todos los audios son voces reales, por lo que no nos sirve para nuestra tarea.
3. ASVSpooof2021 [?]: Este dataset forma parte de una serie de desafíos internacionales organizados por la comunidad de verificación automática de audio cuyo objetivo es evaluar y mejorar los sistemas capaces de detectar voz manipulada. El dataset se compone de tres grupos de audio, todos ellos con voz real y generada mezclada, logical access con grabaciones transmitidas mediante canales de voz con efectos de codificación y transmisión, physical access con grabaciones de voz auténticas y ataques de reproducción en espacios físicos reales y speech deepfake con grabaciones generadas sintéticamente y comprimidas de formas distintas. Este dataset lo hemos descartado por no contar con pares de audio aunque se pueden rescatar algunos audios en inglés sobre todo para probar los modelos que probemos más adelante.
4. Kaggle
5. Wavefake []: Este dataset de Kaggle cuenta con gran cantidad de audios generados. Como tal, nos sirvió para probar el primer prototipo de extracción de características y buscar librerías como librosa o speechRecognition. Este dataset, al no tener los audios reales, no nos sirve para luego desarrollar los modelos.

El dataset por el que nos hemos decantado se llama **ODSS**. Hemos usado este conjunto de audios porque ya tiene creado un par para cada audio, lo que nos ahorra tiempo de generar nuestros propios audios. A esta ventaja se le suma que ODSS ya

contenía audios en Inglés y en Español, ambos idiomas son sumamente hablados por lo que es interesante centrarse en ellos.

Con todo esto mencionado, hemos tomado un subset de 100 audios de cada idioma. La mitad son audios naturales y la otra mitad audios generados. Más adelante, probaremos a usar más cantidad de audios y compararemos el rendimiento.

3.2. Extracción de características

Para poder clasificar los audios en reales y generados tenemos que pensar primero en qué datos necesitamos pasar a los modelos para que aprendan. Podemos separar los datos que debemos proporcionar a dichos modelos en 3 grupos:

1. Características. Podemos extraer características de la voz como el tono fundamental, los formantes, las pausas, y otros. Con estos datos, los modelos pueden aprender las relaciones entre los dos grupos de audios.
2. Gráficas. Podemos extraer gráficas de la voz como la forma de onda, el espectrograma de MEL, y otros. Con estas gráficas las CNN pueden aprender los puntos clave que diferencian a los audios reales de los generados.
3. Audio crudo. Existen modelos llamados wav2vec los cuales aprenden directamente de los audios, sacando un vector denso de características latentes en los audios, para después hacer ajuste fino o *fine-tuning* de un modelo para clasificar los audios.

Vamos a ver más en detalle qué características de cada tipo sacamos.

Características

Podemos extraer características de la voz como el tono fundamental, los formantes, las pausas, y otros. Con estos datos, los modelos pueden aprender las relaciones entre los dos grupos de audios. Tenemos que destacar que las características de este tipo extraídas son mayormente arrays en el que cada componente es un valor en un momento determinado. Esto es porque la voz tiene la componente temporal, por lo que hay que dividir cada audio en marcos temporales (frames). Además, los modelos que aplicaremos no entrenan con arrays, por lo que los promediaremos con la media y/o desviación típica. Vamos a explicar cada característica que extraemos de los audios:

1. **Valor cuadrático medio (rms):** Mide la energía promedio de una señal acústica (i.e. la intensidad o volumen general del audio). Se extrae dividiendo la señal en frames, para cada frame se calcula la raíz cuadrada del promedio de los valores de onda al cuadrado y, por último, se promedian esos valores. En voz humana natural, el RMS tiende a tener variaciones más orgánicas, mientras que audios sintéticos pueden mostrar patrones más uniformes.
2. **Tasa de cruces por cero (zcr):** Mide el número de veces que la señal cambia de signo por segundo, lo que nos permite distinguir entre los sonidos tonales (periódicos) y los ruidosos (no periódicos). Se extrae detectando los puntos

donde la señal cambia de signo, se cuentan dichos puntos por unidad de tiempo y se normaliza por la longitud del frame. Los sonidos sordos (como /s/, /f/) tienen ZCR alto, mientras los sonoros (/a/, /m/) tienen ZCR bajo.

3. **Centroide espectral:** Mide el centro de masa del espectro de frecuencias, lo que nos dice, de forma ponderada, si la energía de un sonido se concentra en las frecuencias graves (bajas) o en las frecuencias agudas (altas). Se obtiene calculando la Transformada Rápida de Fourier (FFT) para cada frame para obtener el espectro de frecuencias, se ponderan las frecuencias por su magnitud (energía de dicha frecuencia) y se calcula la media de estas. Cabe mencionar que las voces femeninas tienden a tener centroides más altos que masculinas.
4. **Ancho de banda espectral:** Mide qué tan dispersas están las frecuencias alrededor del centroide, para ver si el sonido es “puro” como un silbido o una sílaba mantenida, o es “ruidoso” como el ruido blanco o un aplauso. Se extrae hallando el centroide como antes y se calcula la desviación típica ponderada en vez de la media ponderada.
5. **Punto de caída espectral (spectral rolloff):** Mide la frecuencia por debajo de la cual se concentra un determinado porcentaje de la energía total del espectro, es decir, la frecuencia límite para un porcentaje de energía. Normalmente, dicho porcentaje es del 85 %, aunque puede variar entre 75 % a 90 %, y funciona como un percentil. Se obtiene calculando el centroide igual que antes y sumando la energía progresivamente hasta que lleguemos a una frecuencia con la que nos pasamos de dicho porcentaje. Es útil para distinguir entre sonidos con energía concentrada en bajas frecuencias, en un amplio espectro, o en altas frecuencias.
6. **Planitud espectral:** Mide cómo de plano es el sonido. Varía entre 0 y 1 siendo 0 un sonido con picos pronunciados y 1 un sonido con pocos picos. Se obtiene calculando el espectro como antes (FFT) y dividiendo la media geométrica del espectro entre la media aritmética del mismo.
7. **Tono fundamental (F0):** Es la frecuencia más baja y periódica de un sonido. En el contexto de la voz, es la frecuencia a la que vibran tus cuerdas vocales. El tono fundamental puede verse en, por ejemplo, las emociones, las preguntas frente a afirmaciones, las notas musicales, entre otras, por lo que nos da mucha información acerca de algo o alguien. Hay varias formas de calcularlo, y ninguna es 100 % precisa. Nosotros nos decantamos por la función PYIN, la cual primero obtiene las frecuencias fundamentales mediante el algoritmo YIN y después aplica el algoritmo probabilístico de Viterbi para obtener la cadena F0 más probable. Estos son algoritmos más sofisticados que combinan autocorrelación, análisis espectral y probabilidades para evitar errores comunes como la octava errónea (detectar 200Hz por ruido en vez del tono real de 100Hz), zonas no voiceadas (unvoiced) y ruido de fondo.
8. **Formantes:** Son las frecuencias de resonancia del tracto vocal (la boca, la garganta y la nariz). Estas frecuencias se amplifican de forma natural cuando hablamos, dependiendo de la forma que le demos a la boca.

- a) F1 (Primer formante): Relacionado con la abertura de la mandíbula (qué tan abierta está la boca).
- b) F2 (Segundo formante): Relacionado con la posición de la lengua (adelante o atrás).
- c) F3 (Tercer formante): Relacionado con la posición de la punta de la lengua y tiene mucha importancia en las vocales raras en la identidad del hablante.

Para extraerlos hay varias alternativas, nosotros usamos el método de Burg para estimar las formantes, después se muestrean 100 puntos a lo largo del audio y se calcula la media.

9. **Relación Armónico-Ruido:** Mide la proporción entre energía periódica (armónicos) y energía aperiódica (ruido). Esta relación es una indicadora directa de la eficiencia fonatoria y la salud vocal: puede indicar la existencia de patologías como voz ronca, o afonía; una fatiga vocal; o, en algunos casos, emociones. Hay varias formas de calcularla: como el método de autocorrelación o el de análisis espectral. Nosotros usamos la función `to_harmonicity` de `parselmout.Sound`, la cual la calcula con el método de autocorrelación: primero halla el F0 de los frames; después aplica la función de autocorrelación normalizada $r(\tau) = \frac{\int x(t) \cdot x(t+\tau) dt}{\int x^2(t) dt}$; luego busca el máximo de la función de autocorrelación en el intervalo alrededor del período fundamental esperado, este máximo corresponde a la correlación entre la señal y su versión desplazada un período; tras esto calcula el hnr en decibelios $HNR = 10 \cdot \log_{10} \left(\frac{r_{\max}}{1-r_{\max}} \right)$ y, por último, aplica interpolación parabólica para obtener valores más precisos del máximo y realiza correcciones para compensar el efecto de la ventana de análisis. Es interesante saber que las voces humanas naturales suelen oscilar entre los 10 a 25 dB, por lo que unos valores extremos pueden indicar voz sintética.
10. **Proporción de silencio:** Mide el porcentaje del tiempo o de frames donde no hay voz activa, es decir, hay silencio o ruido de fondo hasta cierto umbral. La forma de calcularla es muy simple: se establece un umbral de energía el cual por debajo una energía es considerada silencio, se calcula el rms y se le aplica el filtro del umbral, finalmente se divide el número de frames considerados silencio entre el número total de frames. Esto, pese a su simpleza, puede ser determinante en el análisis de una voz ya que las IAs pueden generar patrones de pausas poco naturales o demasiado regulares.
11. **Coefficientes Cepstrales en Frecuencia de Mel (mfcc):** Son una representación compacta del espectro de frecuencias que imita cómo percibe el sonido el oído humano. En lugar de trabajar con frecuencias lineales (Hz), trabajan con una escala llamada escala Mel, que es más sensible a los cambios en frecuencias bajas que en altas (como nuestro oído). Son un total de 13 coeficientes: el primero representa la energía promedio del espectro (similar al RMS, pero en el dominio cepstral); mientras que el resto representan la forma detallada del espectro: los picos, los valles, las pendientes. Cada coeficiente añade un nivel de detalle diferente. Estos coeficientes son muy importantes ya que son, con diferencia, la

característica más utilizada en: reconocimiento de voz (Speech-To-Text), reconocimiento de hablante (Identificación), clasificación de géneros musicales, entre muchas otras aplicaciones. Hoy en día son un estándar en reconocimiento de voz. Se extraen mediante un proceso más laborioso: primero se hace un pre-énfasis, amplificando las frecuencias altas, ya que estas tienen poca energía; después se calcula el espectro de frecuencias de cada frame; tras esto se aplica un banco de filtros triangulares espaciados según la escala Mel, donde por debajo de los 1000 Hz se aplican filtros lineales (nuestro oído distingue bien los cambios en frecuencias bajas) y por encima de los 1000 Hz se aplican filtros logarítmicos (nuestro oído distingue peor los cambios en frecuencias altas), con la fórmula $Mel(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right)$ y, para terminar, aplica la Transformada Coseno Discreta (DCT), la cual decorrelaciona las bandas de Mel, que suelen estar correlacionadas entre sí, compacta la información y devuelve los 13 primeros coeficientes (pueden aparecer entre 20 y 40, pero no son muy representativos).

12. **Asimetría (skewness):** Mide hacia qué lado se inclina la distribución de la energía en un conjunto de datos. Si hay una asimetría positiva, la energía se concentra en valores bajos, con una cola larga hacia los valores altos. Si hay una asimetría negativa, la energía se concentra en valores altos, con una cola larga hacia los valores bajos. Si no hay asimetría, la energía está equilibrada alrededor del centro (como una campana de Gauss). Se calcula restando la media a cada muestra y elevando al cubo, luego hallando el promedio de estas desviaciones cúbicas, y, finalmente, dividiendo por la desviación estándar al cubo para estandarizar. Cabe mencionar que unas distribuciones de amplitud asimétricas pueden indicar características anómalas en voces sintéticas.
13. **Curtosis:** Mide qué tan concentrados están los valores alrededor de la media y qué tan pesadas son las colas de la distribución. En audio, la curtosis nos dice qué tan "espigado" o "suave" es un sonido en términos de cómo se distribuyen sus amplitudes (en el tiempo) o su energía (en la frecuencia). Se obtiene con la siguiente fórmula
$$Curtosis = \frac{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^4}{\left(\sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2} \right)^4}$$
. Adicionalmente, se puede restar 3 a la curtosis para que la mitad (mesocúrtica) se halle en 0. Podemos destacar que una curtosis alta (distribución picuda) puede aparecer en audios con compresión excesiva o artefactos de síntesis.
14. **Transcripción:** Para la transcripción de los audios usamos modelos de **vosk**. Esta elección se debe a que tiene modelos para ambos idiomas que vamos a usar y además, 2 modelos dentro de cada lenguaje. El que usamos para las pruebas es el small ya que es más rápido y por lo tanto más útil para esta primera fase pero dejamos en consideración el modelo full para futuras fases ya que tiene mayor precisión. Sobre esto, cabe mencionar que primero probamos el modelo whisper pero tras varias pruebas con errores y la incapacidad para hacer funcionar, lo descartamos y es cuando escogimos vosk para esta tarea. Es interesante tener en cuenta la transcripción de un audio ya que en ocasiones, si no podemos sacar texto en claro, pero se sabe que hay voces, es muy probable que el audio sea

generado.

3.3. Métricas de evaluación

Antes de entrar a hablar de los modelos, vamos a ver qué métricas de evaluación usaremos en estos, ya que son la pieza clave para entender qué tan bien está funcionando un modelo concreto. Métricas de evaluación hay muchas, e incluso distintas según distintos problemas (regresión, clasificación, etc.). Las principales y más conocidas son la exactitud (*accuracy*), *f1*, y Error Cuadrático Medio (RMSE), aunque hay muchas más como hemos mencionado. Vamos a listar todas las métricas que usamos, qué es lo que evalúan y en qué modelos las usamos (ya que algunas son tan importantes que se usan en casi todos los modelos). Es importante mencionar que, ya que nuestro problema es de clasificación, no usaremos algunas métricas de regresión como el RMSE, pues no podemos calcularlas ni tiene sentido.

Matriz de confusión

Vamos a introducir también la matriz de confusión y el concepto de aciertos y fallos, ya que es fundamental para entender mejor las métricas. Un modelo puede hacer dos cosas, acertar y fallar, y, a su vez, los aciertos y los fallos pueden deberse a que la instancia fuera negativa y positiva. Con esto tenemos los siguientes conceptos:

- **Verdaderos Positivos (VP):** Instancias positivas predichas como positivas.
- **Verdaderos Negativos (VN):** Instancias negativas predichas como negativas.
- **Falsos Positivos (FP):** Instancias negativas predichas como positivas. También llamado Error tipo I.
- **Falsos Negativos (FN):** Instancias positivas predichas como negativas. También llamado Error tipo II.

Las matrices de confusión toman esos cuatro valores y los distribuyen en: eje y los valores reales, eje x los valores predichos y se forma una matriz $N \times N$, siendo N el número de clases que definamos. En nuestro caso, y en la mayoría de casos, se da una matriz 2×2 . También es importante entender que la diagonal principal siempre guarda los valores verdaderos (los aciertos de predicción). Con la siguiente imagen queremos ilustrar cómo se ve una matriz de confusión 2×2 . Normalmente se pone la clase negativa arriba/a la izquierda de la clase positiva, aunque podrían estar al revés, pero siempre manteniendo lo que comentamos de la diagonal principal.




Figura 2: Ejemplo real de matriz de confusión.

Métricas usadas

Veamos entonces con lo que ya sabemos qué métricas usamos y qué miden.

- **Exactitud (*accuracy*):** Mide la proporción total de predicciones correctas (tanto positivas como negativas) sobre el total de casos. Es útil cuando las clases están balanceadas, pero puede ser engañosa si hay un desbalance (ej. 95 % de una clase y 5 % de otra, predecir siempre la mayoritaria daría un 95 % de *accuracy*). Su fórmula es: $\frac{VP+VN}{VP+VN+FP+FN}$. Lo usamos en Random Forest, LightGBM, SVM, ...
- **Precisión:** Mide la relación de las clases predichas como positivas frente al total de valores reales positivos. Es una métrica que se enfoca en controlar los Falsos Positivos (FP). Es útil cuando el costo de un FP es alto (por ejemplo, marcar un correo legítimo como spam). Su fórmula es: $\frac{VP}{VP+FP}$. Podría calcularse la precisión para la clase negativa también. Lo usamos en Random Forest, LightGBM, SVM, ...
- **Exhaustividad (*recall*):** Mide la cantidad de valores positivos que el modelo logró predecir correctamente. Es una métrica que se enfoca en minimizar los Falsos Negativos (FN). Es útil cuando el costo de un FN es alto (por ejemplo, no detectar una enfermedad grave). Su fórmula es: $\frac{VP}{VP+FN}$. Podría calcularse el *recall* de la clase negativa también. Lo usamos en Random Forest, LightGBM, SVM, ...

- **F1-Score:** Es la media armónica entre la Precisión y el Recall. Busca un equilibrio entre ambas métricas. Es una métrica más robusta que la Accuracy cuando hay clases desbalanceadas, ya que penaliza los extremos (una precisión alta con recall bajo, o viceversa). Es útil cuando quieres una sola métrica que resuma el rendimiento en la clase positiva. Su fórmula es: $2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$. Lo usamos en Random Forest, LightGBM, SVM, ...
- **Área bajo la curva ROC (ROC-AUC):** Mide la capacidad discriminativa del modelo, independientemente del umbral de decisión elegido. La curva ROC (Receiver Operating Characteristic) grafica la Tasa de Verdaderos Positivos (Recall) frente a la Tasa de Falsos Positivos. La fórmula de la curva es: $\frac{FP}{FP+VN}$. El AUC (Area Under the Curve) es el área bajo esta. Lo usamos en Random Forest, LightGBM, SVM, ...
- **Coefficiente de Correlación de Matthews (MCC):** Es esencialmente un coeficiente de correlación entre las etiquetas reales y las predicciones. A diferencia de las métricas anteriores (que a veces solo se enfocan en la clase positiva), el MCC considera los cuatro cuadrantes de la matriz de confusión (VP, VN, FP, FN). Se considera una métrica equilibrada incluso con conjuntos de datos muy desbalanceados. Su valor oscila entre -1 y 1 siendo -1 una discrepancia total entre predicción y realidad y 1 una predicción perfecta. Su fórmula es: $\frac{VP \cdot VN - FP \cdot FN}{\sqrt{(VP+FP)(VP+FN)(VN+FP)(VN+FN)}}$. Lo usamos en Random Forest, LightGBM, SVM, ...

3.4. Modelos

3.4.1. Random Forest

Implementación de SHAP para la interpretabilidad del modelo Random Forest

Para complementar el análisis predictivo y dotar de interpretabilidad al modelo Random Forest, se implementaron explicaciones basadas en SHAP (SHapley Additive exPlanations). Esta sección describe la implementación práctica realizada sobre el modelo optimizado.

Funciones implementadas para explicabilidad

Se desarrollaron dos funciones principales para generar y visualizar explicaciones SHAP, tanto a nivel global como local.

Función de explicación SHAP La función `explica_shap` (Código 1) genera las explicaciones y visualizaciones:

Listing 1: Función para generar explicaciones SHAP

```
def explica_shap(modelo, X_train, X_test, n_show, local):
    # Creacion del explainer basado en el modelo
```

```

explainer = shap.Explainer(modelo.predict , X_train)

# Calculo de valores SHAP para el conjunto de prueba
shap_values = explainer(X_test)

# Visualizacion segun el tipo solicitado
if local:
    # Explicaciones locales: diagramas de cascada (waterfall)
    # para las primeras n_show instancias
    for j in range(n_show):
        shap.plots.waterfall(shap_values[j])
else:
    # Explicacion global: summary plot
    shap.summary_plot(shap_values , X_test)
    plt.show()

# Retorno de predicciones para evaluacion posterior
y_pred = modelo.predict(X_test)
y_pred_proba = modelo.predict_proba(X_test)[: , 1]
return y_pred , y_pred_proba

```

El funcionamiento de esta función es el siguiente:

1. Se crea un `shap.Explainer` utilizando el método de predicción del modelo y el conjunto de entrenamiento como referencia.
2. Se calculan los valores SHAP para todas las instancias del conjunto de prueba.
3. Dependiendo del parámetro `local`:
 - Si `local=True`: Se generan `n_show` diagramas de cascada (*waterfall plots*), cada uno mostrando la contribución de cada característica a la predicción de un audio específico.
 - Si `local=False`: Se genera un *summary plot* que agrega los valores SHAP de todas las instancias, mostrando la importancia global de cada característica y la dirección de su impacto.
4. La función retorna las predicciones (clases y probabilidades) para su posible evaluación posterior.

Función de validación mediante eliminación de características Para validar la importancia de las características identificadas por SHAP, se implementó la función `drop_features_explica_shap`, que permite realizar un experimento de ablación:

Listing 2: Función para evaluar impacto de eliminar características

```

def drop_features_explica_shap(modelo , model_name , X_train , y_train ,
                               X_test , y_test , feats , n_show ,

```

```

        evalua_modelo=False , local=True):
# Creacion de nuevos conjuntos sin las características especificadas
X_train_new = X_train.drop(feats , axis=1, inplace=False)
X_test_new = X_test.drop(feats , axis=1, inplace=False)

# Reentrenamiento del modelo con los mismos hiperparametros
params = modelo.get_params()

modelo = RandomForestClassifier(**params)
modelo.fit(X_train_new , y_train)

# Generacion de explicaciones para el nuevo modelo
y_pred , y_pred_proba = explica_shap(
    modelo=modelo ,
    X_train=X_train_new ,
    X_test=X_test_new ,
    n_show=n_show ,
    local=local
)

# Evaluacion opcional del rendimiento
if evalua_modelo:
    evaluacion_modelo(
        model_name=model_name ,
        y_true=y_test ,
        y_pred=y_pred ,
        y_pred_proba=y_pred_proba
    )

return modelo_new , X_train_new , X_test_new

```

Esta función permite:

1. Eliminar un conjunto de características especificadas (**feats**) de los conjuntos de entrenamiento y prueba.
2. Reentrenar un nuevo modelo Random Forest con los mismos hiperparámetros que el modelo original.
3. Generar nuevas explicaciones SHAP para el modelo reducido.
4. Evaluar opcionalmente el rendimiento del nuevo modelo utilizando la función `evaluacion_modelo`, la cual calcula una serie de métricas como f1-score, accuracy o roc-auc, entre otras.

Interpretación de las visualizaciones generadas

Las visualizaciones obtenidas se interpretan de la siguiente manera:




Figura 3: Explicación local con SHAP

- **Summary plot (global):** Muestra las características ordenadas por importancia. El color indica el valor de la característica (rojo = alto, azul = bajo) y la posición en el eje X indica el valor SHAP (impacto en la predicción). Características con puntos extendidos horizontalmente son más influyentes. Un ejemplo es:
- **Waterfall plot (local):** Para un audio específico, muestra:
 - $E[f(X)]$: Valor base (probabilidad media de la clase IA).
 - $f(x)$: Predicción final para este audio.
 - Barras rojas/azules: Características que empujan la predicción hacia IA (rojo) o hacia real (azul), con la magnitud de su contribución.

Un ejemplo de explicación local es:

Implementación de LIME para la interpretabilidad local del modelo

Como complemento a SHAP, se incorporó LIME (Local Interpretable Model-agnostic Explanations) para obtener explicaciones locales de las predicciones del modelo Random Forest. LIME genera explicaciones interpretables aproximando localmente el modelo complejo mediante un modelo simple (lineal) en la vecindad de la instancia a explicar.

Funciones implementadas para explicaciones LIME

Para integrar LIME en el flujo de trabajo, se implementó un procedimiento que permite generar explicaciones visualmente claras y personalizar su presentación para facilitar su inclusión en informes y memorias.

Configuración del explainer LIME El primer paso consiste en crear un explainer de LIME adaptado a datos tabulares:

Listing 3: Configuración del explainer LIME

```
from lime.lime_tabular import LimeTabularExplainer
import re
from IPython.display import HTML, display

# Creacion del explainer para datos tabulares
explainer = LimeTabularExplainer(
    X_train.values,           # Datos de entrenamiento en formato numpy
    feature_names=X.columns,  # Nombres de las características
    class_names=['label'],    # Nombres de las clases (0: Real, 1: IA)
    mode='classification'     # Modo de clasificacion
)
```

Los parámetros utilizados son:

- `X_train.values`: Matriz de características de entrenamiento en formato numpy array, necesaria para que LIME pueda muestrear la vecindad de las instancias.
- `feature_names`: Lista con los nombres de las características (formantes, MFCC, etc.) para etiquetar correctamente las explicaciones.
- `class_names`: Etiquetas descriptivas para las clases ('Real' y 'IA') en lugar de valores numéricos.
- `mode='classification'`: Indica que se trata de un problema de clasificación.

Generación de explicaciones para una instancia Para obtener la explicación de un audio específico, se utiliza el método `explain_instance`:

Listing 4: Generación de explicación para una instancia

```
# Seleccionamos la primera instancia del conjunto de prueba como ejemplo
instancia_a_explicar = X_test.values[0]

# Generamos la explicacion
exp = explainer.explain_instance(
    instancia_a_explicar,           # Instancia a explicar
    modelo_rf.predict_proba,        # Funcion de prediccion (probabilidades)
    num_features=10                 # Numero de características a mostrar
)
```


El método `explain_instance` recibe:

- La instancia concreta a explicar (en formato numpy array).
- La función de predicción del modelo (en este caso `predict_proba`), que LIME utiliza para muestrear la vecindad y entrenar el modelo local.
- `num_features`: Número de características más relevantes a incluir en la explicación (por defecto 10).

Personalización visual de las explicaciones LIME

LIME genera por defecto visualizaciones con estilos que pueden no integrarse adecuadamente en el formato de la memoria. Para solucionarlo, se implementó un proceso de limpieza y personalización del HTML generado:

Listing 5: Limpieza y personalización del HTML de LIME

```
# Obtenemos el HTML generado por LIME
exp_html = exp.as_html()

# Removemos las etiquetas <style> internas que pueden forzar estilos no deseados
exp_html_clean = re.sub(
    r'<style.*?>.*?</style>',
    '',
    exp_html,
    flags=re.DOTALL
)

# Envolvemos el HTML limpio en un contenedor con estilos personalizados
html_con_style = f"""
<style>
.lime-container * {{
    color: black !important;          # Texto en negro
    background-color: white !important; # Fondo blanco
    border-color: black !important;    # Bordes en negro
}}
</style>
<div class="lime-container">
    {exp_html_clean}
</div>
"""

# Mostramos el resultado
display(HTML(html_con_style))
```

Este proceso realiza las siguientes transformaciones:

1. **Extracción del HTML:** `exp.as_html()` genera una representación HTML completa de la explicación LIME, incluyendo estilos CSS embebidos.
2. **Limpieza de estilos:** Mediante una expresión regular (`re.sub`) se eliminan todas las etiquetas `<style>` internas que LIME incluye por defecto. Esto evita conflictos con los estilos de la memoria y permite un control total sobre la apariencia.
3. **Envoltura con estilos personalizados:** Se crea un contenedor `<div>` con clase `lime-container` y se definen estilos CSS que fuerzan:
 - Texto en color negro (`color: black !important`)
 - Fondo blanco (`background-color: white !important`)
 - Bordes en negro (`border-color: black !important`)El uso de `!important` garantiza que estos estilos prevalezcan sobre cualquier otro.
4. **Visualización:** Se utiliza `display(HTML(...))` de IPython para renderizar el HTML personalizado en el notebook.

Interpretación de las explicaciones LIME

La visualización generada por LIME muestra:

- **Predicción del modelo:** La probabilidad asignada a cada clase (Real/IA) para la instancia explicada.
- **Características más influyentes:** Lista de las `num_features` características con mayor impacto en la decisión, ordenadas por importancia.
- **Contribución de cada característica:** Barras horizontales que indican si la característica apoya la clase IA (color naranja/rojo) o la clase Real (color azul), junto con la magnitud de su contribución.
- **Valor de la característica:** Se muestra el valor concreto que tenía esa característica en el audio explicado.

Consideraciones sobre la implementación

Durante la implementación se tuvieron en cuenta los siguientes aspectos:

- **Formato de datos:** LIME requiere los datos en formato numpy array (`.values`) en lugar de DataFrame de pandas, por lo que se realiza la conversión explícita.
- **Función de predicción:** Se utiliza `predict_proba` en lugar de `predict` para obtener las probabilidades, lo que permite a LIME capturar la confianza del modelo y no solo la clase final.
- **Número de características:** Se limitó a 8-10 características por explicación para mantener la legibilidad, aunque el parámetro es configurable.

- **Personalización visual:** La limpieza de estilos CSS garantiza que las explicaciones LIME mantengan una apariencia profesional y consistente con el resto de la memoria, evitando problemas de contraste o colores no deseados.

Implementación de DiCE para la generación de explicaciones contrafactuales

Para complementar las explicaciones basadas en atribución (SHAP y LIME), se incorporó DiCE (Diverse Counterfactual Explanations) para generar explicaciones contrafactuales. DiCE responde a la pregunta: ¿qué cambios mínimos en las características de un audio clasificado como “a” lo harían ser clasificado como “b”, y viceversa?

Preparación de datos para DiCE

DiCE requiere los datos en un formato específico, combinando características y etiqueta en un mismo DataFrame:

Listing 6: Preparación de datos para DiCE

```
# Eliminacion de columnas no relevantes (ej. filename)
X_train_clean = X_train.drop(columns=['filename'], errors='ignore')
X_test_clean = X_test.drop(columns=['filename'], errors='ignore')

# Combinacion de características con la variable objetivo
data_dice = X_train_clean.copy()
data_dice['label'] = y_train # Variable objetivo (0: Real, 1: IA)
```

Los pasos realizados son:

- **Limpieza de características no predictivas:** Se elimina la columna `filename` (si existe) ya que contiene identificadores de archivo sin valor predictivo y no tendría sentido generar contrafactuales modificándola.
- **Integración de la variable objetivo:** DiCE necesita conocer la relación entre características y etiqueta, por lo que se añade la columna `label` al DataFrame de entrenamiento.

Configuración de DiCE

DiCE utiliza dos componentes principales: un `DataInterface` para manejar los datos y un `Model` para encapsular el clasificador:

Listing 7: Configuración de DiCE

```
import dice_ml

# Definicion del DataInterface
dice_data = dice_ml.Data(
    dataframe=data_dice, # DataFrame con features +
```

```

        continuous_features=X_train_clean.columns.tolist(), # Todas las features son
        outcome_name='label'                               # Nombre de la variable o
    )

# Encapsulacion del modelo
dice_model = dice_ml.Model(
    model=modelo_rf,          # Modelo Random Forest entrenado
    backend='sklearn'         # Backend para modelos scikit-learn
)

# Creacion del explicador DiCE
exp = dice_ml.Dice(
    dice_data,                # DataInterface
    dice_model,               # Model encapsulado
    method="random"           # Metodo de generacion ("random" o "genetic")
)

```

Los parámetros utilizados son:

- **dataframe**: DataFrame completo que contiene tanto las características como la variable objetivo para el entrenamiento.
- **continuous_features**: Lista de nombres de todas las características continuas. En este caso, todas las características de audio (formantes, MFCC, etc.) son continuas.
- **outcome_name**: Nombre de la columna que contiene la variable objetivo ('label').
- **backend='sklearn'**: Indica que el modelo es de scikit-learn, permitiendo a DiCE acceder a los métodos necesarios.
- **method="random"**: Método de generación de contrafactuales. random.^{es} más rápido; también existe "genetic" para búsquedas más exhaustivas.

Generación de contrafactuales para una instancia

Una vez configurado DiCE, se genera un conjunto de contrafactuales para una instancia específica:

Listing 8: Generación de contrafactuales

```

# Seleccion de la instancia a explicar (primera del conjunto de prueba)
query = X_test_clean.iloc[[0]] # Usamos iloc para mantener estructura DataFrame

# Generacion de contrafactuales
el = exp.generate_counterfactuals(
    query_instances=query,      # Instancia(s) a explicar
    total_CFs=3,               # Numero de contrafactuales a generar
)

```

```

        desired_class="opposite"      # Clase deseada (opuesta a la prediccion original)
    )

# Visualizacion de resultados
el.visualize_as_dataframe(show_only_changes=True)

```

Los parámetros de generación son:

- **query_instances:** DataFrame con una o más instancias para las que generar contrafactuales. Se utiliza `iloc[[0]]` para mantener la estructura de DataFrame (a diferencia de `iloc[0]` que devolvería una Serie).
- **total_CFs:** Número de contrafactuales a generar (en este caso 3), permitiendo explorar diferentes alternativas para cambiar la clasificación.
- **desired_class:** Clase objetivo para los contrafactuales. `."opposite"` indica la clase contraria a la predicción original. También se puede especificar directamente 0 (Real) o 1 (IA).
- **show_only_changes=True:** En la visualización, muestra únicamente las características que cambian respecto a la instancia original, facilitando la identificación rápida de las modificaciones necesarias.

Interpretación de los contrafactuales generados

La visualización generada por `visualize_as_dataframe(show_only_changes=True)` muestra:

- **Instancia original:** Valores de las características para el audio consultado y su clasificación original.
- **Contrafactuales:** Para cada uno de los `total_CFs` generados:
 - Valores de las características que cambian respecto al original (si `show_only_changes=True`).
 - La nueva clasificación resultante (clase deseada).
 - La magnitud del cambio necesario en cada característica.
- **Diversidad:** DiCE genera contrafactuales diversos, mostrando diferentes formas de lograr el mismo cambio de clasificación (por ejemplo, modificando diferentes combinaciones de formantes o MFCC).

La salida para la primera instancia es:

Interpretación en el contexto de detección de deepfakes

Las explicaciones contrafactuales permiten responder preguntas como:

- **Para un audio clasificado como IA:** "¿Qué características acústicas deberían cambiar para que el modelo lo considere voz real, y en qué magnitud?"

- **Para un audio clasificado como real:** "¿Qué modificaciones lo harían ser clasificado como generado por IA?"
- **Vías alternativas:** DiCE muestra múltiples formas de lograr el cambio, revelando si hay “camino” principales (modificar ciertos formantes) o alternativos (modificar MFCC específicos).

Consideraciones sobre la implementación

Durante la implementación se tuvieron en cuenta los siguientes aspectos:

- **Eliminación de columnas no relevantes:** Características como 'filename' se eliminan porque no tienen sentido en un contrafactual (no se puede modificar el nombre del archivo para cambiar la clasificación).
- **Selección de instancia:** Se utiliza `iloc[[index]]` en lugar de `iloc[index]` para mantener la estructura de DataFrame requerida por DiCE.
- **Método de generación:** Se eligió `method=random` por su eficiencia computacional, aunque para análisis más exhaustivos se puede utilizar `method=genetic`.
- **Visualización enfocada:** El parámetro `show_only_changes=True` facilita la interpretación al mostrar únicamente las características que realmente cambian, evitando abrumar con información redundante.
- **Clase deseada:** El valor `opposite` es útil cuando se quiere explorar el cambio de clase, pero también se puede especificar explícitamente `0` o `1` si se busca una dirección concreta.

3.4.2. LightGBM

Como hemos comentado antes, a diferencia de Random Forest, que construye árboles de forma independiente y paralela, LightGBM los construye secuencialmente, donde cada nuevo árbol se especializa en corregir los errores de los anteriores.

Justificación del modelo

Hemos usado LightGBM debido a que presenta ventajas significativas para la tarea de detección de deepfakes de audio, como pueden ser su eficiencia computacional para grandes volúmenes de datos o su regulación integrada con los parámetros L1 y L2.

Configuración experimental

El proceso experimental para LightGBM se estructuró en cuatro fases: (1) establecimiento de un modelo baseline, (2) validación cruzada para evaluar robustez, (3) optimización de hiperparámetros mediante búsqueda sistemática, y (4) evaluación comparativa con métricas exhaustivas.

Preparación de datos A diferencia de otros algoritmos, LightGBM puede manejar directamente datos sin normalización, aunque requiere que no existan valores nulos.

Modelo baseline con LightGBM Se estableció una configuración inicial utilizando la interfaz nativa de LightGBM, que ofrece un control más fino sobre el proceso de entrenamiento:

- **objective:** binary.
- **metric:** binary logloss.
- **boosting type:** gbd.
- **num leaves:** 31.
- **learning rate** η : 0,05.
- **feature fraction:** 0,9.
- **bagging fraction:** 0,8.
- **bagging freq:** 5.
- **random state:** 12.
- **is unbalanced:** True.

Tras ello entrenamos el modelo con los parámetros base, los datos de entrenamiento sin escalar, un set de validación, y los siguientes parámetros:

- **num boost round:**
- **callbacks:**

Listing 9: Configuración del modelo baseline LightGBM

```
# Entrenamiento con early stopping
model_baseline = lgb.train(
    params_baseline ,
    train_data ,
    valid_sets=[ test_data ],
    num_boost_round=1000,
    callbacks=[
        lgb.early_stopping(50),    # Detiene si no mejora en 50 rondas
        lgb.log_evaluation(100)   # Log cada 100 iteraciones
    ]
)
```

El parámetro `is_unbalance=True` activa la compensación automática para clases desbalanceadas, ajustando los pesos de forma inversamente proporcional a la frecuencia de cada clase.

Early stopping Una ventaja importante de LightGBM es la capacidad de detener el entrenamiento cuando añadir más árboles no mejora el rendimiento en validación. Esto:

- Previene el sobreajuste (overfitting)
- Ahorra tiempo computacional
- Determina automáticamente el número óptimo de iteraciones

Validación cruzada

Para LightGBM se utilizó la interfaz compatible con scikit-learn (LGBMClassifier) que permite integrarse con las herramientas de validación cruzada estándar:

Listing 10: Validación cruzada con LightGBM

```
from sklearn.model_selection import StratifiedKFold , cross_val_score

# Usamos la interfaz scikit-learn de LightGBM
lgb_sklearn = lgb.LGBMClassifier(
    objective='binary',
    boosting_type='gbdt',
    num_leaves=31,
    learning_rate=0.05,
    random_state=12,
    is_unbalance=True,
    n_jobs=-1
)

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=12)

cv_scores_accuracy = cross_val_score(lgb_sklearn, X_train, y_train,
                                     cv=cv, scoring='accuracy')
cv_scores_f1 = cross_val_score(lgb_sklearn, X_train, y_train,
                               cv=cv, scoring='f1')
cv_scores_auc = cross_val_score(lgb_sklearn, X_train, y_train,
                                cv=cv, scoring='roc_auc')
```

La validación cruzada proporciona una estimación más robusta del rendimiento, reportándose la media y la desviación estándar de las métricas.

Optimización de hiperparámetros

LightGBM cuenta con un conjunto de hiperparámetros específicos, diferentes a los de Random Forest. La búsqueda se centró en aquellos que más influyen en el rendimiento:

- **num_leaves**: Controla la complejidad del modelo. Valores altos permiten capturar patrones más complejos pero aumentan el riesgo de sobreajuste.
- **learning_rate**: Tasa de aprendizaje (eta). Valores pequeños requieren más iteraciones pero pueden lograr mejor convergencia.
- **n_estimators**: Número de iteraciones de boosting.

- **min_child_samples**: Mínimo de muestras requeridas en una hoja. Controla la profundidad y evita hojas con pocas muestras.
- **subsample** y **colsample_bytree**: Fracciones de muestras y características para cada árbol, introduciendo aleatoriedad.
- **reg_alpha** y **reg_lambda**: Regularización L1 y L2 para controlar la complejidad.
- **num leaves**: Probamos 15, 31 y 63.
- **learning rate**: Probamos 0,01, 0,05 y 0,1.
- **n estimators**: Probamos 100, 200 y 300.
- **min child samples**: Probamos 20, 50 y 100.
- **subsample**: Probamos 0,6, 0,8 y 1.
- **colsample bytree**: Probamos 0,6, 0,8 y 1.
- **reg alpha**: Probamos 0, 0,1 y 0,5.
- **reg lambda**: Probamos 0, 0,1 y 0,5.

Listing 11: Grid Search para LightGBM

```
param_grid = {
    'num_leaves': [15, 31, 63],           # Complejidad del modelo
    'learning_rate': [0.01, 0.05, 0.1],   # Tasa de aprendizaje
    'n_estimators': [100, 200, 300],       # Numero de iteraciones
    'min_child_samples': [20, 50, 100],    # Minimo muestras por hoja
    'subsample': [0.6, 0.8, 1.0],         # Fraccion de muestras
    'colsample_bytree': [0.6, 0.8, 1.0],   # Fraccion de caracteristicas
    'reg_alpha': [0, 0.1, 0.5],           # Regularizacion L1
    'reg_lambda': [0, 0.1, 0.5]           # Regularizacion L2
}

grid_search = GridSearchCV(
    lgb.LGBMClassifier(objective='binary', random_state=42,
                        is_unbalance=True, n_jobs=-1),
    param_grid,
    cv=cv,
    scoring='f1',
    n_jobs=-1,
    verbose=1
)

grid_search.fit(X_train, y_train)
lgb_optimized = grid_search.best_estimator_
```

3.4.3. Support Vector Machine (SVM)

Como ya hemos visto sobre los SVM, estos se fundamentan en la búsqueda del hiperplano óptimo que maximiza el margen de separación entre clases, lo que proporciona una base teórica sólida y garantías de generalización.

Justificación del modelo

Usamos SVM ya que presenta características especialmente relevantes para la detección de deepfakes de audio que hemos comentado antes, como la eficacia en espacios de alta dimensión (como puede ser el mundo del lenguaje natural) o su fundamento teórico robusto.

Importancia de la normalización

Una característica crítica de SVM es su sensibilidad a la escala de las características. Las variables de audio presentan escalas muy diferentes:

- **Formantes:** Del orden de cientos de Hz (ej. 300-3000 Hz)
- **MFCC:** Valores típicamente en el rango $[-200, 200]$
- **ZCR (Zero Crossing Rate):** Valores normalizados entre 0 y 1
- **HNR (Harmonics-to-Noise Ratio):** Valores en decibelios (dB)

Sin normalización, las características con mayor magnitud dominarían el cálculo de distancias, sesgando el modelo. Por ello, se aplicó `StandardScaler` para estandarizar las características a media cero y desviación típica uno:

Listing 12: Normalización de características para SVM

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Es crucial aplicar el escalado *después* de la división train/test para evitar *data leakage* (fuga de información del conjunto de prueba al entrenamiento).

Configuración experimental

El proceso experimental para SVM se estructuró en cuatro fases: (1) modelo baseline con kernel lineal, (2) modelo con kernel RBF, (3) validación cruzada, y (4) optimización de hiperparámetros mediante Grid Search.

Modelo baseline: SVM lineal Se estableció un primer modelo con kernel lineal como referencia simple:

- **kernel (“linear”)**: La función matemática que transforma los datos para encontrar el hiperplano óptimo.
- **C**: Parámetro de regularización.
- **probability**: Habilita el cálculo de probabilidades en lugar de solo clases.
- **random_state**: Fija el estado aleatorio para reproducibilidad.
- **class_weight**: Ajuste de pesos para clases desbalanceadas inversamente proporcionales a la frecuencia de cada clase.

Modelo no lineal: SVM con kernel RBF Dada la naturaleza compleja de las señales de audio, se implementó un modelo con kernel RBF para capturar relaciones no lineales:

- **kernel (“rbf”)**: La función matemática que transforma los datos para encontrar el hiperplano óptimo.
- **gamma**: Parámetro que controla la influencia de cada punto de entrenamiento en la frontera de decisión.

El parámetro `gamma='scale'` establece automáticamente $\gamma = 1/(n_{\text{características}} \cdot \text{Var}(X))$, un valor inicial razonable.

Validación cruzada

Para garantizar la robustez de las evaluaciones y evitar dependencias de una única partición, se implementó validación cruzada estratificada con 5 folds. Se utilizó un pipeline que integra el escalado y el clasificador para asegurar que la normalización se realice correctamente en cada fold:

Listing 13: Pipeline con validación cruzada para SVM

```
from sklearn.pipeline import Pipeline
from sklearn.model_selection import StratifiedKFold, cross_val_score

# Pipeline que integra escalado + SVM
svm_pipeline = Pipeline([
    ('scaler', StandardScaler()),
    ('svm', SVC(kernel='rbf', probability=True,
                random_state=42, class_weight='balanced'))
])

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=12)

cv_scores_accuracy = cross_val_score(svm_pipeline, X_train, y_train,
                                     cv=cv, scoring='accuracy')
cv_scores_f1 = cross_val_score(svm_pipeline, X_train, y_train,
                               cv=cv, scoring='f1')
cv_scores_auc = cross_val_score(svm_pipeline, X_train, y_train,
```

```
cv=cv , scoring='roc_auc')
```

El uso de pipeline es especialmente importante en SVM porque garantiza que la normalización se ajuste únicamente con los datos de entrenamiento de cada fold, evitando contaminación con datos de validación.

Optimización de hiperparámetros

SVM con kernel RBF tiene dos hiperparámetros críticos que determinan su rendimiento (ya explicados previamente):

- **C (parámetro de regularización).**
- γ (**gamma**).

La búsqueda sistemática se realizó mediante Grid Search con validación cruzada:

- **C:** Probamos 0,1, 1, 10 y 100.
- **gamma:** Probamos 0,001, 0,01, 0,1, 1, “scale” y “auto”.
- **kernel:** Probamos únicamente el kernel no lineal “rbf”.

Tras esto instanciamos el GridSearchCV (búsqueda de parámetros (search) probando todas las combinaciones (grid) con validación cruzada (CV)) poniendo un modelo base de Random Forest con el estado aleatorio 12 y el peso de clases balanceado, como antes. A dicho grid search le ponemos el grid de parámetros que comentamos arriba, la validación cruzada de 5-folds que hicimos antes, y la métrica a optimizar de f1. Por último entrenamos el modelo con los datos de entrenamiento sin escalar.

La elección de optimizar el F1-score responde a la necesidad de balancear precisión y sensibilidad en un problema donde ambos tipos de error (falsos positivos y falsos negativos) son relevantes.

Análisis de vectores de soporte

Una característica única de SVM es la identificación de los **vectores de soporte**: las muestras críticas que determinan la frontera de decisión. Su análisis proporciona información sobre la complejidad del problema:

Listing 14: Análisis de vectores de soporte

```
# Obtenemos el modelo del pipeline
svm_model = svm_optimized.named_steps['svm']
n_support_vectors = svm_model.n_support_
support_vectors_count = sum(n_support_vectors)

print(f"Total de vectores de soporte: {support_vectors_count}")
print(f"Porcentaje del dataset: {support_vectors_count/len(X_train)*100:.2f}%")
print(f"Vectores clase Real(0): {n_support_vectors[0]}")
print(f"Vectores clase IA(1): {n_support_vectors[1]}")
```

La interpretación de estos valores es reveladora:

- Un bajo porcentaje de vectores de soporte ($< 30\%$) indica que la frontera de decisión es relativamente simple y está bien definida por pocos ejemplos.
- Si una clase tiene significativamente más vectores de soporte, su región de decisión es más compleja o presenta mayor solapamiento.
- Los vectores de soporte son candidatos naturales para un análisis cualitativo: ¿qué tienen en común los audios más difíciles de clasificar?

Métricas de evaluación

Se emplearon las mismas métricas que en Random Forest y LightGBM:

- **Accuracy:** Proporción de predicciones correctas.
- **Precision:** Proporción de predicciones positivas correctas.
- **Recall:** Proporción de positivos reales correctamente identificados.
- **F1-Score:** Media armónica de precisión y recall.
- **AUC-ROC:** Área bajo la curva ROC.
- **MCC:** Coeficiente de correlación de Matthews.

La función de evaluación implementada es la misma que para los modelos anteriores.

3.4.4. AASIST

AASIST (*Audio Anti-Spoofing using Integrated Spectro-Temporal Graph Attention Networks*) es un modelo creado con la motivación de combinar pistas espectrales y temporales para detectar artefactos de spoofing y conseguir robustez frente a una gran variedad de ataques. Como este modelo produce una predicción a partir del audio crudo, el primer paso es definir las rutas a los audios.

Después, se lee el contenido del **archivo .conf** del modelo. Para ello, hemos creado una función que busca el elemento pasado por parámetro y devuelve el bloque superior que contiene ese elemento junto con los elementos al mismo nivel. Esto nos permite construir una variable, que vamos a llamar `args`, con los siguientes campos:

- **first_conv:** configuración del **kernel** de la primera capa de convolución, es decir, cuántas muestras de audio se utilizan para cada filtro. En este caso, 128.
- **filts:** es un array de elementos siendo el primero el número de **filtros** en la primera capa de convolución. Los siguientes elementos son pares para cada bloque residual con el número de filtros de entrada y de salida.
- **gat_dims:** tamaño del **embedding** que representa cada nodo. Tiene dos valores que hacen referencia al tamaño al construir los grafos de atención y al tamaño en las fases de “HS-GAL” + “pooling” respectivamente.

- **pool_ratios**: se usa en la técnica de “graph pooling” y significa el **ratio de reducción de nodos** en cada capa. Los dos primeros valores se usan para reducir los grafos espectral y temporal respectivamente antes de combinarlos en el grafo heterogéneo. El siguiente valor se usa para reducir el grafo heterogéneo después de cada capa HS-GAL. Aunque existe un cuarto valor, en el modelo final no se usa.
- **temperatures**: controla lo suave o agresiva que es la **atención** en cada fase. Cuanto más bajo es este parámetro, mayor peso se concentra en pocos nodos vecinos.

Con args ya creado, la usamos para instanciar el modelo. Posteriormente, se usa el checkpoint para cargar los pesos preentrenados.

El siguiente paso es definir las funciones de inferencia. Para esto, nos apoyamos primero en dos funciones auxiliares, una que convierte los audios a un **formato estándar**, un solo canal y 16 kHz, y otra que crea una **ventana** para recorrer audios largos. Esta última es importante ya que AASIST está diseñado para recibir segmentos de longitud de unos 4 segundos. Con esto preparado, las tres funciones de inferencia las creamos para ver si conseguimos mejores resultados alterando un poco el proceso y se describen a continuación:

- **average_windows**: esta función devuelve la media de sumar las predicciones de cada ventana calculadas de forma independiente.
- **score_without_windows**: esta función devuelve solamente la puntuación del segmento inicial del audio en archivos largos o del audio en su totalidad en el caso contrario.
- **average_logits**: esta función fusiona todas las ventana sumando sus logits antes de calcular una única probabilidad.

Finalmente, se aplica el modelo y se vuelcan los resultados en un csv con el nombre del audio, la probabilidad de que sea “bonafide” y su duración. Para esto, se recorre cada audio del dataset, se le aplica una de las funciones de inferencia y se escribe la información en el csv.

Resultados y análisis Como hemos mencionado anteriormente, implementamos tres funciones de inferencia distintas para intentar obtener mejores resultados. Tras varias pruebas, alternando las tres funciones, obtuvimos resultados pésimos en los que el modelo tendía a clasificar cada muestra como “bona fide” y alguna como “spoof” pero sin mucho acierto lo que da una sensación de clasificación al azar. Ante estos resultados, decidimos realizar “**fine-tuning**” sobre el propio modelo preentrenado, nuestro propio preentrenamiento con parte del dataset que creamos. Para conseguir esto, primero separamos el dataset en train, eval y dev y generamos los archivos de “protocols” de donde el modelo va leyendo el nombre y el tipo de los audios de cada partición. Adicionalmente, tuvimos que hacer ciertos ajustes en el .conf y en especial, ajustar el número de épocas.

Para las pruebas, las hemos separado en tres tipos: audios en inglés por separado, español por separado y ambos idiomas juntos. Dentro de cada escenario, hay cuatro pruebas con distinto número de **épocas: 10, 20, 40 o 80**. También, cabe mencionar que siempre se ha mantenido una proporción en la separación en train, dev y eval de 72 %, 14 % y 14 %, respectivamente. Por último, antes de analizar los resultados, es importante explicar que en la separación manual del dataset hemos separado los distintos speakers que había en cada idioma. Esto se refiere a que en el dataset hay por idioma, 5 speakers distintos con 10 audios “bonafide” y 10 “spoof”, entonces, hemos intentado que en las tres particiones haya audios de las 5 personas y así intentar evitar sesgos.

A la hora de evaluar, hemos usado 4 medidas:

Accuracy: proporción de las muestras clasificadas correctamente sobre el total de muestras.

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

Precision: proporción de las muestras spoof detectadas sobre el total de muestras clasificadas como spoof.

$$\text{Precision} = \frac{TP}{TP+FP}$$

Recall: proporción de muestras spoof detectadas correctamente sobre el total de muestras spoof.

$$\text{Recall} = \frac{TP}{TP+FN}$$

F1: media armónica entre precision y recall.

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$




Figura 4: Resultados del preentrenamiento en AASIST.

Lo primero que podemos destacar sobre las gráficas, es que el modelo clasifica claramente mejor los audios en español ya que todas las métricas, a excepción de precisión en 40 épocas, tienen valores superiores. Esta diferencia explica el porqué la partición mixta lo hace peor que la que solo tiene muestras en inglés y permite deducir que ejecutar ambos idiomas juntos no le ayuda a clasificarlos mejor.

En lo referido a las épocas, lo más destacable es que superar las 40 épocas empeora la predicción por lo que podemos suponer que está ocurriendo un fenómeno de sobre-aprendizaje. También, podemos observar que en la partición en inglés, el aumento del valor de este parámetro no equivale en términos generales a una subida en la mejora de la predicción, fenómeno que no ocurre con la partición en español.

Explicabilidad Hemos usado las propias estructuras del modelo para empezar a explicar qué es lo que le empuja a decidir una clase a la otra. Esto nos sirve además para enseñar mejor cómo funciona AASIST por dentro. Lo primero que mostramos es el formato de la salida que es una tupla con dos valores, la probabilidad de que el audio sea “spoof” y de que sea “bona fide”, y la estructura de los grafos que nos permite ver que se crean 23 nodos espectrales y 29 temporales. También, simulamos como funciona un “pooling” mostrando los nodos de cada tipo con mayor puntuación.

Después, ejemplificamos cuales son los valores que se pasan a la capa de salida y cuánto afectan al cálculo de cada uno de los valores de la salida. Estos valores son los resultados de las operaciones “max” y “average” de cada subgrafo y el resultado del stack node. Con estas muestras podemos empezar a ver que ha sido mas significativo a la hora de responder si un audio es “spoof” o no.

Como vemos en este ejemplo, en las primeras décimas de segundo ocurre un evento completamente determinante para el predictor. Destacamos los instantes con valor negativo que indican que si “quitamos” ese trozo la probabilidad crece.

En relación a filtros de frecuencia, primero calculamos la banda de frecuencias aproximada de cada uno de los 70 filtros con una transformada rápida de fourier y las graficamos






Figura 5: Gráfica bandas de frecuencia de los filtros.

Con esta gráfica, podemos afirmar que se captan todas las frecuencias de 0 a 8000 Hz y que en las frecuencias bajas hay más solapamiento entre filtros. Esto es importante ya que cuando extraemos cuales son los filtros que más se activan durante el procesado del audio, no es raro que salgan algunos consecutivos ya que si dos filtros están observando una frecuencia muy activa, ambos responderán parecido.

Posteriormente, graficamos los filtros que más activación han tenido en el primer procesado de dos formas: en la imagen de la izquierda viendo que frecuencias cubren y en la imagen de la derecha viendo su activación a lo largo del audio.



(a) Bandas de frecuencia de los filtros más activados.



(b) Activación de los filtros más activados a lo largo del audio.

Como hemos mencionado anteriormente, los 5 filtros más excitados se pueden separar en dos grupos por su consecución. Además, en la gráfica de la derecha se ve claramente como tienen comportamientos muy parecidos. Comparando estas últimas imágenes, con la figura X podemos ver que donde en esta última parece que había mucha relevancia, aquí no se ve reflejado. Esto se explica en que los filtros son solo la activación temprana del frontal sinc-conv y la información captada tiene que pasar por varios procesos. Sin embargo, la observación de los filtros empieza a ofrecernos información relevante para la clasificación.

A continuación, vamos a aplicar “**occlusion**” tanto al ámbito espectral como al temporal focalizando, además, tanto logit de la clase clasificada como el margen entre los logits de ambas clase. Esta técnica consiste en ir “tapando” fragmentos de la entrada y ver como cambia el logit final con estas variaciones para ver que tramos han afectado más. Para tapar, en el ámbito temporal hemos puesto silencio en el tramo objetivo y en el ámbito espectral, hemos puesto silencio en la banda de frecuencia objetivo.

A la hora de llevar esta idea a código, hemos creado dos funciones separadas de cada dominio por su idea es la misma: sacan los logits iniciales, con un bucle vamos tapando segmentos y sacando nuevos logits que nos permiten ver como ha variado el resultado al obviar ese segmento. Ambas funciones tienen un parámetro que permite decidir que clase observar y en caso de no especificar, se mira la clase con la se clasifico el audio. La única diferencia entre estas funciones, es que la del plano espectral necesitas hacer uso de una FFT para poder cambiar entre ámbitos y así seleccionar correctamente que banda de frecuencia silenciar. Las caídas en la probabilidad las graficamos y nos permite ver qué instantes del audio son más relevantes para el modelo. Hemos usado instantes de 10 ms ya que hemos concluido que es un punto donde ya podemos ver cambios finos sin

que picos en tramos pequeños se compensen y salga aportación nula. Aunque todavía no sabemos qué fenómenos son los determinantes si nos permite saber en qué momento ocurren.






Figura 7: Resultados de la ocultación temporal en AASIST.

Siguiendo en relación con las frecuencias, simulamos como sería la salida de la capa sinc-convolution que podemos asemejar a un espectrograma. Para conseguir este mapa filtro-tiempo capturamos la salida de la capa durante la inferencia y la representamos en un “heatmap” en cuyo eje Y se colocan los filtros de menor a mayor banda de frecuencia.

Hemos creado dos mapas filtro-tiempo, el de la izquierda sería el más fiel al modelo y el de la derecha normaliza la activación de cada filtro por su máximo. Esta combinación nos permite determinar qué regiones de frecuencias se excitan más pero sin ocultar completamente a las menos determinantes.



(a) Mapa filtro-tiempo de la capa sinc-convolution.



(b) Mapa filtro-tiempo normalizado.

Con estos mapas, volvemos a observar que los filtros más activados son los de baja frecuencia, predominantemente en los primeros segundos del audio. Además, volvemos a ver una región “vacía” en torno a los 3,5 segundos que equivale a un silencio en el audio.

La siguiente técnica que vamos a aplicar es Integrated Gradients, primero sobre los mapas filtro-tiempo que acabamos de ver. Con este objetivo, usamos la clase `LayerIntegratedGradients` porque analizamos solo una capa concreta del modelo y nos devuelve la salida en el mismo formato que la entrada, lo que nos permite representarla de la misma manera. Cabe mencionar que como baseline utilizamos un vector silencio ya que la entrada es un audio.

A diferencia de los mapas filtro-tiempo anteriores, aquí representamos las zonas que más contribuyen al logit final. Sin embargo, igual que antes, representamos una gráfica normalizada para apreciar más detalle y una sin normalizar para ver el mapa puro.

Como podemos ver en las imágenes en este caso, los filtros que más se activarían son los de baja frecuencias.

Para mostrar esto de manera más visual, generamos una gráfica parecida a las de occlusion pero con los filtros en el eje x.

Para mostrar estos mapas de manera temporal, resumimos todos los filtros en cada instante y hacemos una curva temporal viendo que instantes han sido más relevantes.

Siguiendo con IG, ahora lo aplicamos sobre el audio crudo, usando, a diferencia de con los mapas, la clase `IntegratedGradients`. Como resultado, obtenemos una gráfica de importancia temporal indicando lo importante que es cada instante según está técnica.

Como última técnica aplicamos RISE, y obtenemos los resultados en forma de gráfica temporal.

4. Trabajo Individual

4.0.1. Iván Pastor Sacristán

1. Investigación del estado del arte: Investigué sobre el estado actual de la detección de deepfakes. Durante la investigación leí dos papers. En el primero hablaban sobre adaptación de los modelos a nuevos conjuntos de datos distintos de los que se usaron para entrenarlo y probarlo. En el segundo paper se centraban en un modelo capaz de clasificar correctamente los audios, aún y cuando los generados por IA habían sido modificados tanto en el dominio de la frecuencia como en el del tiempo para añadirles defectos característicos de los audios humanos como el ruido.
2. Prueba del dataset WaveFake: Hice una primera versión del extractor de características entre las que se incluyen rms, zcr, pitch, mfcc's, duración, transcripción, espectral centroid, espectral rolloff y el espectral bandwidth.
3. Prueba del dataset ASVSpooof2021: Usé el mismo extractor de características e hice un clasificador difuso en el que, basándome en las características extraídas, clasifique los audios por género y edad aparente.
4. Modelo compuesto: El modelo se basa en hacer un embedding de las características con un perceptrón multicapa (MLP), hacer un embedding del espectrograma

del audio con una red neuronal convolucional (CNN), concatenarlos, y luego usar esos embeddings como entrada de un MLP + clasificador difuso que es lo que se encargará realmente de la tarea de clasificación.

5. Fine-tuning Wav2Vec2: Usé el modelo desarrollado por Meta Wav2Vec2 y le hice un fine-tuning con nuestro dataset para que se enfocara en la clasificación de audios. Luego procesé la salida del modelo para pasar de la tupla que me devuelve el modelo a un valor entre 0 y 1 que indique la confianza de que un audio sea generado.
6. XAI sobre Wav2Vec2: Sobre el modelo Wav2Vec2, no se puede aplicar directamente IA explicable ya que la entrada son embeddings, para ello lo que he hecho ha sido dividir entre las características y el espectrograma de Mel. Para las características usa Shap y Lime sobre surrogate models que imitan la salida de Wav2Vec2 y para los espectrogramas de Mel use una CNN a la que le apliqué Shap, Lime, Integrated gradients y Grad Cam.

4.0.2. Jorge Aured Zarzoso

- Investigué sobre las motivaciones para investigar sobre la detección de voz generada por IA con dos papers. En estos se hablaba de cómo las personas hemos perdido la capacidad de detectar correctamente cuando un audio es real o no.
- Investigué sobre qué características son relevantes en la voz y cómo extraerlas mediante código. Esto ya que es crucial saber qué representa cada característica para tener una noción de qué puede tener en cuenta los modelos a la hora de predecir si un audio es real o no.
- Investigué parcialmente sobre la extracción de gráficas de la voz, para su uso en redes convolucionales (CNN).
- paper deepShap
- paper peru
- Investigué sobre el estado del arte de los modelos LightGBM, Random Forest y SVM para clasificación. En dicha investigación profundicé en el funcionamiento de los modelos, viendo qué hiperparámetros tiene cada uno y para qué sirven, y qué ventajas tienen para la clasificación de audios en reales o generados.
- Investigué sobre datasets que nos pudieran servir para la clasificación. Encontré audioMNIST y HABLA, el primero de los números del 0 al 9 y el segundo son voces en español de hispanoamérica. audioMNIST solo cuenta con voces reales, mientras que HABLA tiene tanto clonaciones de voz como ataques (hacer que una voz se parezca a otra).
- He hecho un pipeline completo para cada uno de los tres modelos, entrenándolos de varias formas para ver cuál funcionaba mejor. Este pipeline consta de un modelo baseline, una fase de cross validation y un grid search optimizando los

parámetros. En cada paso visualicé los resultados de los modelos viendo su rendimiento. Al final del pipeline guardé como archivo .pkl los mejores modelos

- He aplicado técnicas de Inteligencia Artificial explicable (XAI) a mi modelo óptimo de Random Forest, aunque las pruebas son extrapolables a los demás modelos. Dichas técnicas muestran cómo el modelo hace las predicciones. Las he hecho globales y locales. He aplicado SHAP (local y global), LIME (local) y DiCE (local, contrafactual).