

TFG - XplicaVoz

Jorge Aured Zarzoso, Germán Bravo Quintián,
Rafael López Rodríguez, Iván Pastor Sacristán

9 de marzo de 2026

Índice

1. Introducción	2
2. Estado del arte	2
2.1. Modelos de clasificación	2
2.1.1. Perceptrón multicapa - MLP	2
2.1.2. Wav2Vec2	3
2.1.3. Random Forest	4
2.1.4. LightGBM	5
2.1.5. Support Vector Machines (SVM)	6
2.1.6. AASIST	9
2.2. Modelos de explicación	11
2.2.1. SHAP	11
2.2.2. LIME	11
2.2.3. Grad-CAM	11
2.2.4. Integrated Gradients	11
2.2.5. DICE	12
2.2.6. SincNet	12
2.2.7. ProtoPNet	12
3. Metodología	12
3.1. Dataset	12
3.2. Extracción de características	13
3.3. Preprocesamiento	17
3.4. Modelos de clasificación	17
3.4.1. Perceptrón multicapa	17
3.4.2. Fine-tuning Wav2Vec2	17
3.4.3. Random Forest	18
3.4.4. LightGBM	18
3.4.5. Support Vector Machine (SVM)	21
3.4.6. AASIST	25
3.5. Modelos de explicación	26

1. Introducción

En los últimos años, hemos visto un aumento considerable en el uso de la IA para suplantar la identidad de alguien de forma maliciosa clonando su voz. Estos son los conocidos *deepfakes*. El reconocimiento de dichos *deepfakes* es de vital importancia, pues suponen una gran amenaza. Por otro lado, las técnicas de detección de *deepfakes* no han avanzado al mismo ritmo, y esto lo vemos en la gran cantidad de estafas que se producen de este tipo.

Además, las personas ya no somos capaces de diferenciar entre una voz real y una generada, como se ve en [? ?], donde hacen sendos estudios exponiendo a personas reales a diversos audios, algunos reales, algunos generados y algunos que clonan voces reales. En dichos estudios, se ve que los que son 100 % generados nos cuesta poco detectarlos, pero entre los reales y los clones no diferenciamos bien, y rondamos el 60 % de precisión clasificando dichas voces en reales o falsas. Por esto, no podemos fiarnos más de nuestras capacidades a la hora de diferenciar cuando una voz es real o no.

En este texto, se proponen varias técnicas que podrían ser útiles para la detección de audios generados por IA. Para esta tarea es fundamental sacar las características de la voz, así como gráficas, para poder entrenar los modelos con dichos datos. Entre los audios debe haber tanto reales como generados, y estar medianamente equilibrados, para que los modelos aprendan las diferencias, y así sepan clasificar un audio que nunca han visto.

Pero el rendimiento del modelo de clasificación no es lo único que nos interesa. Hoy en día, los modelos de IA se han convertido en *cajas negras*, donde no sabemos cómo hace las predicciones, dando lugar a problemas de confianza de los humanos respecto de dichas predicciones, como es en el ámbito médico o ingenieril, donde las decisiones que tomen las IAs deben ser precisas, puesto que la vida de las personas puede estar en juego. Para solventar este problema, ha surgido la IA explicable (XAI), la cual toma dichos modelos *caja negra* y da una explicación de qué características de los datos afectan más a la decisión del modelo. En esta investigación, vamos a aplicar XAI para ver qué afecta más a la clasificación de los audios dentro de los distintos grupos que mencionamos antes.

2. Estado del arte

2.1. Modelos de clasificación

2.1.1. Perceptrón multicapa - MLP

Un perceptrón multicapa es una red neuronal que se utiliza en aprendizaje supervisado en el campo del aprendizaje automático. El MLP está compuesto por múltiples capas de neuronas interconectadas, en las que las salidas de las neuronas de una capa se convierten en entradas para la siguiente capa. La primera capa se llama capa de entrada, la última capa se llama capa de salida y las capas intermedias se llaman capas

ocultas. El MLP presenta una gran capacidad para modelar relaciones no lineales y para generalizar. Como punto negativo del uso de este modelo, podemos remarcar la necesidad de un gran conjunto de datos de entrenamiento para evitar el sobreajuste. Por último, cabe resaltar que los MLP's fueron los precursores de otras redes neuronales más complejas como la redes convolucionales y las redes recurrentes. (Fuente: <https://gamco.es/glosario/perceptron-multicapa-mlp/>)

2.1.2. Wav2Vec2

Wav2Vec2 es un modelo de aprendizaje profundo end-to-end para procesamiento de voz que permite obtener representaciones acústicas de alta calidad directamente desde la señal cruda de audio, sin necesidad de características manuales. Fue propuesto por Meta en 2020.

Como parte del entrenamiento, el modelo aprende unidades de habla discreta mediante un gumbel softmax (técnica utilizada en redes neuronales para aproximar el muestreo de distribuciones categóricas discretas de forma diferenciable) para representar las representaciones latentes en la tarea contrastiva.

Tras el preentrenamiento en el habla no etiquetada, el modelo se ajusta con datos etiquetados con una pérdida de Clasificación Temporal Conexiónista (CTC: algoritmo y función de pérdida utilizado en redes neuronales profundas para entrenar modelos de aprendizaje automático en tareas de modelado de secuencias cuando los datos de entrada y salida no están alineados) para ser utilizada en tareas posteriores de reconocimiento de voz.

El modelo se compone de un codificador de características convolucional multicapa que toma la entrada cruda de audio y devuelve representaciones latentes de voz para T instantes de tiempo. Luego son pasados a un transformer para construir representaciones capturando información de toda la secuencia.

El codificador de características consiste en muchos bloques convolucionales seguidos de una capa de normalización y una función de activación GELU (Gaussian Error Linear Unit: pondera las entradas por su probabilidad bajo una distribución gaussiana suavizando su activación cerca de 0).

También realiza representaciones contextualizadas con Transformers siendo que la salida del codificador se pasa a una red que sigue la arquitectura de un Transformer, y usa una capa convolucional que actúa como un embedding posicional relativo.

Por último, Wav2Vec2 consta de un módulo de cuantización que discretiza la salida del codificador a un conjunto finito de representaciones del habla. Esta cuantización se hace con la técnica de Gumbel Softmax (Gumbel Softmax: técnica de reparameterización que aproxima muestras de una distribución categórica discreta mediante una función continua y diferenciable).

El entrenamiento del modelo se basa en un preentrenamiento con enmascaramiento en donde se toma la señal de audio y se transforma en representaciones latentes mediante un encoder. Esto se hace por bloques consecutivos de tamaño M que pueden solaparse.

Para cada paso de tiempo enmascarado, el modelo debe identificar la representación latente cuantizada correcta. Para ello, usa una pérdida contrastiva basada en la similitud del coseno.

También se realiza un fine-tuning supervisado para reconocimiento automático del habla usando CTC como función de pérdida y aplicando una versión de SpecAugment (técnica de aumento de datos diseñada específicamente para el reconocimiento automático de voz) para evitar sobreajuste.

Fuente(<https://arxiv.org/pdf/2006.11477>)

2.1.3. Random Forest

Random Forest es un algoritmo de aprendizaje automático basado en la combinación de múltiples árboles de decisión, propuesto por Leo Breiman en 2001 [?]. Pertenece a la familia de métodos *ensemble*, que mejoran el rendimiento agregando las predicciones de varios modelos más simples.

Arquitectura y funcionamiento

El algoritmo construye un “bosque” de árboles de decisión donde cada árbol se entrena de forma ligeramente diferente, introduciendo aleatoriedad controlada en dos niveles:

- **Bootstrap aggregating (bagging):** Cada árbol se entrena con una muestra aleatoria del conjunto de datos original, permitiendo repeticiones. Esto significa que algunos ejemplos aparecen varias veces en el entrenamiento de un árbol, mientras que otros (alrededor de un tercio) quedan fuera (*out-of-bag*) y sirven para validación interna.
- **Selección aleatoria de características:** En cada división de un nodo del árbol, solo se considera un subconjunto aleatorio de todas las características disponibles. Esto evita que unas pocas características muy fuertes dominen todas las decisiones.

Proceso de clasificación

Cuando llega una nueva muestra de audio con sus características (formantes, MFCC, etc.), cada árbol del bosque realiza su propia clasificación. La predicción final se decide por mayoría:

- Si la mayoría de los árboles clasifican el audio como deepfake, la predicción final es deepfake.
- Si la mayoría lo clasifica como real, la predicción final es real.

Este mecanismo de votación reduce drásticamente la varianza del modelo: aunque un árbol individual pueda cometer errores, el consenso del bosque suele ser acertado. Esto se puede ver en la siguiente imagen:

Ventajas específicas para detección de deepfakes

- **Robustez ante ruido:** Las características de audio pueden contener variaciones por condiciones de grabación; Random Forest maneja bien estos datos ruidosos.
- **No requiere normalización:** A diferencia de redes neuronales o SVM, no es necesario escalar las características, lo que simplifica el pipeline.
- **Interpretabilidad:** El algoritmo proporciona una medida de importancia de cada característica, permitiendo identificar qué parámetros acústicos son más discriminativos entre voz real y sintética.
- **Resistencia al overfitting:** La combinación de bagging y aleatoriedad evita que el modelo memorice el conjunto de entrenamiento.

2.1.4. LightGBM

LightGBM (*Light Gradient Boosting Machine*) es un framework de gradient boosting desarrollado por Microsoft en 2017 [?] que optimiza el proceso de entrenamiento mediante innovaciones en la forma de construir los árboles y muestrear los datos. Mientras que Random Forest construye árboles de forma independiente y paralela, LightGBM los construye secuencialmente, donde cada nuevo árbol se especializa en corregir los errores de los anteriores.

Arquitectura y funcionamiento

El proceso de boosting funciona de la siguiente manera:

1. Se entrena un primer árbol simple que intenta clasificar las voces como reales o deepfake.
2. Se identifican los audios que este primer árbol clasificó incorrectamente.
3. Se entrena un segundo árbol enfocado específicamente en esos casos difíciles.
4. Se combinan ambos árboles para mejorar la precisión global.
5. El proceso se repite construyendo decenas o cientos de árboles, cada uno corrigiendo los residuos de los anteriores.

Innovaciones clave

- **Crecimiento por hoja (*leaf-wise*):** Los árboles tradicionales crecen nivel por nivel (balanceados). LightGBM, en cambio, crece expandiendo la hoja que más puede reducir el error en cada paso, lo que produce árboles más profundos en las regiones problemáticas y más eficientes en las fáciles.
- **Muestreo basado en gradientes (*GOSS*):** Durante el entrenamiento, LightGBM identifica qué instancias (audios) tienen mayor error y las prioriza. Las instancias

con error pequeño se muestrean aleatoriamente para reducir el costo computacional. Esto permite entrenar con datasets grandes sin procesar toda la información redundante.

- **Agrupación de características (EFB):** Muchas características de audio raramente toman valores distintos de cero simultáneamente. LightGBM las agrupa para reducir la dimensionalidad, acelerando el entrenamiento sin pérdida de información significativa.

Proceso de clasificación

Cuando un nuevo audio llega para ser clasificado:

- Pasa secuencialmente por todos los árboles construidos.
- Cada árbol aporta una corrección o ajuste a la predicción anterior.
- La suma ponderada de todas las contribuciones produce la clasificación final (probabilidad de ser deepfake).

Ventajas específicas para detección de deepfakes

- **Alta precisión:** El enfoque secuencial de corrección de errores suele superar a Random Forest en problemas complejos como la detección de deepfakes.
- **Eficiencia computacional:** El muestreo inteligente permite entrenar con grandes volúmenes de audios en menos tiempo que otros métodos de boosting.
- **Manejo de desequilibrios:** Si existen desbalances entre clases, LightGBM incorpora mecanismos para ponderar las muestras adecuadamente.
- **Early stopping:** Se puede configurar para que detenga el entrenamiento cuando añadir más árboles no mejora la validación, evitando overfitting.

2.1.5. Support Vector Machines (SVM)

Las Máquinas de Vectores de Soporte (*Support Vector Machines*, SVM) son un conjunto de algoritmos de aprendizaje supervisado desarrollados por Vladimir Vapnik y su equipo en AT&T Bell Laboratories durante la década de 1990 [?]. Originalmente diseñadas para clasificación binaria, las SVM se han convertido en uno de los métodos más robustos y teóricamente fundamentados del aprendizaje automático.

Fundamento conceptual: El hiperplano óptimo

El objetivo fundamental de una SVM es encontrar un hiperplano que separe las dos clases (en nuestro caso, voces reales y voces generadas por IA) con el máximo margen posible. Para comprender este concepto, es útil visualizar un problema simple en dos dimensiones:

- Imaginemos que representamos cada audio como un punto en un plano, donde los ejes son dos características (por ejemplo, el primer formante y el primer MFCC).

- Las voces reales se agrupan en una región del plano y las generadas por IA en otra.
- Un hiperplano en dos dimensiones es simplemente una línea recta que intenta separar ambos grupos.

La clave de SVM reside en que no cualquier línea divisora es válida: el algoritmo busca aquella que maximiza la distancia (margen) entre la línea y los puntos más cercanos de cada clase. Estos puntos críticos, que “sostienen” el margen, reciben el nombre de **vectores de soporte** (*support vectors*), de donde el algoritmo toma su nombre.

Funcionamiento del algoritmo

El proceso de entrenamiento de una SVM puede entenderse en los siguientes pasos:

1. **Identificación de vectores de soporte:** El algoritmo examina todos los puntos de entrenamiento (audios con sus características) e identifica aquellos que son más difíciles de clasificar, es decir, los que están más cerca de la frontera entre clases.
2. **Maximización del margen:** A partir de estos vectores de soporte, la SVM calcula el hiperplano que maximiza la distancia a ambos lados. Este margen máximo proporciona la mejor capacidad de generalización: cuanto más ancho sea el margen, menor será la probabilidad de error al clasificar nuevos audios.
3. **Clasificación de nuevas muestras:** Una vez entrenado el modelo, para clasificar un nuevo audio, simplemente se calcula a qué lado del hiperplano se sitúa. Si cae en el lado de las voces reales, se clasifica como real; si cae en el lado de las generadas por IA, se clasifica como deepfake.

El truco del kernel: Separando lo inseparable

Uno de los mayores desafíos en la detección de deepfakes es que las voces reales y generadas por IA rara vez son linealmente separables en el espacio original de características. Es decir, no existe una línea recta (o hiperplano) que pueda separarlas perfectamente. Para abordar esta limitación, las SVM introducen el concepto de **kernel** o núcleo.

El *truco del kernel* (*kernel trick*) funciona de la siguiente manera conceptual:

- Los datos originales (no separables linealmente) se transforman implícitamente a un espacio de mayor dimensionalidad mediante una función matemática.
- En este nuevo espacio, es posible que los datos sí sean linealmente separables.
- La magia del kernel es que realiza esta transformación sin necesidad de calcular explícitamente las coordenadas en el espacio de alta dimensión, lo que sería computacionalmente prohibitivo.

Los kernels más comúnmente utilizados son:

- **Kernel lineal:** Asume que los datos son aproximadamente separables por un hiperplano. Útil cuando el número de características es muy grande.
- **Kernel polinomial:** Crea fronteras de decisión curvas mediante combinaciones polinómicas de las características originales.
- **Kernel RBF (*Radial Basis Function*):** Es el más utilizado en problemas de audio. Proyecta los datos a un espacio de dimensionalidad infinita, permitiendo fronteras de decisión altamente complejas y no lineales. Se basa en la similitud entre muestras medida por distancia euclidiana:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$$

donde γ controla la influencia de cada muestra: un valor pequeño considera vecindarios amplios (frontera más suave), mientras que un valor grande se enfoca en vecindarios reducidos (frontera más ajustada a los datos).

Parámetros críticos

El rendimiento de una SVM depende fundamentalmente de dos parámetros:

- **C (parámetro de regularización):** Controla el equilibrio entre tener un margen amplio y clasificar correctamente los puntos de entrenamiento. Un valor bajo de C busca un margen grande aunque se cometan algunos errores (modelo más generalista). Un valor alto de C penaliza fuertemente los errores, ajustándose más a los datos de entrenamiento (riesgo de overfitting).
- **γ (gamma):** Específico del kernel RBF, define hasta qué punto llega la influencia de un solo punto de entrenamiento. Valores bajos significan influencia de largo alcance (frontera más suave), mientras que valores altos hacen que cada punto tenga influencia muy local (frontera más compleja).

Ventajas específicas para detección de deepfakes

- **Fundamento teórico sólido:** A diferencia de otros métodos heurísticos, SVM está basada en la teoría de optimización convexa, lo que garantiza que la solución encontrada es óptima (máximo margen global).
- **Eficaz en espacios de alta dimensión:** Las características de audio pueden generar vectores de gran dimensionalidad (decenas o cientos de coeficientes). SVM maneja bien esta situación sin colapsar por la maldición de la dimensionalidad.
- **Robustez ante overfitting:** La maximización del margen proporciona una regularización natural que mejora la generalización, crucial cuando se trabaja con datasets limitados de voces deepfake.
- **Versatilidad mediante kernels:** La capacidad de elegir diferentes kernels permite adaptar el modelo a la estructura no lineal de los datos de audio sin necesidad de transformaciones manuales.

- **Interpretabilidad limitada pero útil:** Aunque no tan interpretable como los árboles de decisión, el análisis de los vectores de soporte puede revelar qué audios son más representativos o ambiguos en la frontera de decisión.

2.1.6. AASIST

AASIST (*Audio Anti-Spoofing usign Integrated Spectro-Temporal graph attention networks*) es un modelo propuesto por Jee-weon Jung, Hee-Soo Heo, Hemlata Tak, Hye-jin Shim, Joon Son Chung, Bong-Jin Lee, Ha-Jin Yu y Nicholas Evans en 2022. La principal motivación para el desarrollo de este clasificador surge de que los artefactos que sirven para diferenciar audios falsificados de audios bona fide se suelen encontrar en intervalos temporales o espectrales. Por esto, en la práctica se usaban ensembles costosos, desde el punto de vista computacional, donde cada subsistema se centraba en ciertos artefactos. AASIST consigue reemplazar ese enfoque por un único sistema que combina información espectro-temporal buscando robustez ante diversos tipos de ataques.

Arquitectura y funcionamiento

El modelo tiene las siguientes fases:

1. Extracción de características a partir del audio crudo:
 - Se usa un **encoder** basado en RawNet2 que acaba generando un mapa de características F , $F \in \mathbb{R}^{C \times S \times T}$ siendo C , número de canales, S , número de bins espectrales y T , longitud temporal.
 - Para ello, primero, se pasa el audio por una primera capa *sinc-convolution* con 70 filtros. La diferencia frente al RawNet2 original, es que en AASIST se interpreta la salida de esta capa como una “imagen” 2D de 1 canal.
 - A continuación, esta primera representación se pasa por seis bloques residuales con **pre-activación** que van comprimiendo y transformando la información útil para tener una representación lo más compacta posible.
2. Posteriormente, se generan dos **grafos completos** que modelan, de forma independiente, los dominios temporal y espectral, siendo G_t y G_s respectivamente. A cada grafo, se le aplica “**graph pooling**” para reducir el número de nodos, conservando los más relevantes lo que permite bajar el coste computacional posterior.
3. Ambos grafos se combinan en un tercer grafo, G_{st} con $N_t + N_s$ nodos entre los que se generan todas las aristas nuevas posibles en ambas direcciones, manteniendo las aristas de los grafos anteriores.
4. Bloque HS-GAL + pooling:
 - Se aplica **atención heterogénea** usando uno de los tres vectores de proyección según la relación entre los tipos de los nodos entre los que se hace la relación.

- Un (**stack node**), conectado de forma unidireccional a todos los nodos, que va acumulando la información espectro-temporal entre sucesivas capas HS-GAL.
 - Tras cada HS-GAL, se aplica otra vez la técnica “**graph pooling**” con el mismo objetivo anterior.
5. A continuación de crear el grafo G_{st} , se aplica la operación MGO(*Max Graph Operation*) que usa las técnicas del punto anterior. De forma paralela, se procesan dos ramas en las que se ejecutan consecutivamente dos secuencias HS-GAL-pooling. Dentro de cada rama, el “stack node” se propaga de la primera HS-GAL a la segunda. Finalmente, se combinan las salidas de ambas ramas usando un máximo elemento a elemento.
 6. Por último, usando las operaciones “**max**” y “**average**” sobre cada subgrafo final(temporal y espectral), se generan 4 vectores que se combinan con el “stack node” y se pasan a la capa de salida.

Innovaciones clave

- **HS-GAL**: una capa de atención, que permite ir integrando simultaneamente ambos grafos, combinada con un “stack” node para ir acumulando información espectro-temporal
- **MGO**: un método con dos ramas aplicando paralelamente HS-GAL más una fase de “pooling” lo que permite que cada secuencia pueda aprender distintos grupos de artefactos.
- **Nuevo esquema de readout**: permite concatenar la información contenida en el “stack node” con las estadísticas sacadas de la operaciones “max” y “average” finales.

Ventajas específicas para detección de deepfakes

- **Integración espectro-temporal**: al modelar conjuntamente los grafos temporal y espectral en un grafo heterogéneo, permite encontrar información cruzada que se podría perder si se tratara por separado.
- **Stack node**: esta técnica “acumulativa” ayuda a encontrar artefactos de spoofing cuando no están presentes en un solo nodo y se encuentran distribuidos en varios instantes o bandas.
- **Readout**: al juntar estadísticas globales(average) con evidencia puntual fuerte(max), facilita la detección de diferentes patrones de “spoofing”.
- **Ramas paralelas**: en MGO, se introducen dos ramas procesando en paralelo, permitiendo captar pistas complementarias.

2.2. Modelos de explicación

2.2.1. SHAP

Basado en la teoría de juegos cooperativos, SHAP asigna a cada característica acústica un valor de importancia que representa su contribución marginal. El valor de Shapley ϕ_i para una característica i se calcula como:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)]$$

Este método es preferido en el análisis forense debido a su consistencia matemática y su capacidad para ofrecer tanto explicaciones locales como una visión global de la importancia de los descriptores (como los coeficientes MFCC o el pitch).

2.2.2. LIME

LIME aproxima localmente la superficie de decisión de un modelo de caja negra mediante un modelo lineal interpretable. En el dominio del audio, el proceso se define mediante la perturbación de la entrada x (espectrogramas o marcos temporales) para observar las variaciones en la salida $f(x)$. La explicación g se obtiene minimizando:

$$\xi(x) = \arg \min_{g \in G} L(f, g, \pi_x) + \Omega(g)$$

donde L es la pérdida de fidelidad, π_x define la vecindad de la muestra y $\Omega(g)$ mide la complejidad del modelo sustituto.

2.2.3. Grad-CAM

Utiliza los gradientes de la última capa convolucional para producir un mapa de calor que resalta las regiones del espectrograma que influyen en la decisión. Aunque es eficaz para detectar sesgos en el conjunto de datos, su baja resolución espacial a menudo dificulta la identificación de discontinuidades de fase de micro-segundos, típicas de los vocoders neuronales.

2.2.4. Integrated Gradients

IG aborda la saturación del gradiente integrando las variaciones a lo largo de una trayectoria desde una entrada de referencia (baseline) x' hasta la entrada real x . La atribución para la característica i se define como:

$$IG_i(x) = (x_i - x'_i) \times \int_{\alpha=0}^1 \frac{\partial f(x' + \alpha(x - x'))}{\partial x_i} d\alpha$$

En audio, la selección de la línea base (silencio vs. ruido blanco) es un factor crítico para evitar explicaciones espurias.

2.2.5. DICE

Modelos como DiCE permiten generar ejemplos sintéticos mínimos que cambiarían la predicción del modelo. Esto es vital para analistas forenses, ya que permite identificar qué características de "naturalidad" le faltan a una muestra para ser considerada auténtica, proporcionando una comprensión causal del fenómeno de los deepfakes.

2.2.6. SincNet

SincNet sustituye las capas de convolución estándar por filtros de banda basados en la función Sinc. El modelo solo aprende las frecuencias de corte f_1 y f_2 , permitiendo una interpretación física directa de los rangos espectrales (como formantes o armónicos) que el sistema utiliza para discriminar la voz real de la sintética.

2.2.7. ProtoPNet

Estos modelos clasifican la señal encontrando similitudes con "prototipos" aprendidos durante el entrenamiento. Ante un audio sospechoso, el modelo proporciona una explicación del tipo: "Este segmento se clasifica como deepfake porque se asemeja a este patrón de artefacto espectral observado en el modelo de síntesis WaveNet".

3. Metodología

3.1. Dataset

Para encontrar un dataset público que tuviera voces tanto reales como clonadas y que además fueran por pares (i.e. un audio de voz real cuya transcripción es "Hoy he comido en un restaurante chino" y un audio clonando dicha voz diciendo lo mismo) ha sido complicado. Hemos echado un ojo a bastantes datasets. Vamos a comentar los que hemos tenido en cuenta.

1. HABLA [?]: Este dataset cuenta con una gran cantidad de audios tanto reales, como generados (con técnicas como TTS) y voces clonadas (con técnicas como Cycle-GAN). Lo hemos descartado para una primera iteración del proyecto, pero no lo descartamos para una próxima iteración.
2. audioMNIST [?]: Este dataset cuenta con 30 mil audios de los números del 0 al 9 en inglés. Lo hemos descartado porque todos los audios son voces reales, por lo que no nos sirve para nuestra tarea.
3. ASVSpooof2021 [?]: Este dataset forma parte de una serie de desafíos internacionales organizados por la comunidad de verificación automática de audio cuyo objetivo es evaluar y mejorar los sistemas capaces de detectar voz manipulada. El dataset se compone de tres grupos de audio, todos ellos con voz real y generada mezclada, logical access con grabaciones transmitidas mediante canales de voz con efectos de codificación y transmisión, physical access con grabaciones de voz auténticas y ataques de reproducción en espacios físicos reales y speech deepfake con grabaciones generadas sintéticamente y comprimidas de formas distintas.

Este dataset lo hemos descartado por no contar con pares de audio aunque se pueden rescatar algunos audios en inglés sobre todo para probar los modelos que probemos más adelante.

4. Kaggle

5. Wavefake [\[\]](#): Este dataset de Kaggle cuenta con gran cantidad de audios generados. Como tal, nos sirvió para probar el primer prototipo de extracción de características y buscar librerías como librosa o speechRecognition. Este dataset, al no tener los audios reales, no nos sirve para luego desarrollar los modelos.

El dataset por el que nos hemos decantado se llama **ODSS**. Hemos usado este conjunto de audios porque ya tiene creado un par para cada audio, lo que nos ahorra tiempo de generar nuestros propios audios. A esta ventaja se le suma que ODSS ya contenía audios en Inglés y en Español, ambos idiomas son sumamente hablados por lo que es interesante centrarse en ellos.

Con todo esto mencionado, hemos tomado un subset de 100 audios de cada idioma. La mitad son audios naturales y la otra mitad audios generados. Más adelante, probaremos a usar más cantidad de audios y compararemos el rendimiento.

3.2. Extracción de características

Para poder clasificar los audios en reales y generados tenemos que pensar primero en qué datos necesitamos pasar a los modelos para que aprendan. Podemos separar los datos que debemos proporcionar a dichos modelos en 3 grupos:

1. Características. Podemos extraer características de la voz como el tono fundamental, los formantes, las pausas, y otros. Con estos datos, los modelos pueden aprender las relaciones entre los dos grupos de audios.
2. Gráficas. Podemos extraer gráficas de la voz como la forma de onda, el espectrograma de MEL, y otros. Con estas gráficas las CNN pueden aprender los puntos clave que diferencian a los audios reales de los generados.
3. Audio crudo. Existen modelos llamados wav2vec los cuales aprenden directamente de los audios, sacando un vector denso de características latentes en los audios, para después hacer ajuste fino o *fine-tuning* de un modelo para clasificar los audios.

Vamos a ver más en detalle qué características de cada tipo sacamos.

Características

Podemos extraer características de la voz como el tono fundamental, los formantes, las pausas, y otros. Con estos datos, los modelos pueden aprender las relaciones entre los dos grupos de audios. Tenemos que destacar que las características de este tipo extraídas son mayormente arrays en el que cada componente es un valor en un momento determinado. Esto es porque la voz tiene la componente temporal, por lo que hay que dividir cada audio en marcos temporales (frames). Además, los modelos que aplicaremos no entrenan con

arrays, por lo que los promediaremos con la media y/o desviación típica. Vamos a explicar cada característica que extraemos de los audios:

1. **Valor cuadrático medio (rms):** Mide la energía promedio de una señal acústica (i.e. la intensidad o volumen general del audio). Se extrae dividiendo la señal en frames, para cada frame se calcula la raíz cuadrada del promedio de los valores de onda al cuadrado y, por último, se promedian esos valores. En voz humana natural, el RMS tiende a tener variaciones más orgánicas, mientras que audios sintéticos pueden mostrar patrones más uniformes.
2. **Tasa de cruces por cero (zcr):** Mide el número de veces que la señal cambia de signo por segundo, lo que nos permite distinguir entre los sonidos tonales (periódicos) y los ruidosos (no periódicos). Se extrae detectando los puntos donde la señal cambia de signo, se cuentan dichos puntos por unidad de tiempo y se normaliza por la longitud del frame. Los sonidos sordos (como /s/, /f/) tienen ZCR alto, mientras los sonoros (/a/, /m/) tienen ZCR bajo.
3. **Centroide espectral:** Mide el centro de masa del espectro de frecuencias, lo que nos dice, de forma ponderada, si la energía de un sonido se concentra en las frecuencias graves (bajas) o en las frecuencias agudas (altas). Se obtiene calculando la Transformada Rápida de Fourier (FFT) para cada frame para obtener el espectro de frecuencias, se ponderan las frecuencias por su magnitud (energía de dicha frecuencia) y se calcula la media de estas. Cabe mencionar que las voces femeninas tienden a tener centroides más altos que masculinas.
4. **Ancho de banda espectral:** Mide qué tan dispersas están las frecuencias alrededor del centroide, para ver si el sonido es “puro” como un silbido o una sílaba mantenida, o es “ruidoso” como el ruido blanco o un aplauso. Se extrae hallando el centroide como antes y se calcula la desviación típica ponderada en vez de la media ponderada.
5. **Punto de caída espectral (spectral rolloff):** Mide la frecuencia por debajo de la cual se concentra un determinado porcentaje de la energía total del espectro, es decir, la frecuencia límite para un porcentaje de energía. Normalmente, dicho porcentaje es del 85 %, aunque puede variar entre 75 % a 90 %, y funciona como un percentil. Se obtiene calculando el centroide igual que antes y sumando la energía progresivamente hasta que lleguemos a una frecuencia con la que nos pasamos de dicho porcentaje. Es útil para distinguir entre sonidos con energía concentrada en bajas frecuencias, en un amplio espectro, o en altas frecuencias.
6. **Planitud espectral:** Mide cómo de plano es el sonido. Varía entre 0 y 1 siendo 0 un sonido con picos pronunciados y 1 un sonido con pocos picos. Se obtiene calculando el espectro como antes (FFT) y dividiendo la media geométrica del espectro entre la media aritmética del mismo.
7. **Tono fundamental (F0):** Es la frecuencia más baja y periódica de un sonido. En el contexto de la voz, es la frecuencia a la que vibran tus cuerdas vocales. El tono fundamental puede verse en, por ejemplo, las emociones, las preguntas frente a afirmaciones, las notas musicales, entre otras, por lo que nos da mucha

información acerca de algo o alguien. Hay varias formas de calcularlo, y ninguna es 100 % precisa. Nosotros nos decantamos por la función PYIN, la cual primero obtiene las frecuencias fundamentales mediante el algoritmo YIN y después aplica el algoritmo probabilístico de Viterbi para obtener la cadena F0 más probable. Estos son algoritmos más sofisticados que combinan autocorrelación, análisis espectral y probabilidades para evitar errores comunes como la octava errónea (detectar 200Hz por ruido en vez del tono real de 100Hz), zonas no voiceadas (unvoiced) y ruido de fondo.

8. **Formantes:** Son las frecuencias de resonancia del tracto vocal (la boca, la garganta y la nariz). Estas frecuencias se amplifican de forma natural cuando hablamos, dependiendo de la forma que le demos a la boca.

- a) F1 (Primer formante): Relacionado con la abertura de la mandíbula (qué tan abierta está la boca).
- b) F2 (Segundo formante): Relacionado con la posición de la lengua (adelante o atrás).
- c) F3 (Tercer formante): Relacionado con la posición de la punta de la lengua y tiene mucha importancia en las vocales raras en la identidad del hablante.

Para extraerlos hay varias alternativas, nosotros usamos el método de Burg para estimar las formantes, después se muestrean 100 puntos a lo largo del audio y se calcula la media.

9. **Relación Armónico-Ruido:** Mide la proporción entre energía periódica (armónicos) y energía aperiódica (ruido). Esta relación es una indicadora directa de la eficiencia fonatoria y la salud vocal: puede indicar la existencia de patologías como voz ronca, o afonía; una fatiga vocal; o, en algunos casos, emociones. Hay varias formas de calcularla: como el método de autocorrelación o el de análisis espectral. Nosotros usamos la función `to_harmonicity` de `parselmout.Sound`, la cual la calcula con el método de autocorrelación: primero halla el F0 de los frames; después aplica la función de autocorrelación normalizada $r(\tau) = \frac{\int x(t) \cdot x(t+\tau) dt}{\int x^2(t) dt}$; luego busca el máximo de la función de autocorrelación en el intervalo alrededor del período fundamental esperado, este máximo corresponde a la correlación entre la señal y su versión desplazada un período; tras esto calcula el hnr en decibelios $HNR = 10 \cdot \log_{10} \left(\frac{r_{\max}}{1-r_{\max}} \right)$ y, por último, aplica interpolación parabólica para obtener valores más precisos del máximo y realiza correcciones para compensar el efecto de la ventana de análisis. Es interesante saber que las voces humanas naturales suelen oscilar entre los 10 a 25 dB, por lo que unos valores extremos pueden indicar voz sintética.

10. **Proporción de silencio:** Mide el porcentaje del tiempo o de frames donde no hay voz activa, es decir, hay silencio o ruido de fondo hasta cierto umbral. La forma de calcularla es muy simple: se establece un umbral de energía el cual por debajo una energía es considerada silencio, se calcula el rms y se le aplica el filtro del umbral, finalmente se divide el número de frames considerados silencio entre

el número total de frames. Esto, pese a su simpleza, puede ser determinante en el análisis de una voz ya que las IAs pueden generar patrones de pausas poco naturales o demasiado regulares.

11. **Coefficientes Cepstrales en Frecuencia de Mel (mfcc)**: Son una representación compacta del espectro de frecuencias que imita cómo percibe el sonido el oído humano. En lugar de trabajar con frecuencias lineales (Hz), trabajan con una escala llamada escala Mel, que es más sensible a los cambios en frecuencias bajas que en altas (como nuestro oído). Son un total de 13 coeficientes: el primero representa la energía promedio del espectro (similar al RMS, pero en el dominio cepstral); mientras que el resto representan la forma detallada del espectro: los picos, los valles, las pendientes. Cada coeficiente añade un nivel de detalle diferente. Estos coeficientes son muy importantes ya que son, con diferencia, la característica más utilizada en: reconocimiento de voz (Speech-To-Text), reconocimiento de hablante (Identificación), clasificación de géneros musicales, entre muchas otras aplicaciones. Hoy en día son un estándar en reconocimiento de voz. Se extraen mediante un proceso más laborioso: primero se hace un pre-énfasis, amplificando las frecuencias altas, ya que estas tienen poca energía; después se calcula el espectro de frecuencias de cada frame; tras esto se aplica un banco de filtros triangulares espaciados según la escala Mel, donde por debajo de los 1000 Hz se aplican filtros lineales (nuestro oído distingue bien los cambios en frecuencias bajas) y por encima de los 1000 Hz se aplican filtros logarítmicos (nuestro oído distingue peor los cambios en frecuencias altas), con la fórmula $\text{Mel}(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right)$ y, para terminar, aplica la Transformada Coseno Discreta (DCT), la cual decorrelaciona las bandas de Mel, que suelen estar correlacionadas entre sí, compacta la información y devuelve los 13 primeros coeficientes (pueden aparecer entre 20 y 40, pero no son muy representativos).
12. **Asimetría (skewness)**: Mide hacia qué lado se inclina la distribución de la energía en un conjunto de datos. Si hay una asimetría positiva, la energía se concentra en valores bajos, con una cola larga hacia los valores altos. Si hay una asimetría negativa, la energía se concentra en valores altos, con una cola larga hacia los valores bajos. Si no hay asimetría, la energía está equilibrada alrededor del centro (como una campana de Gauss). Se calcula restando la media a cada muestra y elevando al cubo, luego hallando el promedio de estas desviaciones cúbicas, y, finalmente, dividiendo por la desviación estándar al cubo para estandarizar. Cabe mencionar que unas distribuciones de amplitud asimétricas pueden indicar características anómalas en voces sintéticas.
13. **Curtosis**: Mide qué tan concentrados están los valores alrededor de la media y qué tan pesadas son las colas de la distribución. En audio, la curtosis nos dice qué tan "espigado" o "suave" es un sonido en términos de cómo se distribuyen sus amplitudes (en el tiempo) o su energía (en la frecuencia). Se obtiene con la siguiente fórmula $\text{Curtosis} = \frac{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^4}{\left(\sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2} \right)^4}$. Adicionalmente, se puede restar 3 a la curtosis para que la mitad (mesocúrtica) se halle en 0. Podemos destacar que

una curtosis alta (distribución picuda) puede aparecer en audios con compresión excesiva o artefactos de síntesis.

14. **Transcripción:** Para la transcripción de los audios usamos modelos de **vosk**. Esta elección se debe a que tiene modelos para ambos idiomas que vamos a usar y además, 2 modelos dentro de cada lenguaje. El que usamos para las pruebas es el small ya que es más rápido y por lo tanto más útil para esta primera fase pero dejamos en consideración el modelo full para futuras fases ya que tiene mayor precisión. Sobre esto, cabe mencionar que primero probamos el modelo whisper pero tras varias pruebas con errores y la incapacidad para hacer funcionar, lo descartamos y es cuando escogimos vosk para esta tarea. Es interesante tener en cuenta la transcripción de un audio ya que en ocasiones, si no podemos sacar texto en claro, pero se sabe que hay voces, es muy probable que el audio sea generado.

3.3. Preprocesamiento

3.4. Modelos de clasificación

3.4.1. Perceptrón multicapa

Hemos usado el código de extracción de características para procesar los audios que tenemos en el dataset personalizado con 100 audios en español (50 reales y 50 generados a partir de esos reales). Una vez preprocesados los audios con sus características extraídas, empleamos una CNN (red neuronal convolucional) para sacar un embedding de 128 dimensiones del espectrograma del audio y un MLP (perceptrón multicapa) para sacar un embedding de 64 dimensiones de las características paralingüísticas del audio. Tras esto, las concatenamos teniendo un embedding de 192 dimensiones siendo las primeras 64 las características y las otras 128 las del espectrograma.

Después, creamos un perceptrón multicapa cuyo objetivo es clasificar el audio en si es generado o es real empleando para ello lógica difusa (*fuzzy logic*). Para ello, pasamos la salida del perceptrón por un controlador fuzzy que irá aprendiendo también sus parámetros y adaptará la salida para que esté entre 0 y 1 siendo que cuanto más cercano al 0, más posible es que el audio sea real y no sea generado. En la práctica, como el dataset es de 100 datos, no hay suficientes para entrenar un perceptrón de forma correcta ya que cuando hicimos las pruebas, todas las predicciones del perceptrón no se alejan del 0.5 que en este contexto de probabilidad continuo significa que el modelo está indeciso y no lo sabe clasificar como real o como generado.

3.4.2. Fine-tuning Wav2Vec2

Wav2Vec2 es un modelo de aprendizaje profundo para procesamiento de voz que permite obtener representaciones acústicas de alta calidad directamente desde la señal cruda de audio, sin necesidad de características manuales. Fue propuesto por Meta en 2020.

Este modelo recibe como entrada la forma de onda sin procesar del audio (audio crudo) y su salida debe ser decodificada utilizando Wav2Vec2CTCTokenizer.

El fine-tuning se hará con el dataset de 100 datos que tenemos para entrenar el Wav2Vec2 en la tarea de clasificación de audio. Al igual que con el modelo anterior, también lo pasaré por un controlador fuzzy para que nos diga cuan probable es que el audio sea real o IA.

El proceso comienza creando un dataset de entrenamiento y otro de prueba en el que cada uno tendrá el mismo número de audios reales y generados y una etiqueta que indique si es humano o no. Una vez tenemos el dataset, hay que preprocesar los audios ya que en un inicio solo tiene las rutas de los audios por lo que ahora hay que cargar los audios de verdad. Para esta tarea usaremos el propio extractor de características que tiene el modelo (Wav2Vec2FeatureExtractor) fijando la frecuencia de muestreo a 16KHz y activando el padding que rellenará los audios cortos con ceros y trucará los audios largos para que todos tengan la misma longitud. Este preprocesado resultará en que ahora en el dataset, en lugar de haber rutas a los audios, hay tensores de Torch representándolos.

Ahora que ya tenemos el dataset de entrenamiento preprocesado, lo volvemos a dividir en entrenamiento y validación y entrenamos el modelo ya preentrenado para la nueva tarea de detección de voz generada por . Para evaluar el modelo se emplearon tres métricas, la precisión (verdaderos positivos / (verdaderos positivos + falsos positivos), la f1 (Media armónica entre precisión y recall) y el AUC (Área bajo la curva: Capacidad del modelo para distinguir entre clases positivas y negativas). El fine-tuning ha sido muy leve ya que con los 90 audios (80 de entrenamiento y 10 de validación) hay que congelar el aprendizaje del modelo para evitar un sobreentrenamiento.

Una vez hecho el fine-tuning, hacemos el mismo preprocesado para el dataset de test y ponemos el modelo en modo evaluación. Los resultados que de el modelo se pasan por un clasificador fuzzy que se encargará del postprocesado de la salida que la normalizará entre 0 y 1 siendo que los audios cuya score está entre 0.4 y 0.6 no los sabe clasificar, los que están por debajo de 0.4 son audios reales y los que están por encima de 0.6 son audios generados.

3.4.3. Random Forest

3.4.4. LightGBM

LightGBM (Light Gradient Boosting Machine) es un framework de gradient boosting desarrollado por Microsoft en 2017 [?] que optimiza el proceso de entrenamiento mediante innovaciones como el muestreo unilateral basado en gradientes (GOSS) y la agrupación exclusiva de características (EFB). A diferencia de Random Forest, que construye árboles de forma independiente y paralela, LightGBM los construye secuencialmente, donde cada nuevo árbol se especializa en corregir los errores de los anteriores.

Justificación del modelo

LightGBM presenta ventajas significativas para la tarea de detección de deepfakes de audio:

- **Alta precisión:** El enfoque secuencial de corrección de errores suele superar a los métodos de bagging en problemas complejos como la detección de deepfakes.
- **Eficiencia computacional:** El muestreo inteligente (GOSS) permite entrenar con grandes volúmenes de audios en menos tiempo que otros métodos de boosting.
- **Manejo de no linealidades:** Las firmas acústicas de las voces generadas por IA presentan patrones complejos que los árboles de decisión secuenciales pueden capturar de forma más efectiva.
- **Regularización integrada:** Los parámetros de regularización L1 y L2 ayudan a prevenir el sobreajuste cuando se trabaja con características de audio altamente correlacionadas.
- **Soporte nativo para datos desbalanceados:** Mediante el parámetro `is_unbalance` o `scale_pos_weight`, LightGBM ajusta automáticamente los pesos de las clases.

Fundamento del algoritmo

LightGBM construye los árboles de decisión de forma secuencial, minimizando una función de pérdida mediante el gradiente. A diferencia del boosting tradicional, introduce dos innovaciones clave:

- **GOSS (Gradient-based One-Side Sampling):** En lugar de usar todas las muestras para estimar la ganancia de información, GOSS retiene las muestras con gradientes grandes (aquellas con mayor error) y muestrea aleatoriamente las de gradiente pequeño. Esto reduce drásticamente el número de instancias a considerar sin perder precisión.
- **EFB (Exclusive Feature Bundling):** Agrupa características mutuamente excluyentes (que raramente toman valores no cero simultáneamente) para reducir la dimensionalidad, crucial cuando se trabaja con características de audio de alta dimensión como los MFCC.
- **Crecimiento por hoja (leaf-wise):** A diferencia del crecimiento nivelado tradicional, LightGBM expande el nodo con mayor pérdida, lo que produce árboles más profundos en las regiones problemáticas y más eficientes en las fáciles.

Configuración experimental

El proceso experimental para LightGBM se estructuró en cuatro fases: (1) establecimiento de un modelo baseline, (2) validación cruzada para evaluar robustez, (3) optimización de hiperparámetros mediante búsqueda sistemática, y (4) evaluación comparativa con métricas exhaustivas.

Preparación de datos A diferencia de otros algoritmos, LightGBM puede manejar directamente datos sin normalización, aunque requiere que no existan valores nulos.

Modelo baseline con LightGBM Se estableció una configuración inicial utilizando la interfaz nativa de LightGBM, que ofrece un control más fino sobre el proceso de entrenamiento:

El parámetro `is_unbalance=True` activa la compensación automática para clases desbalanceadas, ajustando los pesos de forma inversamente proporcional a la frecuencia de cada clase.

Early stopping Una ventaja importante de LightGBM es la capacidad de detener el entrenamiento cuando añadir más árboles no mejora el rendimiento en validación. Esto:

- Previene el sobreajuste (overfitting)
- Ahorra tiempo computacional
- Determina automáticamente el número óptimo de iteraciones

Validación cruzada

Para LightGBM se utilizó la interfaz compatible con scikit-learn (`LGBMClassifier`) que permite integrarse con las herramientas de validación cruzada estándar:

La validación cruzada proporciona una estimación más robusta del rendimiento, reportándose la media y la desviación estándar de las métricas.

Optimización de hiperparámetros

LightGBM cuenta con un conjunto de hiperparámetros específicos, diferentes a los de Random Forest. La búsqueda se centró en aquellos que más influyen en el rendimiento:

- `num_leaves`: Controla la complejidad del modelo. Valores altos permiten capturar patrones más complejos pero aumentan el riesgo de sobreajuste.
- `learning_rate`: Tasa de aprendizaje (eta). Valores pequeños requieren más iteraciones pero pueden lograr mejor convergencia.
- `n_estimators`: Número de iteraciones de boosting.
- `min_child_samples`: Mínimo de muestras requeridas en una hoja. Controla la profundidad y evita hojas con pocas muestras.
- `subsample` y `colsample_bytree`: Fracciones de muestras y características para cada árbol, introduciendo aleatoriedad.
- `reg_alpha` y `reg_lambda`: Regularización L1 y L2 para controlar la complejidad.

Métricas de evaluación

Se emplearon las mismas métricas que en Random Forest para mantener la comparabilidad:

- **Accuracy:** Proporción de predicciones correctas.
- **Precision:** Proporción de predicciones positivas correctas.
- **Recall:** Proporción de positivos reales correctamente identificados.
- **F1-Score:** Media armónica de precisión y recall.
- **AUC-ROC:** Área bajo la curva ROC.
- **MCC:** Coeficiente de correlación de Matthews.

La función de evaluación implementada es la misma que para Random Forest, garantizando consistencia en la comparación.

Análisis de importancia de características

LightGBM ofrece dos tipos de importancia de características, complementarias entre sí:

- **Gain:** Suma de la mejora (reducción de pérdida) que aporta cada característica cuando se usa en una división. Es la medida más informativa.
- **Split:** Número de veces que la característica se utiliza para dividir nodos. Indica la frecuencia de uso, no necesariamente su impacto.

Esta dualidad permite un análisis más profundo: una característica puede usarse con frecuencia (split alto) pero aportar poca mejora (gain bajo), o viceversa.

Análisis de eficiencia computacional

Una ventaja destacada de LightGBM es su eficiencia. Se midieron los tiempos de entrenamiento para cuantificar esta mejora:

3.4.5. Support Vector Machine (SVM)

Como ya hemos visto sobre los SVM, estos se fundamentan en la búsqueda del hiperplano óptimo que maximiza el margen de separación entre clases, lo que proporciona una base teórica sólida y garantías de generalización.

Justificación del modelo

Usamos SVM ya que presenta características especialmente relevantes para la detección de deepfakes de audio que hemos comentado antes, como la eficacia en espacios de alta dimensión (como puede ser el mundo del lenguaje natural) o su fundamento teórico robusto.

Importancia de la normalización

Una característica crítica de SVM es su sensibilidad a la escala de las características. Las variables de audio presentan escalas muy diferentes:

- **Formantes**: Del orden de cientos de Hz (ej. 300-3000 Hz)
- **MFCC**: Valores típicamente en el rango $[-200, 200]$
- **ZCR** (Zero Crossing Rate): Valores normalizados entre 0 y 1
- **HNR** (Harmonics-to-Noise Ratio): Valores en decibelios (dB)

Sin normalización, las características con mayor magnitud dominarían el cálculo de distancias, sesgando el modelo. Por ello, se aplicó `StandardScaler` para estandarizar las características a media cero y desviación típica uno:

Listing 1: Normalización de características para SVM

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Es crucial aplicar el escalado *después* de la división train/test para evitar *data leakage* (fuga de información del conjunto de prueba al entrenamiento).

Configuración experimental

El proceso experimental para SVM se estructuró en cuatro fases: (1) modelo baseline con kernel lineal, (2) modelo con kernel RBF, (3) validación cruzada, y (4) optimización de hiperparámetros mediante Grid Search.

Modelo baseline: SVM lineal Se estableció un primer modelo con kernel lineal como referencia simple:

Listing 2: Configuración SVM lineal baseline

```
svm_linear = SVC(
    kernel='linear',          # Frontera de decision lineal
    C=1.0,                   # Parametro de regularizacion
    probability=True,        # Habilita probabilidades para AUC-ROC
    random_state=12,
    class_weight='balanced'  # Compensacion de clases desbalanceadas
)
```

El parámetro `class_weight='balanced'` ajusta los pesos de las clases de forma inversamente proporcional a su frecuencia, compensando posibles desbalances en el conjunto de datos.

Modelo no lineal: SVM con kernel RBF Dada la naturaleza compleja de las señales de audio, se implementó un modelo con kernel RBF para capturar relaciones no lineales:

Listing 3: Configuración SVM con kernel RBF

```
svm_rbf = SVC(  
    kernel='rbf',          # Kernel no lineal  
    C=1.0,                 # Regularizacion  
    gamma='scale',        # Coeficiente del kernel  
    probability=True,  
    random_state=12,  
    class_weight='balanced'  
)
```

El parámetro `gamma='scale'` establece automáticamente $\gamma = 1/(n_{\text{características}} \cdot \text{Var}(X))$, un valor inicial razonable.

Validación cruzada

Para garantizar la robustez de las evaluaciones y evitar dependencias de una única partición, se implementó validación cruzada estratificada con 5 folds. Se utilizó un pipeline que integra el escalado y el clasificador para asegurar que la normalización se realice correctamente en cada fold:

Listing 4: Pipeline con validación cruzada para SVM

```
from sklearn.pipeline import Pipeline  
from sklearn.model_selection import StratifiedKFold, cross_val_score  
  
# Pipeline que integra escalado + SVM  
svm_pipeline = Pipeline([  
    ('scaler', StandardScaler()),  
    ('svm', SVC(kernel='rbf', probability=True,  
                random_state=42, class_weight='balanced'))  
)  
  
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=12)  
  
cv_scores_accuracy = cross_val_score(svm_pipeline, X_train, y_train,  
                                     cv=cv, scoring='accuracy')  
cv_scores_f1 = cross_val_score(svm_pipeline, X_train, y_train,  
                               cv=cv, scoring='f1')  
cv_scores_auc = cross_val_score(svm_pipeline, X_train, y_train,  
                                cv=cv, scoring='roc_auc')
```

El uso de pipeline es especialmente importante en SVM porque garantiza que la normalización se ajuste únicamente con los datos de entrenamiento de cada fold, evitando contaminación con datos de validación.

Optimización de hiperparámetros

SVM con kernel RBF tiene dos hiperparámetros críticos que determinan su rendimiento (ya explicados previamente):

- **C (parámetro de regularización).**
- γ (**gamma**).

La búsqueda sistemática se realizó mediante Grid Search con validación cruzada:

Listing 5: Grid Search para optimización de SVM

```
param_grid = {
    'svm__C': [0.1, 1, 10, 100],          # Regularizacion
    'svm__gamma': [0.001, 0.01, 0.1, 1, 'scale', 'auto'],
# Influencia del kernel
    'svm__kernel': ['rbf']                # Nos centramos en RBF
}

grid_search = GridSearchCV(
    svm_pipeline,
    param_grid,
    cv=cv,
    scoring='f1',                          # Optimizamos F1-score
    n_jobs=-1,
    verbose=1
)

grid_search.fit(X_train, y_train)
svm_optimized = grid_search.best_estimator_
```

La elección de optimizar el F1-score responde a la necesidad de balancear precisión y sensibilidad en un problema donde ambos tipos de error (falsos positivos y falsos negativos) son relevantes.

Análisis de vectores de soporte

Una característica única de SVM es la identificación de los **vectores de soporte**: las muestras críticas que determinan la frontera de decisión. Su análisis proporciona información sobre la complejidad del problema:

Listing 6: Análisis de vectores de soporte

```
# Obtenemos el modelo del pipeline
svm_model = svm_optimized.named_steps['svm']
n_support_vectors = svm_model.n_support_
support_vectors_count = sum(n_support_vectors)

print(f"Total de vectores de soporte: {support_vectors_count}")
```



```

print(f"Porcentaje del dataset: {support_vectors_count/len(X_train)*100:.2f}%")
print(f"Vectores clase Real(0): {n_support_vectors[0]}")
print(f"Vectores clase IA(1): {n_support_vectors[1]}")

```

La interpretación de estos valores es reveladora:

- Un bajo porcentaje de vectores de soporte (< 30 %) indica que la frontera de decisión es relativamente simple y está bien definida por pocos ejemplos.
- Si una clase tiene significativamente más vectores de soporte, su región de decisión es más compleja o presenta mayor solapamiento.
- Los vectores de soporte son candidatos naturales para un análisis cualitativo: ¿qué tienen en común los audios más difíciles de clasificar?

Métricas de evaluación

Se emplearon las mismas métricas que en Random Forest y LightGBM:

- **Accuracy:** Proporción de predicciones correctas.
- **Precision:** Proporción de predicciones positivas correctas.
- **Recall:** Proporción de positivos reales correctamente identificados.
- **F1-Score:** Media armónica de precisión y recall.
- **AUC-ROC:** Área bajo la curva ROC.
- **MCC:** Coeficiente de correlación de Matthews.

La función de evaluación implementada es la misma que para los modelos anteriores.

3.4.6. AASIST

Como hemos comentado antes, AASIST produce una predicción a partir del audio crudo por lo que el primer paso es definir las rutas a los audios.

Después, se lee el contenido del **archivo .conf** del modelo. Para ello, hemos creado una función que busca el elemento pasado por parámetro y devuelve el bloque superior que contiene ese elemento junto con los elementos al mismo nivel. Esto nos permite construir una variable, que vamos a llamar args, con los siguientes campos:

- **first_conv:** configuración del **kernel** de la primera capa de convolución, es decir, cuántas muestras de audio se utilizan para cada filtro. En este caso, 128.
- **filts:** es un array de elementos siendo el primero el número de **filtros** en la primera capa de convolución. Los siguientes elementos son pares para cada bloque residual con el número de filtros de entrada y de salida.
- **gat_dims:** tamaño del **embedding** que representa cada nodo. Tiene dos valores que hacen referencia al tamaño al construir los grafos de atención y al tamaño en las fases de “HS-GAL” + “pooling” respectivamente.

- **pool_ratios**: se usa en la técnica de “graph pooling” y significa el **ratio de reducción de nodos** en cada capa. Los dos primeros valores se usan para reducir los grafos espectral y temporal respectivamente antes de combinarlos en el grafo heterogéneo. El siguiente valor se usa para reducir el grafo heterogéneo después de cada capa HS-GAL. Aunque existe un cuarto valor, en el modelo final no se usa.
- **temperatures**: controla lo suave o agresiva que es la **atención** en cada fase. Cuanto más bajo es este parámetro, mayor peso se concentra en pocos nodos vecinos.

Con args ya creado, la usamos para instanciar el modelo. Posteriormente, se usa el checkpoint para cargar los pesos preentrenados.

El siguiente paso es definir las funciones de inferencia. Para esto, nos apoyamos primero en dos funciones auxiliares, una que convierte los audios a un **formato estándar**, un solo canal y 16 kHz, y otra que crea una **ventana** para recorrer audios largos. Esta última es importante ya que AASIST está diseñado para recibir segmentos de longitud de unos 4 segundos. Con esto preparado, las tres funciones de inferencia las creamos para ver si conseguimos mejores resultados alterando un un poco el proceso y se describen a continuación:

- **average_windows**: esta función devuelve la media de sumar las predicciones de cada ventana calculadas de forma independiente.
- **score_without_windows**: esta función devuelve solamente la puntuación del segmento inicial del audio en archivos largos o del audio en su totalidad en el caso contrario.
- **average_logits**: esta función fusiona todas las ventana sumando sus logits antes de calcular una única probabilidad.

Finalmente, se aplica el modelo y se vuelcan los resultados en un csv con el nombre del audio, la probabilidad de que sea “bonafide” y su duración. Para esto, se recorre cada audio del dataset, se le aplica una de las funciones de inferencia y se escribe la información en el csv.

3.5. Modelos de explicación