

TFG - XplicaVoz

Jorge Aured Zarzoso, Germán Bravo Quintián,
Rafael López Rodríguez, Iván Pastor Sacristán

13 de abril de 2026

Índice

1. Introducción	3
2. Estado del arte	3
2.1. Modelos de clasificación	3
2.1.1. Perceptrón multicapa - MLP	4
2.1.2. Wav2Vec2	4
2.1.3. Random Forest	5
2.1.4. LightGBM	7
2.1.5. Support Vector Machines (SVM)	11
2.1.6. AASIST	14
2.1.7. Regresión Logística	16
2.1.8. K-Nearest Neighbors (k-NN)	17
2.2. Modelos de explicación	18
2.2.1. SHAP	19
2.2.2. LIME	19
2.2.3. Grad-CAM	20
2.2.4. Integrated Gradients	20
2.2.5. DICE	21
2.2.6. SincNet	21
2.2.7. ProtoPNet	21
2.2.8. Occlusion	22
2.2.9. RISE	22
3. Metodología	23
3.1. Dataset	23
3.2. Extracción de características	24
3.3. Métricas de evaluación	28
3.4. Modelos	31
3.4.1. Random Forest	32
3.4.2. LightGBM	43
3.4.3. Support Vector Machine (SVM)	45

3.4.4.	AASIST	48
3.4.5.	Perceptrón multicapa	57
3.4.6.	Wav2Vec2	62
3.4.7.	Regresión Logística	84
3.4.8.	KNN	86
3.5.	Resultados	89
3.5.1.	Random Forest	89
3.5.2.	LightGBM	91
3.5.3.	Support Vector Machine	94
3.5.4.	AASIST	97
3.5.5.	Perceptrón Multicapa	97
3.5.6.	Wav2Vec2	97
3.5.7.	Regresión Logística	97
3.5.8.	KNN	97
3.6.	Discusión de los resultados	97
4.	Trabajo Individual	97
4.0.1.	Iván Pastor Sacristán	97
4.0.2.	Jorge Aured Zarzoso	98
4.0.3.	Germán Bravo Quintián	100

1. Introducción

En los últimos años, hemos visto un aumento considerable en el uso de la IA para suplantar la identidad de alguien de forma maliciosa clonando su voz. Estos son los conocidos *deepfakes*. El reconocimiento de dichos *deepfakes* es de vital importancia, pues suponen una gran amenaza. Por otro lado, las técnicas de detección de *deepfakes* no han avanzado al mismo ritmo, y esto lo vemos en la gran cantidad de estafas que se producen de este tipo.

Además, las personas ya no somos capaces de diferenciar entre una voz real y una generada, como se ve en [? ?], donde hacen sendos estudios exponiendo a personas reales a diversos audios, algunos reales, algunos generados y algunos que clonan voces reales. En dichos estudios, se ve que los que son 100 % generados nos cuesta poco detectarlos, pero entre los reales y los clones no diferenciamos bien, y rondamos el 60 % de precisión clasificando dichas voces en reales o falsas. Por esto, no podemos fiarnos más de nuestras capacidades a la hora de diferenciar cuando una voz es real o no.

En este texto, se proponen varias técnicas que podrían ser útiles para la detección de audios generados por IA. Para esta tarea es fundamental sacar las características de la voz, así como gráficas, para poder entrenar los modelos con dichos datos. Entre los audios debe haber tanto reales como generados, y estar medianamente equilibrados, para que los modelos aprendan las diferencias, y así sepan clasificar un audio que nunca han visto.

Pero el rendimiento del modelo de clasificación no es lo único que nos interesa. Hoy en día, los modelos de IA se han convertido en *cajas negras*, donde no sabemos cómo hace las predicciones, dando lugar a problemas de confianza de los humanos respecto de dichas predicciones, como es en el ámbito médico o ingenieril, donde las decisiones que tomen las IAs deben ser precisas, puesto que la vida de las personas puede estar en juego. Para solventar este problema, ha surgido la IA explicable (XAI), la cual toma dichos modelos *caja negra* y da una explicación de qué características de los datos afectan más a la decisión del modelo. En esta investigación, vamos a aplicar XAI para ver qué afecta más a la clasificación de los audios dentro de los distintos grupos que mencionamos antes.

2. Estado del arte

2.1. Modelos de clasificación

La detección de audio deepfake se fundamenta en la capacidad de los algoritmos para discriminar entre patrones biométricos naturales y artefactos generados sintéticamente. Dado que los métodos de falsificación varían en complejidad desde técnicas de concatenación simple hasta modelos de difusión avanzados, es necesario abordar el problema mediante diversos enfoques de aprendizaje automático.

A continuación se describen los modelos de clasificación que se usan actualmente para

este estudio de audios fake, abarcando desde algoritmos estadísticos clásicos y modelos basados en árboles, hasta arquitecturas de aprendizaje profundo más complejas.

2.1.1. Perceptrón multicapa - MLP

Un perceptrón multicapa es una red neuronal que se utiliza en aprendizaje supervisado en el campo del aprendizaje automático. El MLP está compuesto por múltiples capas de neuronas interconectadas, en las que las salidas de las neuronas de una capa se convierten en entradas para la siguiente capa. La primera capa se llama capa de entrada, la última capa se llama capa de salida y las capas intermedias se llaman capas ocultas. El MLP presenta una gran capacidad para modelar relaciones no lineales y para generalizar. Como punto negativo del uso de este modelo, podemos remarcar la necesidad de un gran conjunto de datos de entrenamiento para evitar el sobreajuste. Por último, cabe resaltar que los MLP's fueron los precursores de otras redes neuronales más complejas como la redes convolucionales y las redes recurrentes. (Fuente: <https://gamco.es/glosario/perceptron-multicapa-mlp/>)

2.1.2. Wav2Vec2

Wav2Vec2 es un modelo de aprendizaje profundo end-to-end para procesamiento de voz que permite obtener representaciones acústicas de alta calidad directamente desde la señal cruda de audio, sin necesidad de características manuales. Fue propuesto por Meta en 2020.

Como parte del entrenamiento, el modelo aprende unidades de habla discreta mediante un gumbel softmax (técnica utilizada en redes neuronales para aproximar el muestreo de distribuciones categóricas discretas de forma diferenciable) para representar las representaciones latentes en la tarea contrastiva.

Tras el preentrenamiento en el habla no etiquetada, el modelo se ajusta con datos etiquetados con una pérdida de Clasificación Temporal Conexiónista (CTC: algoritmo y función de pérdida utilizado en redes neuronales profundas para entrenar modelos de aprendizaje automático en tareas de modelado de secuencias cuando los datos de entrada y salida no están alineados) para ser utilizada en tareas posteriores de reconocimiento de voz.

El modelo se compone de un codificador de características convolucional multicapa que toma la entrada cruda de audio y devuelve representaciones latentes de voz para T instantes de tiempo. Luego son pasados a un transformer para construir representaciones capturando información de toda la secuencia.

El codificador de características consiste en muchos bloques convolucionales seguidos de una capa de normalización y una función de activación GELU (Gaussian Error Linear Unit: pondera las entradas por su probabilidad bajo una distribución gaussiana suavizando su activación cerca de 0).

También realiza representaciones contextualizadas con Transformers siendo que la salida del codificador se pasa a una red que sigue la arquitectura de un Transformer, y usa una capa convolucional que actúa como un embedding posicional relativo.

Por último, Wav2Vec2 consta de un módulo de cuantización que discretiza la salida del codificador a un conjunto finito de representaciones del habla. Esta cuantización se hace con la técnica de Gumbel Softmax (Gumbel Softmax: técnica de reparameterización que aproxima muestras de una distribución categórica discreta mediante una función continua y diferenciable).

El entrenamiento del modelo se basa en un preentrenamiento con enmascaramiento en donde se toma la señal de audio y se transforma en representaciones latentes mediante un encoder. Esto se hace por bloques consecutivos de tamaño M que pueden solaparse.

Para cada paso de tiempo enmascarado, el modelo debe identificar la representación latente cuantizada correcta. Para ello, usa una pérdida contrastiva basada en la similitud del coseno.

También se realiza un fine-tuning supervisado para reconocimiento automático del habla usando CTC como función de pérdida y aplicando una versión de SpecAugment (técnica de aumento de datos diseñada específicamente para el reconocimiento automático de voz) para evitar sobreajuste.

Fuente(<https://arxiv.org/pdf/2006.11477>)

2.1.3. Random Forest

Random Forest es un algoritmo de aprendizaje automático basado en la combinación de múltiples árboles de decisión, propuesto por Leo Breiman en 2001 [?]. Pertenecce a la familia de métodos *ensemble*, que mejoran el rendimiento agregando las predicciones de varios modelos más simples.

Arquitectura y funcionamiento

El algoritmo construye un “bosque” de árboles de decisión donde cada árbol se entrena de forma ligeramente diferente, introduciendo aleatoriedad controlada en dos niveles:

- **Bootstrap aggregating (bagging):** Cada árbol se entrena con una muestra aleatoria del conjunto de datos original, permitiendo repeticiones. Esto significa que algunos ejemplos aparecen varias veces en el entrenamiento de un árbol, mientras que otros (alrededor de un tercio) quedan fuera (*out-of-bag*) y sirven para validación interna.
- **Selección aleatoria de características:** En cada división de un nodo del árbol, solo se considera un subconjunto aleatorio de todas las características disponibles. Esto evita que unas pocas características muy fuertes dominen todas las decisiones.

Proceso de clasificación

Cuando llega una nueva muestra de audio con sus características (formantes, MFCC, etc.), cada árbol del bosque realiza su propia clasificación. La predicción final

se decide por mayoría:

- Si la mayoría de los árboles clasifican el audio como deepfake, la predicción final es deepfake.
- Si la mayoría lo clasifica como real, la predicción final es real.

Este mecanismo de votación reduce drásticamente la varianza del modelo: aunque un árbol individual pueda cometer errores, el consenso del bosque suele ser acertado. Esto se puede ver en la siguiente imagen:




Figura 1: Voto por mayoría en el “bosque”.

Hiperparámetros

Vamos a hablar de los hiperparámetros que tiene Random Forest y para qué sirven o qué representan, ya que conocerlos es crucial a la hora de usar un modelo.

- **n_estimators**: Define la cantidad de árboles de decisión que conforman el bosque aleatorio. A medida que aumentamos este número, el modelo tiende a mejorar su rendimiento porque se promedian más predicciones individuales, lo que reduce la varianza y el riesgo de sobreajuste. Sin embargo, a partir de cierto punto (generalmente entre 100 y 500 árboles) los beneficios se vuelven marginales, mientras que el tiempo de entrenamiento y predicción sigue incrementándose linealmente, por lo que es recomendable encontrar un equilibrio entre rendimiento y eficiencia computacional.
- **max_depth**: Controla la profundidad máxima que pueden alcanzar los árboles individuales dentro del bosque. Si no se establece un límite (None), los árboles crecerán hasta que todas las hojas sean puras o contengan el mínimo de muestras permitido, lo que puede llevar a un sobreajuste en datos de entrenamiento. Por el

contrario, valores pequeños limitan la complejidad del modelo, actuando como una forma de regularización que previene el sobreajuste pero podría aumentar el sesgo si la profundidad es demasiado restrictiva.

- **min_samples_split:** Determina el número mínimo de muestras requeridas para dividir un nodo interno durante la construcción del árbol. Valores más altos hacen que el árbol sea más conservador al crear nuevas ramas, ya que necesita más evidencia (muestras) para justificar una división. Esto ayuda a prevenir el sobreajuste al evitar que el modelo aprenda patrones demasiado específicos de grupos pequeños de datos, aunque valores excesivamente altos podrían impedir que el modelo capture patrones importantes.
- **max_features:** Especifica cuántas características debe considerar cada árbol al buscar la mejor división en cada nodo. Al limitar las características disponibles, se fuerza a los árboles a ser más diversos entre sí, lo que reduce la correlación entre ellos y mejora la capacidad de generalización del conjunto. Para clasificación, el valor recomendado suele ser la raíz cuadrada del número total de características ($\sqrt{n}$), mientras que para regresión se suele usar un tercio del total. Valores más pequeños aumentan la aleatoriedad y la diversidad, mientras que valores más grandes hacen que los árboles sean más similares entre sí.
- **max_samples:** Cuando se utiliza muestreo bootstrap (que es el comportamiento por defecto), este parámetro controla el tamaño de la muestra aleatoria que se toma del conjunto de datos original para entrenar cada árbol. Valores inferiores a 1.0 (por ejemplo, 0.7) significan que cada árbol se entrena solo con el 70 % de los datos, lo que aumenta la diversidad entre los árboles y fortalece la capacidad de generalización del bosque. Este parámetro es especialmente útil cuando se trabaja con conjuntos de datos muy grandes o cuando se sospecha que los árboles individuales están demasiado correlacionados.

Ventajas específicas para detección de deepfakes

- **Robustez ante ruido:** Las características de audio pueden contener variaciones por condiciones de grabación; Random Forest maneja bien estos datos ruidosos.
- **No requiere normalización:** A diferencia de redes neuronales o SVM, no es necesario escalar las características, lo que simplifica el pipeline.
- **Interpretabilidad:** El algoritmo proporciona una medida de importancia de cada característica, permitiendo identificar qué parámetros acústicos son más discriminativos entre voz real y sintética.
- **Resistencia al overfitting:** La combinación de bagging y aleatoriedad evita que el modelo memorice el conjunto de entrenamiento.

2.1.4. LightGBM

LightGBM (*Light Gradient Boosting Machine*) es un framework de gradient boosting desarrollado por Microsoft en 2017 [?] que optimiza el proceso de entrenamiento

mediante innovaciones en la forma de construir los árboles y muestrear los datos. Mientras que Random Forest construye árboles de forma independiente y paralela, LightGBM los construye secuencialmente, donde cada nuevo árbol se especializa en corregir los errores de los anteriores.

Arquitectura y funcionamiento

El proceso de boosting funciona de la siguiente manera:

1. Se entrena un primer árbol simple que intenta clasificar las instancias según las etiquetas.
2. Se identifican las que este primer árbol clasificó incorrectamente.
3. Se entrena un segundo árbol enfocado específicamente en esos casos difíciles.
4. Se combinan ambos árboles para mejorar la precisión global.
5. El proceso se repite construyendo decenas o cientos de árboles, cada uno corrigiendo los residuos de los anteriores.

Innovaciones clave

- **Crecimiento por hoja (*leaf-wise*):** Los árboles tradicionales crecen nivel por nivel (balanceados). LightGBM, en cambio, crece expandiendo la hoja que más puede reducir el error en cada paso, lo que produce árboles más profundos en las regiones problemáticas y más eficientes en las fáciles.
- **Muestreo basado en gradientes (*GOSS*):** Durante el entrenamiento, LightGBM identifica qué instancias tienen mayor error y las prioriza. Las instancias con error pequeño se muestrean aleatoriamente para reducir el costo computacional. Esto permite entrenar con datasets grandes sin procesar toda la información redundante.
- **Agrupación de características (*EFB*):** LightGBM agrupa las características que no suelen tomar valores iguales a 0 para reducir la dimensionalidad, acelerando el entrenamiento sin pérdida de información significativa.

Proceso de clasificación

Cuando una nueva instancia llega para ser clasificada:

- Pasa secuencialmente por todos los árboles construidos.
- Cada árbol aporta una corrección o ajuste a la predicción anterior.
- La suma ponderada de todas las contribuciones produce la clasificación final (probabilidad de pertenecer a una clase).

Hiperparámetros

Vamos a explicar los hiperparámetros más importantes en los modelos LightGBM.

- **max_depth**: Limita explícitamente la profundidad máxima que pueden alcanzar los árboles durante el entrenamiento. Es especialmente importante cuando se trabaja con conjuntos de datos pequeños, ya que los árboles poco profundos tienen menos probabilidad de sufrir sobreajuste. Si max_depth es menor o igual a cero, significa que no hay límite para la profundidad máxima, lo que puede ser arriesgado con datos limitados.
- **num_leaves**: Controla la complejidad del modelo en LightGBM, ya que determina el número máximo de hojas por árbol. A diferencia de otros algoritmos que crecen por niveles, LightGBM utiliza un crecimiento por hojas (leaf-wise), lo que significa que elige la hoja con la mayor pérdida delta para crecer, permitiendo una convergencia más rápida y mayor precisión. Sin embargo, este enfoque puede provocar sobreajuste si no se configura adecuadamente. En la práctica, el valor de num_leaves debe ser menor que 2 elevado a la max_depth para evitar que los árboles crezcan demasiado profundo. Por ejemplo, si max_depth=7, establecer num_leaves en 70 u 80 suele dar mejor precisión que usar 127.
- **min_data_in_leaf**: Define la cantidad mínima de observaciones que debe contener una hoja para que sea creada. Configurarla con un valor grande (cientos o miles para datasets grandes) evita que los árboles crezcan demasiado profundo y aprendan patrones demasiado específicos de grupos muy pequeños de datos. Sin embargo, si el valor es excesivamente alto, puede provocar underfitting al impedir que el modelo capture patrones importantes. Su valor óptimo depende del número de muestras de entrenamiento y de num_leaves.
- **learning_rate**: También conocido como shrinkage_rate o eta η , este parámetro controla la velocidad a la que se actualizan los pesos del modelo después de cada iteración de boosting. Valores pequeños (por ejemplo, 0.01 o 0.05) hacen que el modelo aprenda más lentamente pero generalmente logran mejor precisión, aunque requieren más iteraciones (num_iterations) para converger. Por el contrario, valores altos (cerca de 1.0) aceleran el aprendizaje pero aumentan el riesgo de sobreajuste y pueden hacer que el modelo oscile alrededor del óptimo sin alcanzarlo. La práctica común es usar learning_rate bajos junto con un mayor número de iteraciones.
- **n_estimators**: Determina el número máximo de iteraciones de boosting que se realizarán, lo que equivale al número de árboles que se construirán. Para problemas de clasificación multiclase, LightGBM construye internamente num_class * num_iterations árboles. El valor predeterminado suele ser 100, pero puede aumentarse para mejorar el rendimiento, siempre ajustando también la tasa de aprendizaje. Una estrategia inteligente es combinarlo con early_stopping_rounds, que detiene el entrenamiento si la métrica de validación no mejora durante varias rondas consecutivas, ahorrando tiempo computacional y previniendo sobreajuste.
- **feature_fraction**: Especifica la fracción de características que se seleccionarán

aleatoriamente para construir cada árbol. Por ejemplo, `feature_fraction=0.8` significa que cada árbol utilizará aleatoriamente el 80 % de las variables disponibles. Esto aumenta la diversidad entre los árboles, reduce la correlación entre ellos y ayuda a prevenir el sobreajuste, además de acelerar el entrenamiento al considerar menos splits posibles. Valores típicos oscilan entre 0.5 y 0.9, siendo 1.0 el valor por defecto que significa que se usan todas las características.

- **bagging_fraction:** Similar a `feature_fraction`, pero aplicado al muestreo de datos en lugar de características. Este parámetro selecciona aleatoriamente una fracción de los datos sin reemplazo para entrenar cada árbol, lo que también se conoce como bagging. Para que sea efectivo, debe acompañarse de `bagging_freq`, que especifica cada cuántas iteraciones se realiza un nuevo muestreo. Por ejemplo, con `bagging_fraction=0.7` y `bagging_freq=5`, cada 5 iteraciones se toma una muestra aleatoria del 70 % de los datos. Esta técnica reduce el tiempo de entrenamiento y ayuda a combatir el sobreajuste.
- **reg_alpha y reg_lambda:** Estos parámetros aplican regularización L1 (lasso) y L2 (ridge) respectivamente para controlar la complejidad del modelo y prevenir el sobreajuste. La regularización añade una penalización a la función de pérdida por tener valores de parámetros grandes, lo que favorece modelos más simples y generalizables. Por defecto valen 0, lo que significa que no se aplica regularización. Aumentar estos valores puede ser especialmente útil cuando se sospecha de sobreajuste o cuando se trabaja con muchas características redundantes.
- **min_gain_to_split:** Establece la ganancia mínima necesaria para realizar una división en un nodo del árbol. Por defecto es 0, lo que significa que cualquier mejora, por pequeña que sea, justifica una división. Aumentar este valor hace que el modelo sea más conservador, ya que solo se dividirán nodos cuando la reducción en la pérdida sea significativa. Esto puede acelerar el entrenamiento al reducir el número de divisiones y también actuar como regularización, previniendo que el modelo aprenda patrones muy sutiles que podrían ser ruido.
- **objective:** Define la tarea de aprendizaje que debe realizar el modelo y la función de pérdida que se optimizará durante el entrenamiento. Es uno de los parámetros más importantes porque determina fundamentalmente cómo se evalúa el error y cómo se actualizan los pesos. Para problemas de regresión, los valores más comunes son 'regression' (error cuadrático medio L2), 'regression_l1' (error absoluto L1, más robusto ante outliers) y 'huber' (combinación híbrida de L1 y L2 para datos con ruido). Para clasificación binaria se usa 'binary' (pérdida logística), para clasificación multiclase se usa 'multiclass' y para ranking se usa 'lambda_rank'. En la práctica, elegir el objective correcto según el problema es el primer paso antes de ajustar cualquier otro parámetro.
- **metric:** Especifica qué métrica se utilizará para evaluar el rendimiento del modelo durante el entrenamiento, tanto para mostrar progreso como para implementar early stopping. A diferencia del objective (que es la función que el modelo optimiza), la métrica es solo para evaluación y puede ser diferente de la función de pérdida. LightGBM incluye múltiples métricas predefinidas: para regresión

están 'mse', 'mae', 'rmse'; para clasificación binaria 'binary_logloss' (pérdida logarítmica) y 'binary_error' (tasa de error); para clasificación multiclase 'multi_logloss' y 'multi_error'; y para ranking 'ndcg' y 'map'. Algunas métricas como 'auc' son mayores cuanto mejores, mientras que otras como 'rmse' son mejores cuanto menores.

- **boosting_type:** Determina el algoritmo específico que LightGBM utilizará para construir los árboles secuencialmente. Las opciones principales son: 'gbdt' (Gradient Boosting Decision Tree), que es el método tradicional y el valor por defecto, donde cada árbol corrige los errores del anterior; 'dart' (Dropouts meet Multiple Additive Regression Trees), que utiliza un enfoque inspirado en dropout de redes neuronales, apagando aleatoriamente algunos árboles durante el entrenamiento para reducir el sobreajuste; 'goss' (Gradient-based One-Side Sampling), que acelera el entrenamiento muestreando selectivamente las instancias con gradientes grandes; y 'rf' (Random Forest), que cambia el comportamiento a un verdadero bosque aleatorio donde los árboles se construyen independientemente sin boosting. La elección afecta tanto la velocidad de entrenamiento como la precisión y el riesgo de sobreajuste.

Ventajas específicas para detección de deepfakes

- **Alta precisión:** El enfoque secuencial de corrección de errores suele superar a Random Forest en problemas complejos como la detección de deepfakes.
- **Eficiencia computacional:** El muestreo inteligente permite entrenar con grandes volúmenes de audios en menos tiempo que otros métodos de boosting.
- **Manejo de desequilibrios:** Si existen desbalances entre clases, LightGBM incorpora mecanismos para ponderar las muestras adecuadamente.
- **Early stopping:** Se puede configurar para que detenga el entrenamiento cuando añadir más árboles no mejora la validación, evitando overfitting.

2.1.5. Support Vector Machines (SVM)

Las Máquinas de Vectores de Soporte (*Support Vector Machines*, SVM) son un conjunto de algoritmos de aprendizaje supervisado desarrollados por Vladimir Vapnik y su equipo en AT&T Bell Laboratories durante la década de 1990 [?]. Originalmente diseñadas para clasificación binaria, las SVM se han convertido en uno de los métodos más robustos y teóricamente fundamentados del aprendizaje automático.

Fundamento conceptual: El hiperplano óptimo

El objetivo fundamental de una SVM es encontrar un hiperplano que separe las dos clases (en nuestro caso, voces reales y voces generadas por IA) con el máximo margen posible. Para comprender este concepto, es útil visualizar un problema simple en dos dimensiones:

- Imaginemos que representamos cada audio como un punto en un plano, donde los ejes son dos características (por ejemplo, el primer formante y el primer MFCC).
- Las voces reales se agrupan en una región del plano y las generadas por IA en otra.
- Un hiperplano en dos dimensiones es simplemente una línea recta que intenta separar ambos grupos.

La clave de SVM reside en que no cualquier línea divisora es válida: el algoritmo busca aquella que maximiza la distancia (margen) entre la línea y los puntos más cercanos de cada clase. Estos puntos críticos, que “sostienen” el margen, reciben el nombre de **vectores de soporte** (*support vectors*), de donde el algoritmo toma su nombre.

Funcionamiento del algoritmo

El proceso de entrenamiento de una SVM puede entenderse en los siguientes pasos:

1. **Identificación de vectores de soporte:** El algoritmo examina todos los puntos de entrenamiento (instancias) e identifica aquellas que son más difíciles de clasificar, es decir, las que están más cerca de la frontera entre clases.
2. **Maximización del margen:** A partir de estos vectores de soporte, la SVM calcula el hiperplano que maximiza la distancia a ambos lados. Este margen máximo proporciona la mejor capacidad de generalización: cuanto más ancho sea el margen, menor será la probabilidad de error al clasificar nuevas instancias.
3. **Clasificación de nuevas muestras:** Una vez entrenado el modelo, para clasificar una nueva instancia, simplemente se calcula a qué lado del hiperplano se sitúa.

El truco del kernel: Separando lo inseparable

Uno de los mayores desafíos en la clasificación es que las instancias rara vez son linealmente separables en el espacio original de características. Es decir, no existe una línea recta (o hiperplano) que pueda separarlas perfectamente. Para abordar esta limitación, las SVM introducen el concepto de **kernel** o núcleo.

El *truco del kernel* (*kernel trick*) funciona de la siguiente manera conceptual:

- Los datos originales (no separables linealmente) se transforman implícitamente a un espacio de mayor dimensionalidad mediante una función matemática.
- En este nuevo espacio, es posible que los datos sí sean linealmente separables.
- La magia del kernel es que realiza esta transformación sin necesidad de calcular explícitamente las coordenadas en el espacio de alta dimensión, lo que sería computacionalmente costoso.

Los kernels más comúnmente utilizados son:

- **Kernel lineal:** Asume que los datos son aproximadamente separables por un hiperplano. Útil cuando el número de características es muy grande.

- **Kernel polinomial:** Crea fronteras de decisión curvas mediante combinaciones polinómicas de las características originales.
- **Kernel RBF (*Radial Basis Function*):** Es el más utilizado en muchos problemas. Proyecta los datos a un espacio de dimensionalidad infinita, permitiendo fronteras de decisión altamente complejas y no lineales. Se basa en la similitud entre muestras medida por distancia euclidiana:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$$

donde γ controla la influencia de cada muestra: un valor pequeño considera vecindarios amplios (frontera más suave), mientras que un valor grande se enfoca en vecindarios reducidos (frontera más ajustada a los datos).

Hiperparámetros

Vamos a ver cuáles son los hiperparámetros más importantes en los SVM.

- **C:** Controla el equilibrio entre tener un margen amplio y clasificar correctamente los puntos de entrenamiento. Un valor bajo de C busca un margen grande aunque se cometan algunos errores (modelo más generalista). Un valor alto de C penaliza fuertemente los errores, ajustándose más a los datos de entrenamiento (riesgo de overfitting).
- **kernel:** Es la función que transforma los datos a un espacio de mayor dimensión donde puedan ser separables linealmente. Los kernels más comunes son: lineal (recomendado para datos con muchas características o problemas aproximadamente lineales), polinomial (permite curvas más complejas mediante el grado del polinomio), y RBF o radial (el más utilizado por defecto, capaz de crear límites de decisión muy flexibles y adaptarse a diferentes formas de los datos). La elección del kernel determina fundamentalmente la capacidad del modelo para encontrar patrones complejos.
- **gamma γ :** Específico de kernels no lineales (RBF, sigmoide o polinomial). define cuánta influencia tiene un solo punto de entrenamiento: valores bajos significan que cada punto tiene un alcance amplio, produciendo límites de decisión más suaves y generales; valores altos hacen que cada punto influya solo en su vecindario cercano, lo que puede generar límites muy ajustados a los datos de entrenamiento pero con alto riesgo de sobreajuste.
- **degree:** Cuando se utiliza el kernel polinomial, este parámetro especifica el grado del polinomio usado para transformar los datos. Un grado mayor permite capturar relaciones más complejas y no lineales, pero también aumenta el riesgo de sobreajuste y el costo computacional. Normalmente se utilizan grados bajos (2, 3 o 4) porque valores muy altos tienden a producir modelos inestables y difíciles de generalizar.

- **coef0**: Este parámetro es relevante para los kernels polinomial y sigmoide, donde actúa como un término independiente en la función del kernel. En el kernel polinomial, coef0 controla cuánto influyen los términos de menor grado respecto a los de mayor grado; en el sigmoide, ayuda a definir la forma de la función de activación. Aunque no es tan crítico como C o gamma, puede necesitar ajuste para optimizar el rendimiento del modelo.
- **probability**: Este parámetro booleano determina si el modelo SVM debe calibrarse para proporcionar estimaciones de probabilidad junto con las predicciones de clase. Activarlo (True) permite obtener la probabilidad de pertenencia a cada clase mediante validación cruzada interna, lo cual es útil para interpretar la confianza del modelo. Sin embargo, este proceso aumenta significativamente el tiempo de entrenamiento y puede afectar ligeramente la precisión de las clasificaciones.

Ventajas específicas para detección de deepfakes

- **Fundamento teórico sólido**: A diferencia de otros métodos heurísticos, SVM está basada en la teoría de optimización convexa, lo que garantiza que la solución encontrada es óptima (máximo margen global).
- **Eficaz en espacios de alta dimensión**: Las características de audio pueden generar vectores de gran dimensionalidad (decenas o cientos de coeficientes). SVM maneja bien esta situación sin colapsar por la maldición de la dimensionalidad.
- **Robustez ante overfitting**: La maximización del margen proporciona una regularización natural que mejora la generalización, crucial cuando se trabaja con datasets limitados de voces deepfake.
- **Versatilidad mediante kernels**: La capacidad de elegir diferentes kernels permite adaptar el modelo a la estructura no lineal de los datos de audio sin necesidad de transformaciones manuales.
- **Interpretabilidad limitada pero útil**: Aunque no tan interpretable como los árboles de decisión, el análisis de los vectores de soporte puede revelar qué audios son más representativos o ambiguos en la frontera de decisión.

2.1.6. AASIST

AASIST (*Audio Anti-Spoofing usign Integrated Spectro-Temporal graph attention networks*) es un modelo propuesto por Jee-weon Jung, Hee-Soo Heo, Hemlata Tak, Hye-jin Shim, Joon Son Chung, Bong-Jin Lee, Ha-Jin Yu y Nicholas Evans en 2022. La principal motivación para el desarrollo de este clasificador surge de que los artefactos que sirven para diferenciar audios falsificados de audios bona fide se suelen encontrar en intervalos temporales o espectrales. Por esto, en la práctica se usaban ensembles costosos, desde el punto de vista computacional, donde cada subsistema se centraba en ciertos artefactos. AASIST consigue reemplazar ese enfoque por un único sistema que combina información espectro-temporal buscando robustez ante diversos tipos de ataques.

Arquitectura y funcionamiento

El modelo tiene las siguientes fases:

1. Extracción de características a partir del audio crudo:
 - Se usa un **encoder** basado en RawNet2 que acaba generando un mapa de características F , $F \in \mathbb{R}^{C \times S \times T}$ siendo C , número de canales, S , número de bins espectrales y T , longitud temporal.
 - Para ello, primero, se pasa el audio por una primera capa *sinc-convolution* con 70 filtros. La diferencia frente al RawNet2 original, es que en AASIST se interpreta la salida de esta capa como una “imagen” 2D de 1 canal.
 - A continuación, esta primera representación se pasa por seis bloques residuales con **pre-activación** que van comprimiendo y transformando la información útil para tener una representación lo más compacta posible.
2. Posteriormente, se generan dos **grafos completos** que modelan, de forma independiente, los dominios temporal y espectral, siendo G_t y G_s respectivamente. A cada grafo, se le aplica “**graph pooling**” para reducir el número de nodos, conservando los más relevantes lo que permite bajar el coste computacional posterior.
3. Ambos grafos se combinan en un tercer grafo, G_{st} con $N_t + N_s$ nodos entre los que se generan todas las aristas nuevas posibles en ambas direcciones, manteniendo las aristas de los grafos anteriores.
4. Bloque HS-GAL + pooling:
 - Se aplica **atención heterogénea** usando uno de los tres vectores de proyección según la relación entre los tipos de los nodos entre los que se hace la relación.
 - Un (**stack node**), conectado de forma unidireccional a todos los nodos, que va acumulando la información espectro-temporal entre sucesivas capas HS-GAL.
 - Tras cada HS-GAL, se aplica otra vez la técnica “**graph pooling**” con el mismo objetivo anterior.
5. A continuación de crear el grafo G_{st} , se aplica la operación MGO(*Max Graph Operation*) que usa las técnicas del punto anterior. De forma paralela, se procesan dos ramas en las que se ejecutan consecutivamente dos secuencias HS-GAL-pooling. Dentro de cada rama, el “stack node” se propaga de la primera HS-GAL a la segunda. Finalmente, se combinan las salidas de ambas ramas usando un máximo elemento a elemento.
6. Por último, usando las operaciones “**max**” y “**average**” sobre cada subgrafo final(temporal y espectral), se generan 4 vectores que se combinan con el “stack node” y se pasan a la capa de salida.

Innovaciones clave

- **HS-GAL**: una capa de atención, que permite ir integrando simultaneamente ambos grafos, combinada con un “stack” node para ir acumulando información espectro-temporal
- **MGO**: un método con dos ramas aplicando paralelamente HS-GAL más una fase de “pooling” lo que permite que cada secuencia pueda aprender distintos grupos de artefactos.
- **Nuevo esquema de readout**: permite concatenar la información contenida en el “stack node” con las estadísticas sacadas de la operaciones “max” y “average” finales.

Ventajas específicas para detección de deepfakes

- **Integración espectro-temporal**: al modelar conjuntamente los grafos temporal y espectral en un grafo heterogéneo, permite encontrar información cruzada que se podría perder si se tratara por separado.
- **Stack node**: esta técnica “acumulativa” ayuda a encontrar artefactos de spoofing cuando no están presentes en un solo nodo y se encuentran distribuidos en varios instantes o bandas.
- **Readout**: al juntar estadísticas globales(average) con evidencia puntual fuerte(max), facilita la detección de diferentes patrones de “spoofing”.
- **Ramas paralelas**: en MGO, se introducen dos ramas procesando en paralelo, permitiendo captar pistas complementarias.

2.1.7. Regresión Logística

A pesar de su nombre, la Regresión Logística es un algoritmo de clasificación lineal utilizado para predecir la probabilidad de que una instancia pertenezca a una categoría específica. Es un modelo fundamental en el aprendizaje estadístico debido a su simplicidad, eficiencia y facilidad de interpretación.

Fundamento conceptual: La función Sigmoid

A diferencia de la regresión lineal, que predice valores continuos, la regresión logística utiliza la función logística o sigmoide para confinar el resultado de una ecuación lineal entre 0 y 1. La fórmula matemática es:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Donde z es la combinación lineal de las características de entrada ($w^T x + b$). El valor resultante se interpreta como la probabilidad de pertenencia a la clase positiva. Si la probabilidad es superior a un umbral (generalmente 0.5), se clasifica como “Real”, de lo contrario, como “Deepfake”.

Proceso de entrenamiento

El modelo aprende los pesos (w) minimizando una función de pérdida denominada **Log-Loss** o entropía cruzada binaria. Este proceso se realiza mediante algoritmos de optimización como el Gradiente Descendente. Durante el entrenamiento, el modelo ajusta los coeficientes para penalizar fuertemente las predicciones que se alejan de la etiqueta real.

Ventajas específicas para detección de deepfakes

- **Interpretabilidad directa:** Los coeficientes asignados a cada característica (como el pitch o los MFCC) indican directamente la importancia y la dirección de la influencia de cada parámetro en la detección del fraude.
- **Eficiencia:** Es computacionalmente muy ligero, lo que permite procesar grandes volúmenes de datos de audio en tiempo real con recursos mínimos.
- **Línea base robusta:** Sirve como un excelente modelo de referencia (*baseline*) para comparar el rendimiento de arquitecturas más complejas.

2.1.8. K-Nearest Neighbors (k-NN)

El algoritmo de los K-Vecinos más Cercanos (k-NN) es un método de aprendizaje supervisado basado en instancias. A diferencia de otros modelos, k-NN no construye un modelo explícito durante el entrenamiento, sino que almacena todas las instancias de entrenamiento para realizar la clasificación en el momento de la consulta.

Arquitectura y funcionamiento

El principio de k-NN es la proximidad: asume que las muestras de audio con características acústicas similares pertenecerán a la misma categoría.

1. **Cálculo de distancia:** Cuando se presenta una nueva muestra de audio, el algoritmo calcula la distancia (generalmente la distancia euclidiana) entre esa muestra y todas las demás del conjunto de entrenamiento.
2. **Selección de vecinos:** Se seleccionan los k ejemplares más cercanos (donde k es un número entero definido por el usuario).
3. **Votación mayoritaria:** La muestra se asigna a la clase que sea más frecuente entre sus k vecinos.

El papel del parámetro k

La elección de k es crítica: un valor muy pequeño (ej. $k = 1$) hace que el modelo sea sensible al ruido en el audio, mientras que un valor muy grande puede suavizar demasiado las fronteras de decisión.

Ventajas específicas para detección de deepfakes

- **Sin suposiciones sobre los datos:** No asume que las características del audio sigan una distribución lineal, lo que le permite capturar patrones complejos en la distribución de artefactos sintéticos.

- **Eficacia con características bien definidas:** Si la extracción de características logra separar bien las clases, k-NN es extremadamente preciso.
- **Aprendizaje incremental:** Es fácil añadir nuevos ejemplos de ataques de audio sintético al sistema sin necesidad de reentrenar todo el modelo.

Como hemos visto, se ha presentado un espectro diverso de clasificadores que permiten abordar la detección de spoofing desde diferentes ángulos. Los modelos lineales y de vecinos cercanos, como la **Regresión Logística** y **k-NN**, ofrecen una base sólida y eficiente para el análisis de características acústicas predefinidas. Por otro lado, métodos como **Random Forest** y **LightGBM** incrementan la robustez del sistema ante datos ruidosos y relaciones no lineales.

Por último, modelos como **Wav2Vec2** y **AASIST** procesan la señal de audio cruda y modelar relaciones espectro-temporales mediante grafos y mecanismos de atención. La combinación de estos enfoques permite no solo alcanzar altas tasas de precisión, sino también adaptarnos según la disponibilidad de recursos computacionales. Esta base taxonómica de modelos constituye el núcleo operativo sobre el cual se aplicarán posteriormente las técnicas de explicabilidad.

2.2. Modelos de explicación

La adopción de modelos de aprendizaje profundo ha permitido alcanzar una precisión sin precedentes en la detección de audio sintético. Sin embargo, estos sistemas operan frecuentemente como “cajas negras”, lo que dificulta su aplicación en ámbitos críticos como en forense o ciberseguridad. La Inteligencia Artificial Explicable (XAI) surge como la solución técnica para dotar a estos modelos de transparencia, permitiendo a los expertos entender el “por qué” de cada clasificación.

A continuación, se describen las técnicas de explicabilidad, organizados según el siguiente enfoque técnico:

- **Métodos de Atribución y Perturbación:** Se analizan técnicas post-hoc, es decir, que no dependen del modelo al que se aplican, como **SHAP** y **LIME**, que permiten identificar qué características acústicas individuales son determinantes para el modelo; métodos basados en perturbaciones, como **Occlusion** y **RISE**, que miden la importancia de regiones modificando de forma controlada la entrada; y métodos basados en gradientes, como **Grad-CAM** e **Integrated Gradients**, fundamentales para visualizar la relevancia en el plano tiempo-frecuencia.
- **Razonamiento Contrafáctico:** Los modelos contrafactuales generan ejemplos alternativos a una muestra original que permiten entender la frontera de decisión del modelo estudiado (“¿qué cambios harían que este audio fake pareciera real?”). Como ejemplo de este tipo de enfoque, se explora el modelo **DiCE** que es uno de los más representativos para datos tabulares.
- **Modelos Interpretables por Diseño (Ante-hoc):** Se profundiza en arquitecturas cuya transparencia es intrínseca, como **SincNet**, que utiliza filtros con significado

físico, y **ProtoPNet**, que basa su decisión en la comparación con prototipos o ejemplos conocidos.

Además de esa clasificación, en interpretabilidad, los métodos suelen clasificarse según qué alcance tiene la explicación, a qué conjuntos de modelos se pueden aplicar y en qué momento aparece la interpretabilidad dentro del proceso de aprendizaje. Por un lado, pueden distinguirse según el alcance de la explicación en métodos **locales**, **globales** o de **cohortes**: los locales explican una predicción concreta para una muestra individual; los globales describen el comportamiento del modelo sobre el conjunto total de datos; y los “cohort explanations” analizan el comportamiento del modelo sobre un subconjunto de muestras que comparten cierta característica. Por otro lado, según a qué modelos se aplican, existen métodos “**model-agnostic**”, que pueden aplicarse a cualquier modelo porque solo necesitan acceder a sus entradas y salidas; métodos “**model-specific**”, diseñados para modelos concretos; y métodos “model-class-specific”, aplicables a una familia de modelos que comparten una estructura común, como árboles, redes neuronales o modelos lineales. Por último, también pueden clasificarse en “ante-hoc” y “post-hoc”: los métodos “**ante-hoc**” son aquellos en los que la interpretabilidad viene incorporada en el diseño del propio modelo, mientras que los “**post-hoc**” generan explicaciones una vez entrenado el modelo, sin necesidad de que este sea interpretable desde un primer momento.

2.2.1. SHAP

Basado en la teoría de juegos cooperativos, SHAP (Shapley Additive Explanations) asigna a cada característica acústica un valor de importancia que representa su contribución marginal. El valor de Shapley ϕ_i para una característica i se calcula como:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)]$$

Se trata de un método post-hoc, generalmente model-agnostic, que ofrece explicaciones locales para muestras concretas aunque usando agregación de resultados, también se pueden conseguir explicaciones globales o por cohortes. Este método es preferido en el análisis forense debido a su consistencia matemática y su capacidad para ofrecer tanto explicaciones locales como globales. Mientras que las explicaciones locales proporcionan información sobre la influencia de cada característica sobre el resultado de una muestra concreta, las explicaciones globales ofrecen una visión de la relevancia media de las características sobre el conjunto total de datos.

SHAP, aunque se pueda aplicar sobre varios tipos de datos como imágenes o texto, se utiliza principalmente sobre datos tabulares como MFCC o pitch en el caso del audio.

2.2.2. LIME

LIME (Local Interpretable Model-agnostic Explanations) es un método post-hoc, generalmente considerado agnostic, que aproxima, en el entorno de una muestra local, la superficie de decisión de un modelo de caja negra mediante un sustituto interpretable, generalmente una regresión lineal, aunque se pueden emplear otros modelos

como árboles de decisión. Puede aplicarse a varios tipos de datos como datos tabulares, imágenes o audio, siempre que la entrada pueda representarse mediante características interpretables. En el dominio del audio, el proceso se define mediante la perturbación de la entrada x (espectrogramas o marcos temporales) para observar las variaciones en la salida $f(x)$. La explicación g se obtiene minimizando:

$$\xi(x) = \arg \min_{g \in G} L(f, g, \pi_x) + \Omega(g)$$

donde L es la pérdida de fidelidad, π_x define la vecindad de la muestra y $\Omega(g)$ mide la complejidad del modelo sustituto. La explicación resultante corresponde a los parámetros del modelo interpretable, el caso de una regresión lineal, estos parámetros son sus coeficientes, que representan la importancia de cada característica en la predicción de una muestra concreta.

2.2.3. Grad-CAM

Grad-CAM (Gradient-weighted Class Activation Mapping) es un método post-hoc, de alcance local y model-class-specific ya que se usa en modelos basados en capas convolucionales. Utiliza los gradientes de la última capa convolucional para construir un mapa de calor que resalta las regiones del espectrograma que más influyen en la clasificación. Aunque es eficaz para detectar sesgos en el conjunto de datos, su baja resolución espacial a menudo dificulta la identificación de discontinuidades de fase de micro-segundos, típicas de los vocoders neuronales, es decir, modelos que generan la señal de audio a partir de representaciones acústicas como espectrogramas.

2.2.4. Integrated Gradients

Integrated Gradients (IG) es una técnica de carácter local, de interpretabilidad post-hoc y model-class-specific, ya que requiere acceder a los gradientes del modelo sobre el que se aplica. Se basa en integrar los gradientes de la función del modelo a lo largo de una trayectoria que conecta una entrada de referencia (“baseline”) x' con la entrada real x . Este método permite capturar cómo varía la sensibilidad del modelo respecto a cada característica a lo largo del recorrido, evitando problemas como la saturación del gradiente en el punto de entrada.

Siendo f la función del modelo, i una característica específica que se está observando, x' el “baseline” y α que parametriza el camino continuo entre x y x' :

$$IG_i(x) = (x_i - x'_i) \times \int_{\alpha=0}^1 \frac{\partial f(x' + \alpha(x - x'))}{\partial x_i} d\alpha$$

Tres propiedades clave de IG que justifican teóricamente su uso son:

- **Sensibilidad:** si x y x' difieren únicamente en una característica y la predicción varía, entonces esa característica debe tener una atribución no nula.

- **Invariancia de implementación:** si dos modelos implementan la misma función aunque varíen las arquitecturas o la organización de parámetros, entonces las atribuciones de IG serán iguales.
- **Complejidad:** la suma de las atribuciones de todas las características es igual a la diferencia entre la predicción del modelo para x y x' .

En audio, el “baseline” se representa como ruido blanco o como silencio.

2.2.5. DICE

DiCE (Diverse Counterfactual Explanations) es un método post-hoc, generalmente considerado agnóstico y de carácter local que permite generar ejemplos sintéticos que cambiarían la predicción del modelo. En vez de justificar la decisión obtenida como otros modelos, estos ejemplos muestran al usuario casos alternativos cercanos con una salida diferente, de modo que puede compararlos con la muestra original y observar qué cambios en la entrada serían necesarios para obtener una decisión distinta por parte del modelo. En análisis forense, esto facilita estudiar qué variaciones en los rasgos de una señal llevan al sistema a considerarla auténtica o falsificada.

DiCE se aplica principalmente sobre datos tabulares o representaciones con características interpretables en las que se pueda imponer restricciones sobre qué variables pueden ser alteradas y en qué rango.

2.2.6. SincNet

SincNet es una arquitectura ante-hoc y model-specific en la que la explicabilidad se incorpora al diseño del propio modelo. Sustituye las capas de convolución estándar por filtros de banda basados en la función Sinc, una función matemática, utilizada para construir filtros pasa-banda definidos por sus frecuencias de corte inferior y superior f_1 y f_2 . En lugar de aprender todos los coeficientes de los filtros, el modelo solo aprende estas frecuencias de corte, permitiendo una interpretación física directa de los rangos espectrales (como formantes o armónicos) que el sistema utiliza para discriminar la voz real de la sintética.

Este método opera directamente sobre la onda de audio cruda por lo que no requiere espectrogramas ni características acústicas adicionales. Esto favorece que se use para una interpretación global de los resultados.

2.2.7. ProtoPNet

ProtoPNet es una arquitectura de interpretabilidad ante-hoc y model-specific. El mecanismo de decisión de este modelo consiste en comparar regiones de la representación interna de una muestra con un conjunto de prototipos aprendidos durante el entrenamiento. Con esta idea, proporciona explicaciones locales de la forma “esta parte de la entrada se asemeja a cierta región de este prototipo”, al mismo tiempo que se puede extraer una visión más global de cada clase usando los prototipos.

2.2.8. Occlusion

Occlusion, propuesta por Zeiler y Fergus, es una técnica de interpretabilidad model-agnostic, post-hoc y que ofrece explicaciones locales. Analiza la sensibilidad del modelo ocultando sucesivamente pequeñas regiones de la entrada y observando la variación de su salida. En imágenes, este análisis se realiza desplazando un cuadrado gris sobre la imagen; cuando la puntuación de la clase disminuye de forma notable, la región “tapada” se considera relevante para la decisión del clasificador. A diferencia de otros métodos, Occlusion solo necesita acceder a las predicciones del modelo.

En audio, adoptamos la misma idea pero aplicada sobre ventanas temporales o sobre regiones de un espectrograma, permitiendo identificar qué zonas de la señal contienen la información más importante a la hora de clasificar muestras.

2.2.9. RISE

RISE (*Randomized Input Sampling for Explanation*) es un método de explicabilidad post-hoc, de carácter local y model-agnostic, basado en perturbaciones aleatorias de la entrada. Su funcionamiento consiste en generar múltiples versiones enmascaradas de la señal mediante máscaras aleatorias que ocultan total o parcialmente distintas regiones de la entrada. La importancia de cada segmento se estima a partir de la media del *score* del modelo sobre todas aquellas entradas enmascaradas en las que dicho segmento permanece visible, es decir, en las que el valor de la máscara en esa posición es distinto de cero. Aunque al igual que con Occlusion, esta técnica fue propuesta originalmente para imágenes, en este trabajo se ha adaptado su planteamiento al dominio de audio.

La importancia de cada segmento puede expresarse mediante la siguiente aproximación:

$$S_{I,f}(\lambda) \approx \frac{1}{N \cdot \mathbb{E}[M]} \sum_{i=1}^N f(I \odot M_i) M_i(\lambda)$$

donde I es la entrada original, N es el número total de máscaras generadas, $\mathbb{E}[M]$ representa la fracción media de posiciones visibles en cada máscara, y M_i es la máscara aleatoria i -ésima. Además, $f(I \odot M_i)$ corresponde al *score* asignado por el modelo a la entrada enmascarada, mientras que $M_i(\lambda)$ indica si el segmento λ permanece visible en dicha máscara.

Tras ver las diversas metodologías, se puede concluir que la detección de audio deepfake no depende de un único enfoque, sino de la combinación estratégica de diferentes niveles de explicabilidad. Los modelos analizados ofrecen una visión complementaria del problema:

- **Precisión vs. Explicabilidad:** Mientras que métodos post-hoc como **SHAP**, **LIME** e **Integrated Gradients** permiten auditar modelos de alta complejidad sin sacrificar su rendimiento, técnicas como **SincNet** y **ProtoPNet** proponen un cambio de paradigma hacia la transparencia por diseño (*ante-hoc*), donde el razonamiento del modelo es inseparable de su arquitectura.

- **Análisis Multidimensional:** La inclusión de **Grad-CAM** permite a los analistas visualizar anomalías en el espectro sonoro, mientras que herramientas como **DiCE** aportan un valor único al proporcionar simulaciones causales. Estas últimas son fundamentales para identificar qué rasgos de “naturalidad” están ausentes en una señal sintética.

En definitiva, el conjunto de técnicas presentadas establece el marco de referencia para este proyecto. La integración de estos métodos garantiza que el sistema resultante no solo actúe como un clasificador binario, sino como una herramienta de soporte a la decisión, capaz de proporcionar evidencias técnicas robustas.

3. Metodología

3.1. Dataset

Para encontrar un dataset público que tuviera voces tanto reales como clonadas y que además fueran por pares (i.e. un audio de voz real cuya transcripción es "Hoy he comido en un restaurante chino" un audio clonando dicha voz diciendo lo mismo) ha sido complicado. Hemos echado un ojo a bastantes datasets. Vamos a comentar los que hemos tenido en cuenta.

1. **HABLA [?]:** Este dataset cuenta con una gran cantidad de audios tanto reales, como generados (con técnicas como TTS) y voces clonadas (con técnicas como Cycle-GAN). Lo hemos descartado para una primera iteración del proyecto, pero no lo descartamos para una próxima iteración.
2. **audioMNIST [?]:** Este dataset cuenta con 30 mil audios de los números del 0 al 9 en inglés. Lo hemos descartado porque todos los audios son voces reales, por lo que no nos sirve para nuestra tarea.
3. **ASVSpooof2021 [?]:** Este dataset forma parte de una serie de desafíos internacionales organizados por la comunidad de verificación automática de audio cuyo objetivo es evaluar y mejorar los sistemas capaces de detectar voz manipulada. El dataset se compone de tres grupos de audio, todos ellos con voz real y generada mezclada, logical access con grabaciones transmitidas mediante canales de voz con efectos de codificación y transmisión, physical access con grabaciones de voz auténticas y ataques de reproducción en espacios físicos reales y speech deepfake con grabaciones generadas sintéticamente y comprimidas de formas distintas. Este dataset lo hemos descartado por no contar con pares de audio aunque se pueden rescatar algunos audios en inglés sobre todo para probar los modelos que probemos más adelante.
4. **Mozilla Common Voice:** Este dataset contenía voces de personas reales en varios idiomas, lo cual daba muchas posibilidades, pero no tenía las respectivas voces generadas por IA por lo que decidimos descartarlo para buscar otro dataset más acorde a lo que necesitábamos.
5. **Wavefake [?]:** Este dataset de Kaggle cuenta con gran cantidad de audios gene-

rados. Como tal, nos sirvió para probar el primer prototipo de extracción de características y buscar librerías como librosa o speechRecognition. Este dataset, al no tener los audios reales, no nos sirve para luego desarrollar los modelos.

6. In-the-wild:[] este dataset busca condiciones realistas recopilando audios reales y falsos desde fuentes públicas como redes sociales y plataformas relacionadas. Cuenta con 38 horas de audios en inglés repartidas más o menos equitativa entre reales y falsos.

El dataset por el que nos hemos decantado se llama **ODSS**. Hemos usado este conjunto de audios porque ya tiene creado un par para cada audio, lo que nos ahorra tiempo de generar nuestros propios audios. A esta ventaja se le suma que ODSS ya contenía audios en Inglés y en Español, ambos idiomas son sumamente hablados por lo que es interesante centrarse en ellos.

Con todo esto mencionado, hemos tomado un subset de 100 audios de cada idioma. La mitad son audios naturales y la otra mitad audios generados. De estos 100 audios entrenaremos con 80 audios y probaremos los modelos con 20, de cambiar la partición lo mencionaremos explícitamente, pero un 80-20 será lo normal. Más adelante, probaremos a usar más cantidad de audios y compararemos el rendimiento.

Análisis del dataset

De este subset de audios extraídos sacaremos todas sus características que explicaremos más adelante junto con su espectrograma, su duración, su categoría (natural o generado) y el audio. Esto hace un total de 47 columnas por cada audio ya que de características como las formantes y los mfcc's que no solo se saca su valor promedio sino que también se sacará su distribución a lo largo del audio. Un resumen de los tipos de datos que encontramos en nuestro dataset sería:

- **Datos tabulares:** La mayoría de los datos sobre las características del audio.
- **Series temporales:** Muestran la evolución de las formantes o los mfcc's a lo largo del audio.
- **Datos de audio:** Se corresponde con el archivo de audio (en la práctica es la ruta al archivo de audio).
- **Datos de texto:** Se corresponde con las transcripciones de los audios.

3.2. Extracción de características

Para poder clasificar los audios en reales y generados separamos los datos que podemos proporcionar a dichos modelos en 3 grupos:

1. Características. Podemos extraer características de la voz como el tono fundamental, los formantes, las pausas, y otros. Con estos datos, los modelos pueden aprender las relaciones entre los dos grupos de audios.

2. Gráficas. Podemos extraer gráficas de la voz como la forma de onda, el espectrograma de MEL, y otros. Con estas gráficas las “Convolutional Neural Networks” pueden aprender los puntos clave que diferencian a los audios reales de los generados.
3. Audio crudo. Existen modelos llamados Wav2Vec2 los cuales aprenden directamente de los audios, sacando un vector denso de características latentes en los audios, para después hacer ajuste fino o *fine-tuning* de un modelo para clasificar los audios. Por otro lado, hay modelos como AASIST que también utilizan la onda cruda y aprenden representaciones discriminativas durante el entrenamiento.

A continuación, estudiamos que características de cada tipo podemos extraer.

Características

Podemos extraer características de la voz como el tono fundamental, los formantes, las pausas, y otros. Con estos datos, los modelos pueden aprender las relaciones entre los dos grupos de audios. Cabe destacar que las características de este tipo extraídas son mayormente arrays en el que cada componente es un valor en un momento determinado. Esto se debe a que la voz tiene una componente temporal, por lo que hay que dividir cada audio en marcos temporales (frames). Además, los modelos que aplicaremos no entrenan con arrays, por lo que los promediaremos con la media y/o desviación típica. Vamos a explicar cada característica que extraemos de los audios:

1. **Valor cuadrático medio (RMS):** Mide la energía promedio de una señal acústica (i.e. la intensidad o volumen general del audio). Se extrae dividiendo la señal en frames, para cada frame se calcula la raíz cuadrada del promedio de los valores de onda al cuadrado y, por último, se promedian esos valores. En voz humana natural, el RMS tiende a tener variaciones más orgánicas, mientras que audios sintéticos pueden mostrar patrones más uniformes.
2. **Tasa de cruces por cero (ZCR):** Mide el número de veces que la señal cambia de signo por segundo, lo que nos permite distinguir entre los sonidos tonales (periódicos) y los ruidosos (no periódicos). Se extrae detectando los puntos donde la señal cambia de signo, se cuentan dichos puntos por unidad de tiempo y se normaliza por la longitud del frame. Los sonidos sordos (como /s/, /f/) tienen ZCR alto, mientras los sonoros (/a/, /m/) tienen ZCR bajo.
3. **Centroide espectral:** Mide el centro de masa del espectro de frecuencias, lo que nos dice, de forma ponderada, si la energía de un sonido se concentra en las frecuencias graves (bajas) o en las frecuencias agudas (altas). Se obtiene calculando la Transformada Rápida de Fourier (FFT) para cada frame para obtener el espectro de frecuencias, se ponderan las frecuencias por su magnitud (energía de dicha frecuencia) y se calcula la media de estas. Cabe mencionar que las voces femeninas tienden a tener centroides más altos que las masculinas.
4. **Ancho de banda espectral:** Mide qué tan dispersas están las frecuencias alrededor del centroide, para ver si el sonido es “puro” como un silbido o una sílaba mantenida, o es “ruidoso” como el ruido blanco o un aplauso. Se extrae hallando

el centroide espectral y se calcula la desviación típica ponderada en vez de la media ponderada.

5. **Punto de caída espectral (spectral rolloff):** Mide la frecuencia por debajo de la cual se concentra un determinado porcentaje de la energía total del espectro, es decir, la frecuencia límite para un porcentaje de energía. Normalmente, dicho porcentaje es del 85 %, aunque puede variar entre 75 % a 90 %, y funciona como un percentil. Se obtiene calculando el centroide espectral y sumando la energía progresivamente hasta que lleguemos a una frecuencia con la que nos pasamos de dicho porcentaje. Es útil para distinguir entre sonidos con energía concentrada en bajas frecuencias, en un amplio espectro, o en altas frecuencias.
6. **Planitud espectral:** Mide cómo de plano es el sonido. Varía entre 0 y 1 siendo 0 un sonido con picos pronunciados y 1 un sonido con pocos picos. Se obtiene calculando el espectro como antes (FFT) y dividiendo la media geométrica del espectro entre la media aritmética del mismo.
7. **Tono fundamental (F0):** Es la frecuencia más baja y periódica de un sonido. En el contexto de la voz, es la frecuencia a la que vibran las cuerdas vocales. El tono fundamental puede verse en, por ejemplo, las emociones, las preguntas frente a afirmaciones, las notas musicales, entre otras, por lo que nos da mucha información acerca de algo o alguien. Hay varias formas de calcularlo, y ninguna es 100 % precisa. Nosotros nos decantamos por la función PYIN, la cual primero obtiene las frecuencias fundamentales mediante el algoritmo YIN y después aplica el algoritmo probabilístico de Viterbi para obtener la cadena F0 más probable. Estos son algoritmos más sofisticados que combinan autocorrelación, análisis espectral y probabilidades para evitar errores comunes como la octava errónea (detectar 200Hz por ruido en vez del tono real de 100Hz), zonas no voiceadas (unvoiced) y ruido de fondo.
8. **Formantes:** Son las frecuencias de resonancia del tracto vocal (la boca, la garganta y la nariz). Estas frecuencias se amplifican de forma natural cuando hablamos, dependiendo de la forma que le demos a la boca.
 - a) F1 (Primer formante): Relacionado con la abertura de la mandíbula (qué tan abierta está la boca).
 - b) F2 (Segundo formante): Relacionado con la posición de la lengua (adelante o atrás).
 - c) F3 (Tercer formante): Relacionado con la posición de la punta de la lengua y tiene mucha importancia en las vocales “r” y en la identidad del hablante.Para extraerlos hay varias alternativas, nosotros usamos el método de Burg para estimar las formantes, después se muestrean 100 puntos a lo largo del audio y se calcula la media.
9. **Relación Armónico-Ruido:** Mide la proporción entre energía periódica (armónicos) y energía aperiódica (ruido). Esta relación es una indicadora directa de la eficiencia fonatoria y la salud vocal: puede indicar la existencia de patologías

como voz ronca, o afonía; una fatiga vocal; o, en algunos casos, emociones. Hay varias formas de calcularla: como el método de autocorrelación o el de análisis espectral. Nosotros usamos la función `to_harmonicity` de `parselmouth.Sound`, la cual la calcula con el método de autocorrelación: primero halla el F0 de los frames; después aplica la función de autocorrelación normalizada $r(\tau) = \frac{\int x(t) \cdot x(t+\tau) dt}{\int x^2(t) dt}$; luego busca el máximo de la función de autocorrelación en el intervalo alrededor del período fundamental esperado, este máximo corresponde a la correlación entre la señal y su versión desplazada un período; tras esto calcula el HNR en decibelios $HNR = 10 \cdot \log_{10} \left(\frac{r_{\max}}{1-r_{\max}} \right)$ y, por último, aplica interpolación parabólica para obtener valores más precisos del máximo y realiza correcciones para compensar el efecto de la ventana de análisis. Es interesante saber que las voces humanas naturales suelen oscilar entre los 10 a 25 dB, por lo que unos valores extremos pueden indicar voz sintética.

10. **Proporción de silencio:** Mide el porcentaje del tiempo o de frames donde no hay voz activa, es decir, hay silencio o ruido de fondo hasta cierto umbral. La forma de calcularla es muy simple: se establece un umbral de energía debajo del cual una energía es considerada silencio, se calcula el rms y se le aplica el filtro del umbral. Finalmente se divide el número de frames considerados silencio entre el número total de frames. Esto, pese a su simpleza, puede ser determinante en el análisis de una voz ya que las IAs pueden generar patrones de pausas poco naturales o demasiado regulares.
11. **Coefficientes Cepstrales en Frecuencia de Mel (MFCC):** Son una representación compacta del espectro de frecuencias que imita cómo percibe el sonido el oído humano. En lugar de trabajar con frecuencias lineales (Hz), trabajan con una escala llamada escala Mel, que es más sensible a los cambios en frecuencias bajas que en altas (como nuestro oído). Son un total de 13 coeficientes: el primero representa la energía promedio del espectro (similar al RMS, pero en el dominio cepstral); mientras que el resto representan la forma detallada del espectro: los picos, los valles, las pendientes... Cada coeficiente añade un nivel de detalle diferente. Estos coeficientes son muy importantes ya que son, con diferencia, la característica más utilizada en: reconocimiento de voz (Speech-To-Text), reconocimiento de hablante (Identificación), clasificación de géneros musicales, entre muchas otras aplicaciones. Hoy en día son un estándar en reconocimiento de voz. Se extraen mediante un proceso más laborioso: primero se hace un pre-énfasis, amplificando las frecuencias altas, ya que estas tienen poca energía. Posteriormente, se calcula el espectro de frecuencias de cada frame; tras esto se aplica un banco de filtros triangulares espaciados según la escala Mel, donde por debajo de los 1000 Hz se aplican filtros lineales (nuestro oído distingue bien los cambios en frecuencias bajas) y por encima de los 1000 Hz se aplican filtros logarítmicos (nuestro oído distingue peor los cambios en frecuencias altas), con la fórmula $Mel(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right)$ y, para terminar, aplica la Transformada Coseno Discreta (DCT), la cual decorrelaciona las bandas de Mel, que suelen estar correlacionadas entre sí, compacta la información y devuelve los 13 primeros

coeficientes (pueden aparecer entre 20 y 40, pero no son muy representativos).

12. **Asimetría (skewness):** Mide hacia qué lado se inclina la distribución de la energía en un conjunto de datos. Si hay una asimetría positiva, la energía se concentra en valores bajos, con una cola larga hacia los valores altos. En cambio si hay una asimetría negativa, la energía se concentra en valores altos, con una cola larga hacia los valores bajos. Si no hay asimetría, la energía está equilibrada alrededor del centro (como una campana de Gauss). Se calcula restando la media a cada muestra y elevando al cubo, luego hallando el promedio de estas desviaciones cúbicas, y, finalmente, dividiendo por la desviación estándar al cubo para estandarizar. Cabe mencionar que unas distribuciones de amplitud asimétricas pueden indicar características anómalas en voces sintéticas.
13. **Curtosis:** Mide qué tan concentrados están los valores alrededor de la media y qué tan pesadas son las colas de la distribución. En audio, la curtosis nos dice qué tan “espigado” o “suave” es un sonido en términos de cómo se distribuyen sus amplitudes (en el tiempo) o su energía (en la frecuencia). Se obtiene con la siguiente fórmula
$$\text{Curtosis} = \frac{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^4}{\left(\sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2} \right)^4}.$$
 Adicionalmente, se puede restar 3 a la curtosis para que la mitad (mesocúrtica) se halle en 0. Podemos destacar que una curtosis alta (distribución picuda) puede aparecer en audios con compresión excesiva o artefactos de síntesis.
14. **Transcripción:** Para la transcripción de los audios, utilizamos modelos de **Vosk**. Esta elección se basó en que tiene modelos para los dos idiomas que vamos a investigar y además, dos versiones dentro de cada lenguaje. El que usamos para las pruebas es el small ya que es más rápido y por lo tanto más útil para esta primera fase pero dejamos en consideración el modelo full para trabajo futuro ya que tiene mayor precisión. Sobre la implementación, cabe mencionar que primero probamos Whisper, el modelo de reconocimiento automático del habla desarrollado por OpenAI, pero tras varios problemas durante su implementación, lo descartamos y escogimos vosk en su defecto para esta tarea. Es interesante tener en cuenta la transcripción de un audio ya que en ocasiones, si no podemos sacar texto en claro, pero se sabe que hay voces, puede ser un primer indicio de que el audio es generado.

3.3. Métricas de evaluación

Antes de entrar a hablar de los modelos, vamos a ver qué métricas de evaluación usaremos en estos, ya que son la pieza clave para entender qué tan bien está funcionando un modelo concreto. Métricas de evaluación hay muchas, e incluso distintas según distintos problemas (regresión, clasificación, etc.). Las principales y más conocidas son la exactitud (*accuracy*), f1, y Error Cuadrático Medio (RMSE), aunque hay muchas más como hemos mencionado. Vamos a listar todas las métricas que usamos, qué es lo que evalúan y en qué modelos las usamos (ya que algunas son tan importantes que se usan en casi todos los modelos). Es importante mencionar que, ya que nuestro problema es de clasificación, no usaremos algunas métricas de regresión como el RMSE, pues no

podemos calcularlas ni tiene sentido.

Matriz de confusión

Vamos a introducir también la matriz de confusión y el concepto de aciertos y fallos, ya que es fundamental para entender mejor las métricas. Un modelo puede hacer dos cosas, acertar y fallar, y, a su vez, los aciertos y los fallos pueden deberse a que la instancia fuera negativa y positiva. Con esto tenemos los siguientes conceptos:

- **Verdaderos Positivos (VP):** Instancias positivas predichas como positivas.
- **Verdaderos Negativos (VN):** Instancias negativas predichas como negativas.
- **Falsos Positivos (FP):** Instancias negativas predichas como positivas. También llamado Error tipo I.
- **Falsos Negativos (FN):** Instancias positivas predichas como negativas. También llamado Error tipo II.

Las matrices de confusión toman esos cuatro valores y los distribuyen en: eje y los valores reales, eje x los valores predichos y se forma una matriz $N \times N$, siendo N el número de clases que definamos. En nuestro caso, y en la mayoría de casos, se da una matriz 2×2 . También es importante entender que la diagonal principal siempre guarda los valores verdaderos (los aciertos de predicción). Con la siguiente imagen queremos ilustrar cómo se ve una matriz de confusión 2×2 . Normalmente se pone la clase negativa arriba/a la izquierda de la clase positiva, aunque podrían estar al revés, pero siempre manteniendo lo que comentamos de la diagonal principal.




Figura 2: Ejemplo real de matriz de confusión.

Métricas usadas

Veamos entonces con lo que ya sabemos qué métricas usamos y qué miden.

- **Exactitud (*accuracy*)**: Mide la proporción total de predicciones correctas (tanto positivas como negativas) sobre el total de casos. Es útil cuando las clases están balanceadas, pero puede ser engañosa si hay un desbalance (ej. 95 % de una clase y 5 % de otra, predecir siempre la mayoritaria daría un 95 % de *accuracy*). Su fórmula es: $\frac{VP+VN}{VP+VN+FP+FN}$. Lo usamos en Random Forest, LightGBM, SVM, ...
- **Precisión**: Mide la relación de las clases predichas como positivas frente al total de valores reales positivos. Es una métrica que se enfoca en controlar los Falsos Positivos (FP). Es útil cuando el costo de un FP es alto (por ejemplo, marcar un correo legítimo como spam). Su fórmula es: $\frac{VP}{VP+FP}$. Podría calcularse la precisión para la clase negativa también. Lo usamos en Random Forest, LightGBM, SVM, ...
- **Exhaustividad (*recall*)**: Mide la cantidad de valores positivos que el modelo logró predecir correctamente. Es una métrica que se enfoca en minimizar los Falsos Negativos (FN). Es útil cuando el costo de un FN es alto (por ejemplo, no detectar una enfermedad grave). Su fórmula es: $\frac{VP}{VP+FN}$. Podría calcularse el *recall* de la clase negativa también. Lo usamos en Random Forest, LightGBM, SVM, ...

- **F1-Score:** Es la media armónica entre la Precisión y el Recall. Busca un equilibrio entre ambas métricas. Es una métrica más robusta que la Accuracy cuando hay clases desbalanceadas, ya que penaliza los extremos (una precisión alta con recall bajo, o viceversa). Es útil cuando quieres una sola métrica que resuma el rendimiento en la clase positiva. Su fórmula es: $2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$. Lo usamos en Random Forest, LightGBM, SVM, ...
- **Área bajo la curva ROC (ROC-AUC):** Mide la capacidad discriminativa del modelo, independientemente del umbral de decisión elegido. La curva ROC (Receiver Operating Characteristic) grafica la Tasa de Verdaderos Positivos (Recall) frente a la Tasa de Falsos Positivos. La fórmula de la curva es: $\frac{FP}{FP+VN}$. El AUC (Area Under the Curve) es el área bajo esta. Lo usamos en Random Forest, LightGBM, SVM, ...
- **Coefficiente de Correlación de Matthews (MCC):** Es esencialmente un coeficiente de correlación entre las etiquetas reales y las predicciones. A diferencia de las métricas anteriores (que a veces solo se enfocan en la clase positiva), el MCC considera los cuatro cuadrantes de la matriz de confusión (VP, VN, FP, FN). Se considera una métrica equilibrada incluso con conjuntos de datos muy desbalanceados. Su valor oscila entre -1 y 1 siendo -1 una discrepancia total entre predicción y realidad y 1 una predicción perfecta. Su fórmula es: $\frac{VP \cdot VN - FP \cdot FN}{\sqrt{(VP+FP)(VP+FN)(VN+FP)(VN+FN)}}$. Lo usamos en Random Forest, LightGBM, SVM, ...

3.4. Modelos

En esta subsección vamos a analizar qué modelos hemos usado para resolver el problema que tenemos entre manos. Es importante recalcar que distintos modelos pueden usar distintos tipos de datos (tabulares, imágenes, etc.). Además, un mismo modelo puede usar varios tipos de datos a la vez para entrenar. Antes de ver los distintos modelos veamos qué tipos de datos usan cada uno.

- **Random Forest:** Datos tabulares.
- **LightGBM:** Datos tabulares.
- **SVM:** Datos tabulares.
- **AASIST:**
- **MLP:**
- **Wav2Vec2:**
- **Regresión Logística:**
- **KNN:**

3.4.1. Random Forest

Como hemos comentado sobre los Random Forest, estos construyen un conjunto o “bosque”, “bosque” de árboles de decisión donde cada árbol se entrena de forma ligeramente diferente, introduciendo aleatoriedad controlada.

Justificación del modelo

Se seleccionó Random Forest como uno de los clasificadores base debido a su robustez frente al sobreajuste, su capacidad para manejar características heterogéneas y su interpretabilidad mediante el análisis de importancia de variables.

Configuración experimental

El proceso experimental para Random Forest se estructuró en tres fases: (1) establecimiento de un modelo baseline, (2) validación cruzada para evaluar robustez, (3) optimización de hiperparámetros mediante búsqueda sistemática.

División de datos El conjunto de datos se particionó en entrenamiento (80 %) y prueba (20 %) utilizando muestreo estratificado para mantener la proporción de clases en ambos conjuntos. Esta estratificación es crucial cuando existe desbalance entre voces reales y generadas.

Modelo baseline Se estableció una configuración inicial con hiperparámetros por defecto para obtener una referencia de rendimiento:

- **n_estimators:** 100.
- **max_depth:** 10.
- **min_samples_split:** 5.
- **min_samples_leaf:** 2.
- **max_features:** sqrt.
- **random_state:** 12.
- **class_weight:** balanced.

Validación cruzada estratificada

Para evaluar la robustez del modelo y evitar que los resultados dependan de una única partición de los datos, se realizó validación cruzada estratificada con 5 conjuntos (folds). Esto es dividir los datos en k conjuntos y entrenar un modelo con k-1 y evaluarlo con el restante, haciendo k entrenamientos (ya que cada conjunto se usa para evaluación exactamente una vez). Nosotros usamos el modelo baseline de Random Forest para aplicar la validación cruzada, mezclamos los datos de entrenamiento antes de instanciar el modelo de validación cruzada y, por último, evaluamos con accuracy, f1 y ROC-AUC.

La validación cruzada proporciona una estimación más realista del rendimiento esperado en datos no vistos, reportándose la media y la desviación estándar de las métricas.

Optimización de hiperparámetros

Se realizó una búsqueda sistemática de hiperparámetros mediante `GridSearchCV` con validación cruzada de 5 folds, optimizando el F1-score. El espacio de búsqueda incluyó:

- **n_estimators**: Probamos los valores 50, 100 y 200.
- **max_depth**: Probamos los valores 5, 10, 15.
- **min_samples_split**: Probamos 2, 5 y 10.
- **min_samples_leaf**: Probamos 1, 2 y 4.
- **max_features**: Probamos “sqrt” y “log2”. Este último toma el logaritmo en base 2 del número de características.

Tras esto instanciamos el `GridSearchCV` (búsqueda de parámetros (search) probando todas las combinaciones (grid) con validación cruzada (CV)) poniendo un modelo base de Random Forest con el estado aleatorio 12 y el peso de clases balanceado, como antes. A dicho grid search le ponemos el grid de parámetros que comentamos arriba, la validación cruzada de 5-folds que hicimos antes, y la métrica a optimizar de f1. Por último entrenamos el modelo con los datos de entrenamiento sin escalar.

Funciones implementadas para explicabilidad

Se desarrollaron dos funciones principales para generar y visualizar explicaciones SHAP, tanto a nivel global como local.

Función de explicación SHAP La función `explica_shap` (Código 1) genera las explicaciones y visualizaciones:

Listing 1: Función para generar explicaciones SHAP

```
def explica_shap(modelo, X_train, X_test, n_show, local):  
    # Creacion del explainer basado en el modelo  
    explainer = shap.Explainer(modelo.predict, X_train)  
  
    # Calculo de valores SHAP para el conjunto de prueba  
    shap_values = explainer(X_test)  
  
    # Visualizacion segun el tipo solicitado  
    if local:  
        # Explicaciones locales: diagramas de cascada (waterfall)  
        # para las primeras n_show instancias  
        for j in range(n_show):  
            shap.plots.waterfall(shap_values[j])  
    else:
```

```

# Explicacion global: summary plot
shap.summary_plot(shap_values , X_test)
plt.show()

# Retorno de predicciones para evaluacion posterior
y_pred = modelo.predict(X_test)
y_pred_proba = modelo.predict_proba(X_test)[: , 1]
return y_pred , y_pred_proba

```

El funcionamiento de esta función es el siguiente:

1. Se crea un `shap.Explainer` utilizando el método de predicción del modelo y el conjunto de entrenamiento como referencia.
2. Se calculan los valores SHAP para todas las instancias del conjunto de prueba.
3. Dependiendo del parámetro `local`:
 - Si `local=True`: Se generan `n_show` diagramas de cascada (*waterfall plots*), cada uno mostrando la contribución de cada característica a la predicción de un audio específico.
 - Si `local=False`: Se genera un *summary plot* que agrega los valores SHAP de todas las instancias, mostrando la importancia global de cada característica y la dirección de su impacto.
4. La función retorna las predicciones (clases y probabilidades) para su posible evaluación posterior.

Función de validación mediante eliminación de características Para validar la importancia de las características identificadas por SHAP, se implementó la función `drop_features_explica_shap`, que permite realizar un experimento de ablación:

Listing 2: Función para evaluar impacto de eliminar características

```

def drop_features_explica_shap(modelo , model_name , X_train , y_train ,
                               X_test , y_test , feats , n_show ,
                               evalua_modelo=False , local=True):
    # Creacion de nuevos conjuntos sin las caracteristicas especificadas
    X_train_new = X_train.drop(feats , axis=1, inplace=False)
    X_test_new = X_test.drop(feats , axis=1, inplace=False)

    # Reentrenamiento del modelo con los mismos hiperparametros
    params = modelo.get_params()

    modelo = RandomForestClassifier(**params)
    modelo.fit(X_train_new , y_train)

    # Generacion de explicaciones para el nuevo modelo

```

```

y_pred , y_pred_proba = explica_shap(
    modelo=modelo ,
    X_train=X_train_new ,
    X_test=X_test_new ,
    n_show=n_show ,
    local=local
)

# Evaluacion opcional del rendimiento
if evalua_modelo:
    evaluacion_modelo(
        model_name=model_name ,
        y_true=y_test ,
        y_pred=y_pred ,
        y_pred_proba=y_pred_proba
    )

return modelo_new , X_train_new , X_test_new

```

Esta función permite:

1. Eliminar un conjunto de características especificadas (**feats**) de los conjuntos de entrenamiento y prueba.
2. Reentrenar un nuevo modelo Random Forest con los mismos hiperparámetros que el modelo original.
3. Generar nuevas explicaciones SHAP para el modelo reducido.
4. Evaluar opcionalmente el rendimiento del nuevo modelo utilizando la función `evaluacion_modelo`, la cual calcula una serie de métricas como f1-score, accuracy o roc-auc, entre otras.

Interpretación de las visualizaciones generadas

Las visualizaciones obtenidas se interpretan de la siguiente manera:

- **Summary plot (global):** Muestra las características ordenadas por importancia. El color indica el valor de la característica (rojo = alto, azul = bajo) y la posición en el eje X indica el valor SHAP (impacto en la predicción). Características con puntos extendidos horizontalmente son más influyentes. Un ejemplo es:
- **Waterfall plot (local):** Para un audio específico, muestra:
 - $E[f(X)]$: Valor base (probabilidad media de la clase IA).
 - $f(x)$: Predicción final para este audio.
 - Barras rojas/azules: Características que empujan la predicción hacia IA (rojo) o hacia real (azul), con la magnitud de su contribución.

Un ejemplo de explicación local es:




Figura 3: Explicación local con SHAP

Implementación de LIME para la interpretabilidad local del modelo

Como complemento a SHAP, se incorporó LIME (Local Interpretable Model-agnostic Explanations) para obtener explicaciones locales de las predicciones del modelo Random Forest. LIME genera explicaciones interpretables aproximando localmente el modelo complejo mediante un modelo simple (lineal) en la vecindad de la instancia a explicar.

Funciones implementadas para explicaciones LIME

Para integrar LIME en el flujo de trabajo, se implementó un procedimiento que permite generar explicaciones visualmente claras y personalizar su presentación para facilitar su inclusión en informes y memorias.

Configuración del explainer LIME El primer paso consiste en crear un explainer de LIME adaptado a datos tabulares:

Listing 3: Configuración del explainer LIME

```
from lime.lime_tabular import LimeTabularExplainer
import re
from IPython.display import HTML, display

# Creacion del explainer para datos tabulares
```

```

explainer = LimeTabularExplainer(
    X_train.values,           # Datos de entrenamiento en formato numpy
    feature_names=X.columns,  # Nombres de las características
    class_names=['label'],    # Nombres de las clases (0: Real, 1: IA)
    mode='classification'     # Modo de clasificacion
)

```

Los parámetros utilizados son:

- **X_train.values**: Matriz de características de entrenamiento en formato numpy array, necesaria para que LIME pueda muestrear la vecindad de las instancias.
- **feature_names**: Lista con los nombres de las características (formantes, MFCC, etc.) para etiquetar correctamente las explicaciones.
- **class_names**: Etiquetas descriptivas para las clases ('Real' y 'IA') en lugar de valores numéricos.
- **mode='classification'**: Indica que se trata de un problema de clasificación.

Generación de explicaciones para una instancia Para obtener la explicación de un audio específico, se utiliza el método `explain_instance`:

Listing 4: Generación de explicación para una instancia

```

# Seleccionamos la primera instancia del conjunto de prueba como ejemplo
instancia_a_explicar = X_test.values[0]

# Generamos la explicacion
exp = explainer.explain_instance(
    instancia_a_explicar,           # Instancia a explicar
    modelo_rf.predict_proba,       # Funcion de prediccion (probabilidades)
    num_features=10                # Numero de caracteristicas a mostrar
)

```

El método `explain_instance` recibe:

- La instancia concreta a explicar (en formato numpy array).
- La función de predicción del modelo (en este caso `predict_proba`), que LIME utiliza para muestrear la vecindad y entrenar el modelo local.
- **num_features**: Número de características más relevantes a incluir en la explicación (por defecto 10).

Personalización visual de las explicaciones LIME

LIME genera por defecto visualizaciones con estilos que pueden no integrarse adecuadamente en el formato de la memoria. Para solucionarlo, se implementó un proceso de limpieza y personalización del HTML generado:

Listing 5: Limpieza y personalización del HTML de LIME

```
# Obtenemos el HTML generado por LIME
exp_html = exp.as_html()

# Removemos las etiquetas <style> internas que pueden forzar estilos no deseados
exp_html_clean = re.sub(
    r'<style.*?>.*?</style>',
    '',
    exp_html,
    flags=re.DOTALL
)

# Envolvemos el HTML limpio en un contenedor con estilos personalizados
html_con_style = f"""
<style>
.lime-container * {{
    color: black !important;          # Texto en negro
    background-color: white !important; # Fondo blanco
    border-color: black !important;    # Bordes en negro
}}
</style>
<div class="lime-container">
    {exp_html_clean}
</div>
"""

# Mostramos el resultado
display(HTML(html_con_style))
```

Este proceso realiza las siguientes transformaciones:

1. **Extracción del HTML:** `exp.as_html()` genera una representación HTML completa de la explicación LIME, incluyendo estilos CSS embebidos.
2. **Limpieza de estilos:** Mediante una expresión regular (`re.sub`) se eliminan todas las etiquetas `<style>` internas que LIME incluye por defecto. Esto evita conflictos con los estilos de la memoria y permite un control total sobre la apariencia.
3. **Envoltura con estilos personalizados:** Se crea un contenedor `<div>` con clase `lime-container` y se definen estilos CSS que fuerzan:
 - Texto en color negro (`color: black !important`)
 - Fondo blanco (`background-color: white !important`)
 - Bordes en negro (`border-color: black !important`)

El uso de `!important` garantiza que estos estilos prevalezcan sobre cualquier otro.

4. **Visualización:** Se utiliza `display(HTML(...))` de IPython para renderizar el HTML personalizado en el notebook.




Figura 4: Explicación local con SHAP

Interpretación de las explicaciones LIME

La visualización generada por LIME muestra:

- **Predicción del modelo:** La probabilidad asignada a cada clase (Real/IA) para la instancia explicada.
- **Características más influyentes:** Lista de las `num_features` características con mayor impacto en la decisión, ordenadas por importancia.
- **Contribución de cada característica:** Barras horizontales que indican si la característica apoya la clase IA (color naranja/rojo) o la clase Real (color azul), junto con la magnitud de su contribución.
- **Valor de la característica:** Se muestra el valor concreto que tenía esa característica en el audio explicado.

Consideraciones sobre la implementación

Durante la implementación se tuvieron en cuenta los siguientes aspectos:

- **Formato de datos:** LIME requiere los datos en formato numpy array (`.values`) en lugar de DataFrame de pandas, por lo que se realiza la conversión explícita.
- **Función de predicción:** Se utiliza `predict_proba` en lugar de `predict` para obtener las probabilidades, lo que permite a LIME capturar la confianza del modelo y no solo la clase final.
- **Número de características:** Se limitó a 8-10 características por explicación para mantener la legibilidad, aunque el parámetro es configurable.
- **Personalización visual:** La limpieza de estilos CSS garantiza que las explicaciones LIME mantengan una apariencia profesional y consistente con el resto de la memoria, evitando problemas de contraste o colores no deseados.

Implementación de DiCE para la generación de explicaciones contrafactuales

Para complementar las explicaciones basadas en atribución (SHAP y LIME), se incorporó DiCE (Diverse Counterfactual Explanations) para generar explicaciones contrafactuales. DiCE responde a la pregunta: ¿qué cambios mínimos en las características de un audio clasificado como “a” lo harían ser clasificado como “b”, y viceversa?

Preparación de datos para DiCE

DiCE requiere los datos en un formato específico, combinando características y etiqueta en un mismo DataFrame:

Listing 6: Preparación de datos para DiCE

```
# Eliminacion de columnas no relevantes (ej. filename)
X_train_clean = X_train.drop(columns=['filename'], errors='ignore')
X_test_clean = X_test.drop(columns=['filename'], errors='ignore')

# Combinacion de características con la variable objetivo
data_dice = X_train_clean.copy()
data_dice['label'] = y_train # Variable objetivo (0: Real, 1: IA)
```

Los pasos realizados son:

- **Limpieza de características no predictivas:** Se elimina la columna `filename` (si existe) ya que contiene identificadores de archivo sin valor predictivo y no tendría sentido generar contrafactuales modificándola.
- **Integración de la variable objetivo:** DiCE necesita conocer la relación entre características y etiqueta, por lo que se añade la columna `label` al DataFrame de entrenamiento.

Configuración de DiCE

DiCE utiliza dos componentes principales: un `DataInterface` para manejar los datos y un `Model` para encapsular el clasificador:

Listing 7: Configuración de DiCE

```
import dice_ml

# Definicion del DataInterface
dice_data = dice_ml.Data(
    dataframe=data_dice, # DataFrame con features +
    continuous_features=X_train_clean.columns.tolist(), # Todas las features son
    outcome_name='label' # Nombre de la variable o
)
```



```

# Encapsulacion del modelo
dice_model = dice_ml.Model(
    model=modelo_rf,          # Modelo Random Forest entrenado
    backend='sklearn'         # Backend para modelos scikit-learn
)

# Creacion del explicador DiCE
exp = dice_ml.Dice(
    dice_data,                # DataInterface
    dice_model,               # Model encapsulado
    method="random"           # Metodo de generacion ("random" o "genetic")
)

```

Los parámetros utilizados son:

- **dataframe**: DataFrame completo que contiene tanto las características como la variable objetivo para el entrenamiento.
- **continuous_features**: Lista de nombres de todas las características continuas. En este caso, todas las características de audio (formantes, MFCC, etc.) son continuas.
- **outcome_name**: Nombre de la columna que contiene la variable objetivo ('label').
- **backend='sklearn'**: Indica que el modelo es de scikit-learn, permitiendo a DiCE acceder a los métodos necesarios.
- **method=random**: Método de generación de contrafactuales. random.^{es} más rápido; también existe "genetic" para búsquedas más exhaustivas.

Generación de contrafactuales para una instancia

Una vez configurado DiCE, se genera un conjunto de contrafactuales para una instancia específica:

Listing 8: Generación de contrafactuales

```

# Seleccion de la instancia a explicar (primera del conjunto de prueba)
query = X_test_clean.iloc[[0]] # Usamos iloc para mantener estructura DataFrame

# Generacion de contrafactuales
e1 = exp.generate_counterfactuals(
    query_instances=query,      # Instancia(s) a explicar
    total_CFs=3,               # Numero de contrafactuales a generar
    desired_class="opposite"    # Clase deseada (opuesta a la prediccion origin
)

# Visualizacion de resultados
e1.visualize_as_dataframe(show_only_changes=True)

```

Los parámetros de generación son:

- **query_instances**: DataFrame con una o más instancias para las que generar contrafactuales. Se utiliza `iloc[[0]]` para mantener la estructura de DataFrame (a diferencia de `iloc[0]` que devolvería una Serie).
- **total_CFs**: Número de contrafactuales a generar (en este caso 3), permitiendo explorar diferentes alternativas para cambiar la clasificación.
- **desired_class**: Clase objetivo para los contrafactuales. `."opposite"` indica la clase contraria a la predicción original. También se puede especificar directamente 0 (Real) o 1 (IA).
- **show_only_changes=True**: En la visualización, muestra únicamente las características que cambian respecto a la instancia original, facilitando la identificación rápida de las modificaciones necesarias.

Interpretación de los contrafactuales generados

La visualización generada por `visualize_as_dataframe(show_only_changes=True)` muestra:

- **Instancia original**: Valores de las características para el audio consultado y su clasificación original.
- **Contrafactuales**: Para cada uno de los `total_CFs` generados:
 - Valores de las características que cambian respecto al original (si `show_only_changes=True`).
 - La nueva clasificación resultante (clase deseada).
 - La magnitud del cambio necesario en cada característica.
- **Diversidad**: DiCE genera contrafactuales diversos, mostrando diferentes formas de lograr el mismo cambio de clasificación (por ejemplo, modificando diferentes combinaciones de formantes o MFCC).

La salida para la primera instancia es:

Interpretación en el contexto de deepfakes

Las explicaciones contrafactuales permiten responder preguntas como:

- **Para un audio clasificado como IA**: "¿Qué características acústicas deberían cambiar para que el modelo lo considere voz real, y en qué magnitud?"
- **Para un audio clasificado como real**: "¿Qué modificaciones lo harían ser clasificado como generado por IA?"
- **Vías alternativas**: DiCE muestra múltiples formas de lograr el cambio, revelando si hay "camino" principales (modificar ciertos formantes) o alternativos (modificar MFCC específicos).

Consideraciones sobre la implementación

Durante la implementación se tuvieron en cuenta los siguientes aspectos:

- **Eliminación de columnas no relevantes:** Características como 'filename' se eliminan porque no tienen sentido en un contrafactual (no se puede modificar el nombre del archivo para cambiar la clasificación).
- **Selección de instancia:** Se utiliza `iloc[[index]]` en lugar de `iloc[index]` para mantener la estructura de DataFrame requerida por DiCE.
- **Método de generación:** Se eligió `method=random` por su eficiencia computacional, aunque para análisis más exhaustivos se puede utilizar `method=genetic`.
- **Visualización enfocada:** El parámetro `show_only_changes=True` facilita la interpretación al mostrar únicamente las características que realmente cambian, evitando abrumar con información redundante.
- **Clase deseada:** El valor `opposite` es útil cuando se quiere explorar el cambio de clase, pero también se puede especificar explícitamente 0 o 1 si se busca una dirección concreta.

3.4.2. LightGBM

Como hemos comentado antes, a diferencia de Random Forest, que construye árboles de forma independiente y paralela, LightGBM los construye secuencialmente, donde cada nuevo árbol se especializa en corregir los errores de los anteriores.

Justificación del modelo

Hemos usado LightGBM debido a que presenta ventajas significativas para la tarea de detección de deepfakes de audio, como pueden ser su eficiencia computacional para grandes volúmenes de datos o su regulación integrada con los parámetros L1 y L2.

Configuración experimental

El proceso experimental para LightGBM se estructuró en tres fases: (1) establecimiento de un modelo baseline, (2) validación cruzada para evaluar robustez, y (3) optimización de hiperparámetros mediante búsqueda sistemática.

Preparación de datos

A diferencia de otros algoritmos, LightGBM puede manejar directamente datos sin normalización, aunque requiere que no existan valores nulos.

Modelo baseline con LightGBM

Se estableció una configuración inicial utilizando la interfaz nativa de LightGBM, que ofrece un control más fino sobre el proceso de entrenamiento:

- **objective:** binary.
- **metric:** binary logloss.
- **boosting_type:** gbdt.
- **num_leaves:** 31.
- **learning_rate** η : 0,05.
- **feature_fraction:** 0,9.
- **bagging_fraction:** 0,8.
- **bagging_freq:** 5.
- **random_state:** 12.
- **is_unbalanced:** True.

El parámetro `is_unbalance=True` activa la compensación automática para clases desbalanceadas, ajustando los pesos de forma inversamente proporcional a la frecuencia de cada clase.

Tras ello entrenamos el modelo con los parámetros base, los datos de entrenamiento sin escalar, un set de validación, y los siguientes parámetros:

- **num_boost_round:** Es el número máximo de iteraciones (árboles) que se entrenarán. En este caso, 1000 es el límite superior, pero el `early_stopping` puede detener el proceso antes si no hay mejoras.
- **callbacks:** funciones que se ejecutan durante el entrenamiento para controlar el proceso. En este caso mostramos información del entrenamiento cada 100 iteraciones y paramos si no mejora por 50 iteraciones.

Early stopping

Una ventaja importante de LightGBM es la capacidad de detener el entrenamiento cuando añadir más árboles no mejora el rendimiento en validación. Esto:

- Previene el sobreajuste (overfitting)
- Ahorra tiempo computacional
- Determina automáticamente el número óptimo de iteraciones

Validación cruzada estratificada

Para LightGBM se utilizó la interfaz compatible con scikit-learn (`LGBMClassifier`) que permite integrarse con las herramientas de validación cruzada estándar. El modelo que usamos es el mismo que el baseline (en cuanto a parámetros). Tras crear el modelo aplicamos la validación cruzada donde mezclamos los datos de entrenamiento y dividimos en 5 conjuntos, donde en cada paso se entrena al modelo con 4 y se evalúa con

el restante, cambiando el conjunto de evaluación en cada etapa. Finalmente evaluamos con accuracy, f1 y ROC-AUC.

La validación cruzada proporciona una estimación más robusta del rendimiento, reportándose la media y la desviación estándar de las métricas.

Optimización de hiperparámetros

LightGBM cuenta con un conjunto de hiperparámetros específicos, diferentes a los de Random Forest. La búsqueda se centró en aquellos que más influyen en el rendimiento:

- **num_leaves**: Probamos 15, 31 y 63.
- **learning_rate**: Probamos 0,01, 0,05 y 0,1.
- **n_estimators**: Probamos 100, 200 y 300.
- **min_child_samples**: Probamos 20, 50 y 100.
- **subsample**: Probamos 0,6, 0,8 y 1.
- **colsample_bytree**: Probamos 0,6, 0,8 y 1.
- **reg_alpha**: Probamos 0, 0,1 y 0,5.
- **reg_lambda**: Probamos 0, 0,1 y 0,5.

Tras esto instanciamos el GridSearchCV (búsqueda de parámetros (search) probando todas las combinaciones (grid) con validación cruzada (CV)) poniendo un modelo base de Random Forest con el estado aleatorio 12 y el peso de clases balanceado, como antes. A dicho grid search le ponemos el grid de parámetros que comentamos arriba, la validación cruzada de 5-folds que hicimos antes, y la métrica a optimizar de f1. Por último entrenamos el modelo con los datos de entrenamiento sin escalar.

3.4.3. Support Vector Machine (SVM)

Como ya hemos visto sobre los SVM, estos se fundamentan en la búsqueda del hiperplano óptimo que maximiza el margen de separación entre clases, lo que proporciona una base teórica sólida y garantías de generalización.

Justificación del modelo

Usamos SVM ya que presenta características especialmente relevantes para la detección de deepfakes de audio que hemos comentado antes, como la eficacia en espacios de alta dimensión (como puede ser el mundo del lenguaje natural) o su fundamento teórico robusto.

Importancia de la normalización

Una característica crítica de SVM es su sensibilidad a la escala de las características. Las variables de audio presentan escalas muy diferentes:

- **Formantes:** Del orden de cientos de Hz (ej. 300-3000 Hz)
- **MFCC:** Valores típicamente en el rango $[-200, 200]$
- **ZCR** (Zero Crossing Rate): Valores normalizados entre 0 y 1
- **HNR** (Harmonics-to-Noise Ratio): Valores en decibelios (dB)

Sin normalización, las características con mayor magnitud dominarían el cálculo de distancias, sesgando el modelo. Por ello, se aplicó `StandardScaler` para estandarizar las características a media cero y desviación típica uno.

Es crucial aplicar el escalado *después* de la división train/test para evitar *data leakage* (fuga de información del conjunto de prueba al entrenamiento).

Configuración experimental

El proceso experimental para SVM se estructuró en cuatro fases: (1) modelo baseline con kernel lineal, (2) modelo con kernel RBF, (3) validación cruzada, y (4) optimización de hiperparámetros mediante Grid Search.

Modelo baseline: SVM lineal

Se estableció un primer modelo con kernel lineal como referencia simple:

- **kernel:** linear.
- **C:** 1.
- **probability:** True.
- **random_state:** 12.
- **class_weight:** balanced.

Modelo no lineal: SVM con kernel RBF

Dada la naturaleza compleja de las señales de audio, se implementó un modelo con kernel RBF para capturar relaciones no lineales:

- **kernel:** RBF.
- **C:** 1.
- **gamma:** scale.
- **probability:** True.
- **random_state:** 12.
- **class_weight:** balanced.

El parámetro `gamma='scale'` establece automáticamente $\gamma = 1/(n_{\text{características}} \cdot \text{Var}(X))$, un valor inicial razonable.

Validación cruzada estratificada

Para garantizar la robustez de las evaluaciones y evitar dependencias de una única partición, se implementó validación cruzada estratificada con 5 conjuntos (folds). Se utilizó un pipeline que integra el escalado y el clasificador para asegurar que la normalización se realice correctamente en cada fold. Primero se escalan los datos y después se crea el modelo base de SVM. Tras esto se instancia el modelo de validación cruzada, el cual crea los 5 conjuntos con los datos de entrenamiento previamente escalados y mezclados, tras lo que se entrena al modelo con 4 conjuntos y se evalúa con el restante, así 5 veces. Por último evaluamos con accuracy, f1 y ROC-AUC.

Optimización de hiperparámetros

SVM con kernel RBF tiene dos hiperparámetros críticos que determinan su rendimiento (C y gamma). La búsqueda sistemática se realizó mediante Grid Search con validación cruzada sobre dichos parámetros:

- **C:** Probamos 0,1, 1, 10 y 100.
- **gamma:** Probamos 0,001, 0,01, 0,1, 1, “scale” y “auto”.
- **kernel:** Probamos únicamente el kernel no lineal “rbf”.

Tras esto instanciamos el GridSearchCV (búsqueda de parámetros (search) probando todas las combinaciones (grid) con validación cruzada (CV)) poniendo un modelo base de Random Forest con el estado aleatorio 12 y el peso de clases balanceado, como antes. A dicho grid search le ponemos el grid de parámetros que comentamos arriba, la validación cruzada de 5-folds que hicimos antes, y la métrica a optimizar de f1. Por último entrenamos el modelo con los datos de entrenamiento sin escalar.

La elección de optimizar el F1-score responde a la necesidad de balancear precisión y sensibilidad en un problema donde ambos tipos de error (falsos positivos y falsos negativos) son relevantes.

Análisis de vectores de soporte

Una característica única de SVM es la identificación de los **vectores de soporte**: las muestras críticas que determinan la frontera de decisión. Su análisis proporciona información sobre la complejidad del problema:

Listing 9: Análisis de vectores de soporte

```
# Obtenemos el modelo del pipeline
svm_model = svm_optimized.named_steps['svm']
n_support_vectors = svm_model.n_support_
support_vectors_count = sum(n_support_vectors)

print(f"Total de vectores de soporte: {support_vectors_count}")
print(f"Porcentaje del dataset: {support_vectors_count / len(X_train) * 100:.2f}%")
print(f"Vectores clase Real(0): {n_support_vectors[0]}")
```

```
print(f"Vectores_clase_IA_{1}:_{n_support_vectors[1]}")
```

La interpretación de estos valores es reveladora:

- Un bajo porcentaje de vectores de soporte (< 30 %) indica que la frontera de decisión es relativamente simple y está bien definida por pocos ejemplos.
- Si una clase tiene significativamente más vectores de soporte, su región de decisión es más compleja o presenta mayor solapamiento.
- Los vectores de soporte son candidatos naturales para un análisis cualitativo: ¿qué tienen en común los audios más difíciles de clasificar?

3.4.4. AASIST

AASIST (*Audio Anti-Spoofing using Integrated Spectro-Temporal Graph Attention Networks*) es un modelo creado con la motivación de combinar pistas espectrales y temporales para detectar artefactos de spoofing y conseguir robustez frente a una gran variedad de ataques. Como este modelo produce una predicción a partir del audio crudo, el primer paso es definir las rutas a los audios.

Después, se lee el contenido del **archivo .conf** del modelo. Para ello, hemos creado una función que busca el elemento pasado por parámetro y devuelve el bloque superior que contiene ese elemento junto con los elementos al mismo nivel. Esto nos permite construir una variable, que vamos a llamar `args`, con los siguientes campos:

- **first_conv**: configuración del **kernel** de la primera capa de convolución, es decir, cuántas muestras de audio se utilizan para cada filtro. En este caso, 128.
- **filters**: es un array de elementos siendo el primero el número de **filtros** en la primera capa de convolución. Los siguientes elementos son pares para cada bloque residual con el número de filtros de entrada y de salida.
- **gat_dims**: tamaño del **embedding** que representa cada nodo. Tiene dos valores que hacen referencia al tamaño al construir los grafos de atención y al tamaño en las fases de “HS-GAL” + “pooling” respectivamente.
- **pool_ratios**: se usa en la técnica de “graph pooling” y significa el **ratio de reducción de nodos** en cada capa. Los dos primeros valores se usan para reducir los grafos espectral y temporal respectivamente antes de combinarlos en el grafo heterogéneo. El siguiente valor se usa para reducir el grafo heterogéneo después de cada capa HS-GAL. Aunque existe un cuarto valor, en el modelo final no se usa.
- **temperatures**: controla lo suave o agresiva que es la **atención** en cada fase. Cuanto más bajo es este parámetro, mayor peso se concentra en pocos nodos vecinos.

Con `args` ya creado, la usamos para instanciar el modelo. Posteriormente, se usa el checkpoint para cargar los pesos preentrenados.

El siguiente paso es definir las funciones de inferencia. Para esto, nos apoyamos primero en dos funciones auxiliares, una que convierte los audios a un **formato estándar**, un solo canal y 16 kHz, y otra que crea una **ventana** para recorrer audios largos. Esta última es importante ya que AASIST está diseñado para recibir segmentos de longitud de unos 4 segundos. Con esto preparado, las tres funciones de inferencia las creamos para ver si conseguimos mejores resultados alterando un poco el proceso y se describen a continuación:

- **average_windows**: esta función devuelve la media de sumar las predicciones de cada ventana calculadas de forma independiente.
- **score_without_windows**: esta función devuelve solamente la puntuación del segmento inicial del audio en archivos largos o del audio en su totalidad en el caso contrario.
- **average_logits**: esta función fusiona todas las ventana sumando sus “logits” antes de calcular una única probabilidad.

Finalmente, se aplica el modelo y se vuelcan los resultados en un csv con el nombre del audio, la probabilidad de que sea “bonafide” y su duración. Para esto, se recorre cada audio del dataset, se le aplica una de las funciones de inferencia y se escribe la información en el csv.

Resultados y análisis Como hemos mencionado anteriormente, implementamos tres funciones de inferencia distintas para intentar obtener mejores resultados. Tras varias pruebas, alternando las tres funciones, obtuvimos resultados pésimos en los que el modelo tendía a clasificar cada muestra como “bona fide” y alguna como “spoof” pero sin mucho acierto lo que da una sensación de clasificación al azar. Ante estos resultados, decidimos realizar “**fine-tunning**” sobre el propio modelo preentrenado, nuestro propio preentrenamiento con parte del dataset que creamos. Para conseguir esto, primero separamos el dataset en train, eval y dev y generamos los archivos de “protocols” de donde el modelo va leyendo el nombre y el tipo de los audios de cada partición. Adicionalmente, tuvimos que hacer ciertos ajustes en el .conf y en especial, ajustar el número de épocas.

Para las pruebas, las hemos separado en tres tipos: audios en inglés por separado, español por separado y ambos idiomas juntos. Dentro de cada escenario, hay cuatro pruebas con distinto número de **épocas: 10, 20, 40 o 80**. También, cabe mencionar que siempre se ha mantenido una proporción en la separación en train, dev y eval de 72 %, 14 % y 14 %, respectivamente. Por último, antes de analizar los resultados, es importante explicar que en la separación manual del dataset hemos separado los distintos speakers que había en cada idioma. Esto se refiere a que en el dataset hay por idioma, 5 speakers distintos con 10 audios “bonafide” y 10 “spoof”, entonces, hemos intentado que en las tres particiones haya audios de las 5 personas y así intentar evitar sesgos.

A la hora de evaluar, hemos usado 4 medidas:

Accuracy: proporción de las muestras clasificadas correctamente sobre el total de muestras.

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

Precision: proporción de las muestras spoof detectadas sobre el total de muestras clasificadas como spoof.

$$\text{Precision} = \frac{TP}{TP+FP}$$

Recall: proporción de muestras spoof detectadas correctamente sobre el total de muestras spoof.

$$\text{Recall} = \frac{TP}{TP+FN}$$

F1: media armónica entre precision y recall.

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$




Figura 5: Resultados del preentrenamiento en AASIST.

Lo primero que podemos destacar sobre las gráficas, es que el modelo clasifica claramente mejor los audios en español ya que todas las métricas, a excepción de precisión en 40 épocas, tienen valores superiores. Esta diferencia explica el porqué la partición mixta lo hace peor que la que solo tiene muestras en inglés y permite deducir que ejecutar ambos idiomas juntos no le ayuda a clasificarlos mejor.

En lo referido a las épocas, lo más destacable es que superar las 40 épocas empeora la predicción por lo que podemos suponer que está ocurriendo un fenómeno de sobreaprendizaje. También, podemos observar que en la partición en inglés, el aumento del valor de este parámetro no equivale en términos generales a una subida en la mejora de la predicción, fenómeno que no ocurre con la partición en español.

Explicabilidad Hemos usado las propias estructuras del modelo para empezar a explicar qué es lo que le empuja a decidir una clase a la otra. Esto nos sirve además para enseñar mejor cómo funciona AASIST por dentro. Lo primero que mostramos es el formato de la salida que es una tupla con dos valores, la probabilidad de que el audio sea “spoof” y de que sea “bona fide”, y la estructura de los grafos que nos permite ver

que se crean 23 nodos espectrales y 29 temporales. También, simulamos como funciona un “pooling” mostrando los nodos de cada tipo con mayor puntuación.

Después, ejemplificamos cuales son los valores que se pasan a la capa de salida y cuánto afectan al cálculo de cada uno de los valores de la salida. Estos valores son los resultados de las operaciones “max” y “average” de cada subgrafo y el resultado del stack node. Con estas muestras podemos empezar a ver que ha sido mas significativo a la hora de responder si un audio es “spoof” o no.

En relación a filtros de frecuencia, primero calculamos la banda de frecuencias aproximada de cada uno de los 70 filtros con una transformada rápida de fourier y las graficamos






Figura 6: Gráfica bandas de frecuencia de los filtros.

Con esta gráfica, podemos afirmar que se captan todas las frecuencias de 0 a 8000 Hz y que en las frecuencias bajas hay más solapamiento entre filtros. Esto es importante ya que cuando extraemos cuales son los filtros que más se activan durante el procesamiento del audio, no es raro que salgan algunos consecutivos ya que si dos filtros están observando una frecuencia muy activa, ambos responderán parecido.

Posteriormente, graficamos los filtros que más activación han tenido en el primer procesamiento de dos formas: en la imagen de la izquierda viendo que frecuencias cubren y en la imagen de la derecha viendo su activación a lo largo del audio.



(a) Bandas de frecuencia de los filtros más activados.




(b) Activación de los filtros más activados a lo largo del audio.

Como hemos mencionado anteriormente, los 5 filtros más excitados se pueden separar en dos grupos por su consecución. Además, en la gráfica de la derecha se ve claramente como tienen comportamientos muy parecidos. Comparando estas últimas imágenes, con la figura X podemos ver que donde en esta última parece que había mucha relevancia, aquí no se ve reflejado. Esto se explica en que los filtros son solo la activación temprana del frontal sinc-conv y la información captada tiene que pasar por varios procesos. Sin embargo, la observación de los filtros empieza a ofrecernos información relevante para la clasificación.


A continuación, vamos a aplicar “**occlusion**” tanto al ámbito espectral como al temporal. Esta técnica consiste en ir “tapando” fragmentos de la entrada y ver como cambia el “logit” final con estas variaciones para ver que tramos han afectado más. Para tapar, en el ámbito temporal hemos puesto silencio en el tramo objetivo y en el ámbito espectral, hemos puesto silencio en la banda de frecuencia objetivo.

Además, vamos a utilizar dos medidas complementarias. Por un lado, el cambio en el “**logit**” de la clase objetivo nos permite representar cuanto contribuye cada región a la evidencia bruta de dicha clase. Por otro, medimos el **margen** o diferencia entre los “logits” de ambas clases, esta métrica nos permite analizar separación entre clases durante el audio. Mientras que la primera aporta información importante sobre cierta clase, el margen resulta más valioso para entender la decisión final de AASIST ya que nos muestra si realmente una región ayuda a la clase objetivo o ayuda a ambas por igual.

A la hora de llevar esta idea a código, hemos creado dos funciones separadas de cada dominio pero su idea es la misma. Primero, sacan los “logits” iniciales, seguidamente, con un bucle vamos tapando segmentos y sacando nuevos “logits” que nos permiten ver como ha variado el resultado al obviar ese segmento. Ambas funciones tienen un parámetro que permite decidir que clase observar y en caso de no especificar, se mira la clase con la se clasifico el audio. La única diferencia entre estas funciones, es que la del plano espectral necesitas hacer uso de una FFT para poder cambiar entre ámbitos y así seleccionar correctamente que banda de frecuencia silenciar. Las caídas en la probabilidad las graficamos y nos permite ver qué instantes del audio son más relevantes para el modelo. Hemos usado instantes de 10 ms ya que hemos concluido que es un punto donde ya podemos ver cambios finos sin que picos en tramos pequeños se compensen y salga aportación nula. Aunque todavía no sabemos qué fenómenos son los determinantes si nos permite saber en qué momento ocurren.




(a) Resultados de “logit” de la ocultación temporal en AASIST.




(b) Resultados de margen de la ocultación temporal en AASIST.

Con las gráficas frecuenciales, podemos ver en que frecuencias ocurren.




(a) Resultados de “logit” de la ocultación frecuencial en AASIST.




(b) Resultados de margen de la ocultación frecuencial en AASIST.

Siguiento en relación con las frecuencias, simulamos como sería la salida de la capa “**sinc-convolution**” que podemos asemejar a un espectrograma. Para conseguir este mapa filtro-tiempo capturamos la salida de la capa durante la inferencia y la representamos en un “**heatmap**” en cuyo eje Y se colocan los filtros de menor a mayor banda de frecuencia.

Hemos creado dos mapas filtro-tiempo, el de la izquierda sería el más fiel al modelo y el de la derecha normaliza la activación de cada filtro por su máximo. Esta combinación nos permite determinar qué regiones de frecuencias se excitan más pero sin ocultar completamente a las menos determinantes.



(a) Mapa filtro-tiempo de la capa sinc-convolution.




(b) Mapa filtro-tiempo de la capa sinc-convolution normalizado.


Con estos mapas, podemos ver que filtros, es decir, bandas de frecuencia se activan más y cuándo se excitan más.

La siguiente técnica que vamos a aplicar es **Integrated Gradients**. Para medir el error usando esta técnica usamos la métrica “**delta**” que devuelve la propia clase. Este valor mide la diferencia entre la variación real de la salida del modelo entre el input y el baseline y la suma de las atribuciones obtenidas. Un valor cercano a 0 significa buena convergencia. Primero, vamos a aplicar IG sobre los mapas filtro-tiempo que acabamos de ver. Para ello, usamos la clase **LayerIntegratedGradients** porque analizamos solo una capa concreta del modelo y nos devuelve la salida en el mismo formato que la entrada, lo que nos permite representarla de la misma manera. Esta clase usa los siguientes parámetros:

- **inputs**: el tensor del propio audio.
- **baselines**: utilizamos un vector silencio ya que la entrada es un audio.
- **target**: la clase objetivo
- **n_steps**: número de saltos entre el baseline y la entrada real
- **return_convergence_delta**: si es “True” nos devuelve la métrica delta.
- **attribute_to_layer_input**: si es “False” las atribuciones se calculan sobre las activaciones que salen de esta capa.




(a) Mapa filtro-tiempo generado por IG.




(b) Mapa filtro-tiempo normalizado generado por IG.

A diferencia de los mapas filtro-tiempo anteriores, aquí representamos las zonas que más **contribuyen** al “logit” final. Sin embargo, igual que antes, representamos una gráfica normalizada para apreciar más detalle y una sin normalizar para ver el mapa puro.

Para mostrar esto de manera más visual, generamos dos gráficas. En la izquierda, vemos los filtros en el eje x, proporcionándonos información sobre los más excitados. Sin embargo, en la derecha mostramos los resultados de manera temporal, resumiendo todos los filtros en cada instante y hacemos una curva temporal viendo que instantes han sido más relevantes.



(a) Mapa filtro-tiempo de la capa sinc-convolution.



(b) Mapa filtro-tiempo normalizado.

Siguiendo con IG, ahora lo aplicamos sobre el **audio crudo**, usando, a diferencia de con los mapas, la clase **IntegratedGradients**. Esta clase recibe los mismos parámetros que la usada antes a excepción de “attribute_to_layer_input”.

Como resultado, obtenemos una gráfica de importancia temporal indicando lo importante que es cada instante según está técnica.




Figura 13: Importancia temporal según IG sobre audio.


Como última técnica aplicamos **RISE**, y obtenemos los resultados en forma de gráfica temporal. Para transformar la idea de esta técnica a audio, lo primero es generar una función que genere las máscaras aleatorias. Esta función genera una primera máscara de tamaño “grid_size” formada solo por 1 o 0. Cada posición de esta primera máscara tiene una probabilidad “p_keep” de tener valor 1, es decir, conservar sin alteraciones esa parte de la señal. Entre cada uno de estos puntos, se realiza un escalado suave hasta tener una máscara del mismo tamaño que la señal original, evitando cambios bruscos que provoquen discontinuidades artificiales.

En cuanto a la función principal, podemos realizar los calculos de dos formas ya mencionadas anteriormente, el “logit” de clase objetivo o el margen entre clases. Para estos cálculos, primero creamos dos vectores de acumulación y después iteramos “n_mask” veces. En cada iteración, generamos una nueva máscara, la aplicamos y, una vez te-

nemos el audio normalizado, recalculamos resultados con el modelo. Posteriormente, calculamos ambas métricas y las sumamos, multiplicadas por la máscara, a sus vectores de acumulación correspondientes. Esta multiplicación es la que va ir discriminando que instantes de audio son los que favorecen más a cada métrica.

Por último, con el bucle acabado, aplicamos a los acumuladores una media sobre el número de máscaras multiplicado por el valor “p_keep”.

Mostramos las gráficas de ambas métricas para poder compararlas como se ha mencionado anteriormente.



(a) Resultados de “logit” usando RISE.

El último modelo de XAI que hemos aplicado en AASIST es **SHAP**. Sin embargo, no hemos podido aplicar directamente debido a dos razones principales. En primer lugar, el modelo recibe como entrada un audio crudo lo que se traduce en muchísimas variables que gestionar para esta técnica. En segundo lugar, la arquitectura de AASIST no encaja con los explicadores de SHAP. Para evitar este problema, hemos creado un modelo surrogate que a partir de un archivo .csv con las características intente imitar el comportamiento de AASIST.

Para medir la precisión del surrogate a la hora de imitar correctamente usamos la métrica R^2 . En este contexto, R^2 mide que tan bien el modelo del surrogate reproduce correctamente la salida original de AASIST:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

donde y_i es el valor real, $\hat{y}_i$ el valor predicho por el surrogate, $\bar{y}$ el media de los valores reales

Esta fórmula se puede presentar de forma más intuitiva como:

$$R^2 = 1 - \frac{\text{error del surrogate}}{\text{variabilidad total de la salida}}$$

Por tanto, cuanto más cercano sea R^2 a 1, mejor será la capacidad del surrogate para imitar el comportamiento de AASIST. En cambio, un valor cercano a 0 indica que el modelo apenas mejora una predicción basada simplemente en la media.

Como se puede observar en la salida de la celda donde se entrena el surrogate, obtenemos un R^2 al testear cercano a 0 lo cual supone que los resultados son muy limitados a la hora

de asociarlos a explicabilidad de AASIST. Sin embargo, vamos a explicar brevemente como hemos construido esta sección de código.

En primer lugar, combinamos el csv de características de los audios y el csv de resultados de AASIST. Para ello, hacemos un merge de ambos archivos poniendo especial atención en que las rutas coinciden y para ellos creamos una función de normalización que unifica su formato.

Cabe mencionar que transformamos el score del segundo csv a “logit” con la intención de intentar hacer mejorar la imitación del modelo ya que los valores en “logit” crecen de manera más lineal y no están cerrados entre 0 y 1.

Posteriormente, eliminamos del conjunto resultante aquellas columnas de características que no queremos que se usen en la entrada del surrogate como el nombre de cada archivo y realizamos una división del dataset. Esta tarea la realizamos a mano para que los archivos de train y test coincidan con los que se usaron a la hora de entrenar AASIST.

Como modelo de surrogate hemos escogido **XGBRegressor**. Esta decisión se fundamenta en su capacidad para modelar regiones no lineales, su flexibilidad a la hora de ajustar y opciones para controlar el sobreajuste. Para estos dos últimos objetivos, podemos ir variando los valores los parámetros que recibe la clase como “n_estimators”, número de árboles, “max_depth”, máxima profundidad de cada árbol, y “subsample”, porcentaje de audios que usa cada árbol, entre muchos otros. Probamos distintas combinaciones de estos hiperparámetros con el objetivo de mejorar la métrica R^2 pero no se obtuvieron mejoras significativas.

Por último, aplicamos SHAP sobre el modelo para generar las gráficas.

3.4.5. Perceptrón multicapa

Los perceptrones multicapa son modelos de redes neuronales empleados para la aproximación de funciones complejas, entre las que se incluyen tareas de clasificación binaria.

Justificación del modelo

El motivo de probar un MLP para esta tarea de clasificación fue, sobre todo, explorar qué posibles opciones tenemos a la hora de abordarla.

La idea inicial fue comprobar qué conseguíamos con los modelos más simples, ya que contamos con un dataset muy reducido.

Planificación del trabajo

El tratamiento del perceptrón se divide en varias etapas:

1. Tratamiento de los datos: En esta etapa se adaptarán los audios a los requisitos del modelo y se dividirán en conjuntos de entrenamiento y prueba.

2. Creación y entrenamiento del modelo: Se creará y configurará el modelo, que posteriormente será entrenado en la tarea de clasificación.
3. Obtención y análisis de resultados: En esta fase se analizarán los resultados obtenidos por el modelo.

Preprocesamiento de los datos

El proceso de tratamiento de datos comienza extrayendo del dataset las características globales de los audios, es decir, los que representan una media. También se obtendrán los espectrogramas de cada audio.

A continuación, emplearemos un MLP y una CNN de PyTorch, que reciben como entrada tensores de datos.

El objetivo de estas dos redes auxiliares es obtener vectores de *embeddings* a partir de los audios.

Embeddings de los espectrogramas

Para sacar los *embeddings* de los espectrogramas emplearemos una CNN de la librería de *Pytorch.nn* y *Pytorch.nn.functional* que recibirá el vector y lo convertirá en un tensor 2D de 128 dimensiones. Para esta tarea la red se definirá de la siguiente manera:

- **Primera capa convolucional:** Conv2d(in_channels = 1 , out_channels = 32, kernel_size=3, padding=1).

- **in_channels = 1:** La imagen tiene un único canal
- **out_channels = 32:** Genera 32 mapas de características, es decir, aprende 32 filtros distintos.
- **Kernel_size = 3:** Indica que cada filtro es de tamaño 3x3
- **padding = 1:** Añade un borde de un píxel alrededor de la imagen para mantener su tamaño espacial

Durante la ejecución de esta capa cada uno de los 32 filtros se deslizará por la imagen haciendo multiplicaciones elemento a elemento y sumando los resultados produciendo al final 32 imágenes nuevas.

- **Primera capa de normalización:** BatchNorm2d(32). Para cada uno de los 32 canales de entrada que espera, calculará:

- **Media y varianza**
- **Normalizará los valores:** $x_{\text{norm}} = \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}}$
- **Aplica una transformación aprendible:** $y = \gamma x_{\text{norm}} + \beta$

- **Primera capa de pooling:** MaxPool2d(kernel_size = 2, stride = 2).

- **kernel_size = 2:** Ventana de tamaño 2x2

- **stride = 2:** La ventana se desplaza de 2 en 2 bloques sin solaparse.

Esta capa reduce cada mapa de características en bloques de 2x2 donde cada bloque se queda con el valor máximo. Esta capa no cambia el número de canales, lo que hace es reducir el alto y el ancho a la mitad.

- **Segunda capa convolucional:** Conv2d(in_channels = 32, out_channels = 64, kernel_size=3, padding=1).
- **Segunda capa de normalización:** BatchNorm2d(64).
- **Segunda capa de pooling:** MaxPool2d(kernel_size = 2, stride = 2).
- **Tercera capa convolucional:** Conv2d(in_channels = 64, out_channels = 128, kernel_size=3, padding=1).
- **Tercera capa de normalización:** BatchNorm2d(128).
- **Capa de pooling adaptativo:** AdaptiveAvgPool2d(1). Reduce cada mapa de características a un tamaño fijo, en este caso 1x1. Esta capa toma cada canal completo (toda la imagen) y calcula su valor promedio colapsando toda la información espacial en un solo número por canal en este caso.
- **Capa totalmente conectada:** Linear(in_features = 128, out_features = 128). Toma un vector de *in_features* y lo transforma en otro de *out_features*. Esto lo hace aplicando la siguiente fórmula: $y = Wx + b$ donde
 - **y:** Vector de salida
 - **W:** Matriz de pesos
 - **x:** Vector de entrada
 - **b:** Vector de sesgo

Además definimos la función de avance aplicando tras cada conjunto de capa convolucional + normalización la función de activación relu (Convierte los valores negativos en 0) para dejar pasar solo los importante. Luego aplicamos la capa de pooling. Hacemos esto hasta que lleguemos a la tercera capa convolucional donde en lugar de aplicarle la capa de pooling, le aplicaremos la capa adaptativa y la capa totalmente conectada.

Al concluir todo este proceso tendremos el embedding de 128 dimensiones final que represente al espectrograma del audio.

Embeddings de las características

Para las características definiremos el siguiente perceptrón multicapa:

- **Primera capa totalmente conectada:** Linear(in_features = 29, out_features = 128).
 - **Primera capa relu:** ReLU().
 - **Capa de normalización:** BatchNorm1d(128).

- **Segunda capa totalmente conectada:** `Linear(in_features = 128, out_features = 64)`.
- **Segunda capa relu:** `ReLU()`.

Este proceso acabará devolviendo un *embedding* de características de 64 dimensiones.

Embedding combinado

A continuación, se concatenan ambos vectores en un único vector de *embeddings* que combina características y espectrograma. Estos vectores resultantes constituirán los datos de entrada del perceptrón encargado de clasificar los audios.

Por último, se divide el dataset en conjuntos de entrenamiento (80 %) y prueba (20 %).

Creación y entrenamiento del modelo

En esta fase se construirá el modelo encargado de la clasificación. Para ello, se debe tener en cuenta que no se busca una decisión binaria (0 o 1), sino un grado de pertenencia a la clase (real o generada) en un entorno continuo. Para ello, se empleará un MLP con coeficientes de regularización inspirados en lógica difusa.

Teniendo esto en cuenta, el modelo constará de las siguientes partes. Durante el entrenamiento, también se le proporcionarán al modelo las etiquetas correspondientes a la clasificación de los audios.

1. Entrada - Primera capa lineal - `Linear(input_dim, 128)`
2. Capa ReLU - `ReLU()`
3. Capa de normalización - `LayerNorm(128)`
4. Segunda capa lineal - `Linear(128, 64)`
5. Capa ReLU - `ReLU()`
6. Capa de normalización - `LayerNorm(64)`
7. Última capa lineal - `Linear(64, 1)`
8. Salida: Aplicación de la función de pertenencia difusa

El modelo también presenta los siguientes parámetros difusos:

1. Centro
2. Temperatura

Su función *forward* devuelve el grado de pertenencia difuso como predicción probabilística del modelo, el logit y la temperatura.

Por último, se define una función de pérdida que ajusta los coeficientes *reg_center* y *reg_temperature*.

En cuanto al entrenamiento, se emplea la siguiente configuración:

1. Batch size = 10
2. Num_batches = 100
3. Epochs = 10
4. Criterion = MSELoss
5. Optimizer = Adam

Resultados del perceptron multicapa

Como podíamos esperar, se produce un gran sobreajuste en el modelo por lo que no emplearemos ninguna de las métricas típicas para evaluarlo.

En su lugar mostraremos una gráfica que compare los labels de los audios con las predicciones del modelo.




Figura 15: Resultados del MLP.

Las conclusiones que podemos sacar sobre este modelo a la vista de los resultados son que para crear un modelo de clasificación desde 0 y que sea eficaz en su labor, necesitaríamos muchísimos más audios de los que disponemos, además, en lo que se refiere a la posterior tarea de aplicar elementos de IA explicable al modelo, al usar embeddings como entrada, no podemos aplicarle directamente ninguna de esas técnicas.

Lamentablemente debido a estos resultados tomamos la decisión de que no merecía la pena perder tiempo aplicándole técnicas de ia explicable.

3.4.6. Wav2Vec2

El modelo elegido fue Wav2Vec2, un modelo de aprendizaje profundo para el procesamiento de voz que permite obtener representaciones acústicas de alta calidad directamente a partir de la señal de audio cruda, sin necesidad de extraer características manualmente. Fue propuesto por Meta en 2020.

Justificación del modelo

El propósito de realizar un *fine-tuning* de este modelo para adaptarlo a nuestra tarea se basa en que, al contar con un dataset de audio muy reducido, es necesario partir de un modelo previamente entrenado con grandes volúmenes de datos. Aunque dicho entrenamiento previo no esté orientado a clasificación, permite reutilizar el conocimiento aprendido y adaptar el modelo a nuestra tarea mediante su reentrenamiento.

Planificación del trabajo

El proceso de *fine-tuning* de este modelo se divide en varias etapas:

1. Preprocesamiento de los datos: Conversión de los datos al formato requerido por el modelo.
2. Configuración y entrenamiento del modelo: Adaptación y reentrenamiento del modelo con los nuevos datos.
3. Análisis de resultados: Evaluación de los resultados obtenidos.

Antes de comenzar con el preprocesamiento de los datos, es necesario considerar las librerías empleadas. Este modelo se utiliza a través de la librería *transformers*, de la cual también se importan las clases *Trainer*, *TrainingArguments*, *Wav2Vec2ForSequenceClassification* y, especialmente relevante en esta etapa, *Wav2Vec2FeatureExtractor*. Asimismo, se emplea la librería *Datasets*, que no debe confundirse con las estructuras de datos de la librería *Pandas*.

Preprocesamiento de los datos

Para el preprocesamiento de los audios se definen dos constantes globales: la frecuencia de muestreo (*sampling rate*), fijada en 16000 Hz (ya que el modelo fue entrenado con esta frecuencia), y la duración máxima de los audios, establecida en 10 segundos.

El *dataframe* utilizado consta de dos columnas: una con las rutas a los audios y otra con las etiquetas correspondientes. Este conjunto de 200 audios, que incluye muestras tanto en español como en inglés, se divide en tres subconjuntos: entrenamiento (80 %), validación (10 %) y prueba (10 %).

Posteriormente, se cargan los audios y se convierten las etiquetas al tipo *long*, que es el formato esperado por el modelo.

A continuación, los datos se procesan mediante una serie de funciones para adaptarlos a los requisitos del modelo:

1. Extractor de características: Define cómo se introduce el audio en el modelo, recibiendo señal cruda, normalizándola y aplicando *padding* para convertirla al formato esperado.
2. Función de preprocesamiento: Recibe el audio, la longitud máxima, la frecuencia de muestreo y el extractor de características, y devuelve los tensores listos para el modelo.
3. Colector de datos: Agrupa los tensores de entrada y las etiquetas, devolviendo un diccionario con los datos en formato de tensores de PyTorch.

Configuración y entrenamiento del modelo

En esta fase se emplean las clases restantes de la librería *transformers*, comenzando con *Wav2Vec2ForSequenceClassification*.

Esta clase permite cargar el modelo base Wav2Vec2, configurar el número de salidas y definir la tarea. En nuestro caso, el modelo se configura para clasificación binaria (*single-label classification*) con dos salidas.

Dado que el conjunto de entrenamiento contiene únicamente 160 audios, se opta por congelar el extractor de características para evitar el sobreajuste de los filtros del modelo.

A continuación, se definen las métricas de evaluación. En este caso, debido al posterior postprocesado de las salidas, se emplean la precisión (*accuracy*), el *F1-score* y el área bajo la curva ROC (ROC-AUC).

Posteriormente, se utiliza la clase *TrainingArguments* para configurar el entrenamiento del modelo:

Listing 10: Configuración de entrenamiento del modelo

```
training_args = TrainingArguments(  
    output_dir="./wav2vec2-deepfake", # Carpeta que guarda los checkpoints, logs  
    eval_strategy="steps", # Evaluacion cada cierto numero de pasos  
    save_strategy="steps", # Guardado cada cierto numero de pasos  
    logging_steps=50, # Cada 50 pasos calcula el loss, la tasa de aprendizaje y  
    save_steps=500, # Guarda cada 500 pasos  
    eval_steps=500, # Evalua cada 500 pasos  
    learning_rate=1e-5, # Tasa de aprendizaje  
    per_device_train_batch_size=4,  
    per_device_eval_batch_size=4,  
    gradient_accumulation_steps=2,  
    num_train_epochs=5, # Numero de epocas de entrenamiento  
    fp16=True,  
    load_best_model_at_end=True, # Carga el modelo con mejor metrica AUC
```

```

        metric_for_best_model="auc",
        report_to="none"
    )

```

Por último, se utiliza la clase *Trainer* para ensamblar todo el pipeline y definir el proceso de entrenamiento:

Listing 11: Trainer del modelo

```

trainer = Trainer(
    model=model,
    args=training_args,
    train_dataset=train_dataset["train"],
    eval_dataset=train_dataset["eval"],
    data_collator=data_collator,
    processing_class=feature_extractor,
    compute_metrics=compute_metrics
)

```

Una vez configurados todos los componentes, se procede a iniciar el entrenamiento del modelo.

Resultados del Wav2Vec2

Una vez hecho el entrenamiento, podemos mostrar los resultados del modelo.

Comenzando con sus métricas de evaluación:

1. Accuracy = 0,9: Porcentaje de aciertos.
2. F1-Score = 0,909: Balance precisión-recall.
3. Roc-Auc = 0,92: Capacidad discriminativa.

Como podemos ver las métricas no son perfectas pero siguen siendo unas métricas bastante buenas.

Ahora vamos a procesar la salida del modelo para hacerla más interpretable y entendible ya que ahora el modelo devuelve una tupla con dos valores de pertenencia a las distintas clases y lo que vamos a hacer es transformar eso en un número entre 0 y 1 que nos indique el grado de pertenencia del modelo a la clase generado siendo que cuanto más cerca del 1, más seguro está el modelo de que el audio es generado, cuanto más cerca del 0, más seguro está de que es real. Si el valor está alrededor del 0,5 significa que el modelo no ha podido decidir a que categoría pertenece ese audio.

Para ello vamos a usar un clasificador fuzzy que procesará la salida del modelo convirtiendo los logits en scores para la categoría de generado calculando los grados de pertenencia fuzzy a esa categoría en función también de un alpha que buscará maximizar el roc-auc.

Name	Score	Label
I_32_N	0.37823838	0
E_47_G	0.71498334	1
I_12_N	0.33863166	0
I_3_N	0.71035093	0
E_7_G	0.71441114	1
I_2_G	0.6257453	1
E_11_N	0.3466234	0
E_23_N	0.31925088	0
E_16_G	0.72027296	1
I_6_G	0.70500165	1
I_49_N	0.32509455	0
I_5_G	0.61754656	1
E_35_G	0.7263741	1
I_41_N	0.32385188	0
E_37_N	0.37273097	0
E_2_N	0.40383905	0
E_40_G	0.6801454	1
E_41_G	0.71816057	1
I_2_N	0.69376636	0
E_43_G	0.70625514	1

Por último estos nuevos resultados se guardarán en un dataframe que servirá para aplicar luego modelos de XAI. Este dataframe tendrá el nombre del audio, el valor devuelto por el modelo y la categoría binaria a la que pertenece.

Cabe recalcar que en los nombres la primera letra es el idioma (E:español, I:inglés), el número es su identificador y la última letra es si es natural (N) o generado (G).

Podemos ver en los resultados de las predicciones como el modelo falla clasificando algunos audios naturales como generados. Esto puede deberse debido a ruido o a otras imperfecciones en los audios.

Implementación de modelos de XAI para la interpretabilidad del modelo Wav2Vec2 fine-tuneado

Ahora que tenemos el resultado del modelo (el Wav2Vec2 fine-tuneado), vamos a explicar que características y que parte del espectrograma de Mel del audio son las más influyentes y en que sentido.

Sin embargo ahora nos encontramos con el problema principal de este modelo que es que como entrada recibe un embedding, entonces, no podemos aplicar técnicas de XAI directamente al modelo. Otro problema que tenemos es que el código que tenemos de extracción de características saca muchísimas características y de ciertas características no solo saca un valor escalar sino que también saca un vector con sus valores en cada instante.

Para solucionar estos problemas hemos hecho dos cosas. La primera es que agruparemos las características en cinco grupos en función de sus características y lo que representan. Con esto nos quedan las siguientes agrupaciones:

1. Energía: rms, silence ratio, zcr, skewness, kurtosis. Este grupo son las características que se centran en la energía del audio.
2. Espectrales: spectral centroid, spectral bandwidth, spectral rolloff, spectral flatness, hnr. Este grupo son las características que miden la distribución de la energía en el ámbito de la frecuencia.
3. Pitch: pitch mean, pitch std. Este grupo son las características
4. Formantes: f1 mean, f2 mean, f3 mean. Este grupo son las características que describen la estructura vocal.
5. MFCC: mfcc1 mean, mfcc2 mean, mfcc3 mean, mfcc4 mean, mfcc5 mean, mfcc6 mean, mfcc7 mean, mfcc8 mean, mfcc9 mean, mfcc10 mean, mfcc11 mean, mfcc12 mean, mfcc13 mean. Este grupo de características capturan

La segunda cosa que se ha hecho ha sido desarrollar modelos sencillos que imiten el comportamiento del modelo. Para esto hemos hecho 6 modelos distintos. Cinco de ellos son regresiones logísticas, uno para cada grupo de características y una CNN muy simple para los espectrogramas.

Una vez tenemos los surrogate models hechos, ahora les vamos a aplicar técnicas de ia explicable. La primera técnica que aplicaremos a cada modelo de regresión es el Shap. Para cada modelo, esta técnica nos sacará dos gráficas, la primera es el impacto general de cada característica en la respuesta del modelo y la segunda es el impacto de cada característica para un audio concreto. Con esto, vamos a ir explicando modelo por modelo.

1. Energía: En este modelo podemos ver como la kurtosis y el silence ratio son las características que más influyen mientras que el rms tiene una influencia nula en la predicción.




Figura 16: Influencia general de las características.

En este ejemplo concreto tenemos que tener en cuenta que los valores del audio para las características de la energía son:

- a) rms: 0,019 - Esto nos indica que el audio tiene un volumen muy bajo, algo por debajo del rango típico de voz estándar pero coherente con voces sin procesar.
- b) silence_ratio: 0.760 - Esto nos dice que el 76 % del audio es silencio.
- c) skewness: -0.494 - Esto muestra que el audio tiene una ligera asimetría negativa.
- d) skewness: -0,494 - Esto muestra que el audio tiene una ligera asimetría negativa.
- e) kurtosis: 28,548 - Esto es un kurtosis extremadamente alta que encaja con voz intermitente o silencios largos junto con palabras puntuales.




Figura 17: Ejemplo concreto.

A la vista de la imagen podemos ver que ninguna de las características influye demasiado en la predicción pero si que se mantiene el orden global y se puede ver con cuanta fuerza influirían y en que dirección. En este caso y por la fuerza que se le presupone a las características, este audio es más real que generado.

2. Espectrales: En este modelo podemos ver como el spectral centroid es la característica dominante aunque seguida de cerca por el spectral rolloff y el spectral bandwidth. También se puede apreciar que el spectral flatness no tiene influencia en la predicción.




Figura 18: Influencia general de las características.

En este ejemplo concreto tenemos que tener en cuenta que los valores del audio para las características espectrales son:

- a) spectral centroid: 1636,524 - Presenta un centro de masa típico de voces habladas.
- b) spectral bandwidth: 1590,950 - Esto indica una dispersión moderada del espectro lo que es típico de voces complejas.
- c) spectral rolloff: 2916,263 - Este es un rolloff típico de voces con consonantes.
- d) spectral flatness: 0,034 - Esto nos muestra que es una señal altamente tonal, es decir, sin ruido.
- e) hnr: 11,754 - Presenta un valor típico para las voces (entre 10 y 20)




Figura 19: Ejemplo concreto.

A la vista de la imagen podemos ver como según estas características, este audio es más probable que sea real.

3. Pitch: En este modelo hay un claro dominio por parte del pitch std en comparación con el pitch mean.




Figura 20: Influencia general de las características.

En este ejemplo concreto tenemos que tener en cuenta que los valores del audio para el pitch son:

- a) pitch std: 55,340 - Este valor muestra la variabilidad del pitch siendo en este caso un valor de variabilidad alto.
- b) pitch mean: 266,192 - Este es un valor alto para el pitch lo que denota voces agudas




Figura 21: Ejemplo concreto.

A la vista de la imagen podemos ver ambas características empujan al modelo a decidir que este audio es real.

- 4. Formantes: En este modelo la f1 y la f3 tienen una influencia similar y muy superior a la de f2.




Figura 22: Influencia general de las características.

En este ejemplo concreto tenemos que tener en cuenta que los valores del audio para las formantes son:

- a) f1 mean: 1001,886 - Este es un valor alta de f1, típico de las vocales abiertas (A,E,O).

- b) f2 mean: 2104,974 - Este es un valor típico de las vocales frontales o anteriores (E,I). Las vocales posteriores tendrían valores menores de 1200.
- c) f3 mean: 3271,627 - Este valor muestra una voz con un timbre bastante claro y resonante típico de voces femeninas o voces masculinas poco graves.




Figura 23: Ejemplo concreto.

En la imagen se puede apreciar como la f1 es la que más tira de la predicción hacia la clase real mientras que la f3 en bastante menos medida lo hace hacia la clase generado.

- MFCC: En este modelo se observa como los coeficientes cepstrales de Mel 5,6 y 7 son los que más influyen mientras que los coeficientes 1,13 y 12 son los que menos influyen.




Figura 24: Influencia general de las características.

En este ejemplo concreto tenemos que tener en cuenta que los valores del audio para las características espectrales son:

- a) mfcc1 mean: -456,798 - Es un valor bastante bajo, típico de audios con pausas frecuentes.
- b) mfcc2 mean: 45,541 - Esto indica que es una voz con más énfasis en fonemas graves y medios.
- c) mfcc3 mean: 2,062 - Esto nos dice que el espectro es bastante equilibrado.
- d) mfcc4 mean: 16,164 - Esto nos habla de la presencia de consonantes agudas.
- e) mfcc5 mean: -1,455 - Esto muestra que es una voz natural y sin exceso de brillo.
- f) mfcc6 mean: 12,418 - Esto indica que la voz hablada es clara.
- g) mfcc7 mean: 4,943 - Esto indica que la señal es estable y natural.

- h) mfcc8 mean: 10,452 - Esto nos dice que la voz presenta consonantes articuladas.
- i) mfcc9 mean: 8,349 - Esto indica que la voz es clara y con información armónica preservada.
- j) mfcc10 mean: 3,038 - Esto muestra que es voz natural, es decir, sin ruido blanco.
- k) mfcc11 mean: 10,387 - Esto refuerza la claridad de la voz.
- l) mfcc12 mean: 12,444 - Esto nos habla de que es voz articulada.
- m) mfcc13 mean: 10,578 - Esto nos dice que la voz no presenta distorsión.




Figura 25: Ejemplo concreto.

En la imagen podemos apreciar como este grupo de características en conjunto empujan la predicción hacia la clase generado siendo que lo que la mfcc5 empuja hacia la clase real se ve contrarrestado por las mfcc7, mfcc11 y mfcc9.

Ahora para las características, buscando también algo que complemente la explicación del Shap, vamos a usar Lime para explicar los mismos modelos y la misma instancia particular.

1. Energía: En este modelo podemos ver como la kurtosis es la única característica que tiene un impacto relevante en la predicción del modelo.




Figura 26: Influencia general de las características.

2. Espectrales: En este modelo podemos ver como todas las características tienen algo de impacto, sin embargo predominan claramente el spectral bandwidth y el spectral centroid hacia reducir la predicción y el spectral rolloff hacia aumentarla.




Figura 27: Influencia general de las características.

3. Pitch: En este modelo se ve como el pitch std influye más que el pitch mean. Ambas características empujan la predicción hacia abajo.



Figura 28: Influencia general de las características.

4. Formantes: En este modelo la f1 domina sobre las demás siendo la que más empuja la predicción hacia alguna dirección, en este caso, contribuye a reducirla mientras que la f3 la empuja hacia arriba aunque con menos fuerza de lo que la f1 lo hace hacia abajo.




Figura 29: Influencia general de las características.

5. MFCC: En este modelo los coeficientes 5,7,9 y 11 son los que más influyen en las decisiones del modelo siendo que el 5 es el coeficiente que más disminuye la predicción mientras que el 7, el 9 y el 11 son los que más la aumentan.




Figura 30: Influencia general de las características.

Ahora que ya tenemos tanto el Shap como el Lime de todas las características de los audios, vamos a agregar los resultados de los cinco modelos para ver de forma general cuales son las características más influyentes a la hora de clasificar los audios en reales o generados.

Para esta tarea se ha hecho lo siguiente, primero calculamos la importancia promedio de cada característica usando sus valores Shap, luego calculamos la importancia de cada grupo de características y con esto podemos promediar la importancia de cada característica entre todos los grupos de características. Por último los ordenamos de mayor a menor importancia y los mostramos.




Figura 31: Influencia general de las características.

En esta gráfica podemos ver las 15 características más importantes para la predicción destacando sobre todo el centroide espectral y el 5º coeficiente cepstral de Mel.

Para Lime hacemos exactamente lo mismo.




Figura 32: Influencia general de las características.

En esta gráfica destacan las mismas características que en la de Shap pero con ligeras variaciones de posición entre ellas.

Para acabar con la explicación de las características, vamos a juntar ambas explicaciones en una sola combinada para obtener el orden global de influencia de las características. Este orden será calculado haciendo la media aritmética de su importancia en shap y lime.





Figura 33: Influencia general de las características.

En esta gráfica combinada podemos ver el ranking global de las características según su importancia.

Ahora pasamos al sexto surrogate model, una CNN muy simple que se compone solo de una capa convolucional y una capa de pooling. Además se simplificará la entrada agrupando todas las bandas de frecuencia en 8 bandas solamente. Esto se hace para evitar que se produzca un sobreajuste ya que tenemos muy pocos audios.

Para los espectrogramas usaremos cuatro modelos de XAI siendo estos Shap, Lime, Integrated Gradients y Grad Cam. Para las cuatro técnicas la explicación local se mostrará superponiendo la salida del modelo de XAI con el espectrograma de Mel del audio y la explicación global se mostrará la gráfica con las bandas de frecuencia y los instantes de tiempo y según el color se verá que partes del espectrograma influyen más en las decisiones del modelo.

SHAP



Aquí podemos ver en las imágenes cómo la parte del audio que más influye en la predicción es la parte final del audio, correspondiente a las bandas de mel entre 25 y 45, que simbolizan frecuencias medio-altas. Estas bandas contienen las formantes F2 y F3, así como elementos clave para la inteligibilidad del habla. Si nos fijamos en el espectrograma, esto coincide con el final, donde parece que el audio está distorsionado. Esto se aprecia claramente al escuchar el audio (I_12_N: audio 12 natural en inglés), donde la última palabra es “next”, y ese final que parece distorsionado corresponde al sonido de la pronunciación del grupo consonántico “xt”. También se puede observar cómo la parte donde ya no hay espectrograma, en la explicación de SHAP, no tiene prácticamente influencia.





Figura 35: Shap general de los espectrogramas

En esta imagen sobre la influencia global del shap podemos ver como las partes que más influyen en la clasificación del audio son el principio y el final del audio. Comparando

esta gráfica con la anterior podemos confirmar la importancia que tienen las bandas de mel medias. También podemos ver como el audio elegido para la explicación global no es representativo de la explicación global ya que esta última si que usa mucho la parte final del audio para la explicación.

LIME



En esta imagen se muestra la explicación local de lime sobre mismo audio que en el shap. En ella podemos ver como, al igual que en el shap, las bandas medias son las más relevantes y la pronunciación final es lo que más mueve la predicción hacia la clase real. Por último podemos ver como en estas bandas medias al principio estas empujan la predicción hacia generado, esto se puede deber a que el audio tarda en comenzar y a como pronuncia el principio de la primera palabra “what”.






Figura 37: Lime general de los espectrogramas

Aquí a diferencia de en shap, según lime, el modelo toma las decisiones principalmente gracias al principio de los audios aunque el final también tiene algo de influencia.

INTEGRATED GRADIENTS



(a) Lime de un audio.



(b) Espectrograma de un audio.

Aquí podemos ver como no está analizando el audio del todo bien ya que las partes más rojas son las que más influyen a una predicción hacia generado pero si vemos el espectrograma del audio, en esas partes como tal no hay nada, son zonas negras, también la gran zona azul del final se corresponde con la parte donde no hay ni siquiera espectrograma. Si ignoramos esas partes y nos centramos solo donde si que hay evidencia de audio, podemos ver como esas son zonas más blancas - azuladas que empujan la predicción hacia real. También se ve como los dos golpes de audio más fuertes en el espectrograma son las partes que más empujan la predicción hacia real.






Figura 39: Integrated gradients general de los espectrogramas

En la predicción global se puede apreciar cierta similitud con las dos explicaciones generales anteriores donde las principales zonas de influencia en la clasificación son la parte inicial y la parte final de los audios en las bandas medias.

GRAD CAM



(a) Lime de un audio.



(b) Espectrograma de un audio.

Aquí, al igual que en la explicación local de integrated gradients, podemos ver que en las partes donde no hay audio son las partes que más influyen en la predicción aunque aquí sí que distingue bien que la parte final donde no hay espectrograma no tiene ningún peso en la predicción. De todas formas, fijándonos donde hay audio podemos apreciar como el primer golpe de voz y la parte final del audio tienen más influencia en la predicción que el resto del mismo.




Figura 41: Grad cam general de los espectrogramas

La explicación global del grad cam se caracteriza por darle el mayor peso a los instantes iniciales del espectrograma, dándole un peso prácticamente nulo al centro del espectrograma, curiosamente donde están los audios, y otorgándole un peso relevante también al final del espectrograma.

Ahora vamos a ver como se ve la agregación de los cuatro modelos de XAI sobre los espectrogramas. Esto se ha calculado para cada frame del espectrograma, se ha sacado su valor en cada una de las explicaciones globales de los distintos modelos y se ha hecho la media aritmética sobre ellos. Antes de poder hacer esto, hemos tenido que normalizar todas las explicaciones ya que estaban en diferentes escalas.




Figura 42: Lime general de los espectrogramas

La agregación de las explicaciones globales nos deja claro donde se encuentran las zonas más influyentes siendo el principio y el final del espectrograma dejando al centro con un peso mucho menos relevante.

Como conclusiones podemos sacar que a la vista de los modelos de explicación, parece que el modelo Wav2Vec2 se fija más en los alrededores del audio que en el audio en sí mismo. Esto puede explicarse gracias a las siguientes propiedades de los espectrogramas de voz:

1. Coarticulación: Este es un fenómeno típico de la voz humana donde esta no está formada por unidades aisladas, es decir, cada sonido depende de los anteriores y posteriores. Esto hace que las transiciones entre fonemas contengan más información que el fonema en sí haciendo que lo que está alrededor del audio tenga más peso.
2. Dinámica espectro-temporal: Las partes centrales de los audios tienden a ser más estables y redundantes mientras que las zonas de cambio contienen mayor variabilidad lo que hace que contengan la mayoría de la información discriminativa del audio.
3. Estructura de formantes y transiciones: Las trayectorias de las formantes, claves para identificar fonemas, suelen estar en los bordes de los segmentos por lo que las zonas de alrededor del audio contienen más información dinámica de las formantes.
4. Efectos de ventana del espectrograma: Como el espectrograma se calcula usando ventanas, cada punto del espectrograma mezcla información de un intervalo temporal siendo que en los bordes del espectrograma se incluyen partes de dos sonidos distintos haciendo que estos sean más informativos al incluir mezclas de contextos.
5. Relación señal-ruido: En muchos audios el inicio y el final de los mismos pueden tener cambios de energía o ruido de fondo que el modelo puede usar como señales

útiles.

6. Información prosódica: Los elementos como la entonación, el ritmo o el énfasis no están concentrados en un punto sino que ocurren durante las transiciones.

3.4.7. Regresión Logística

La Regresión Logística es un algoritmo de aprendizaje supervisado utilizado para problemas de clasificación binaria. En este proyecto, el modelo se emplea para determinar la probabilidad de que una muestra de audio pertenezca a una de dos categorías: **Real (1)** o **Generado/Fake (0)**. A pesar de su nombre, es un clasificador lineal que utiliza la función sigmoide para mapear cualquier valor real en un rango de 0 a 1, facilitando la interpretación de los resultados como probabilidades.

Justificación del modelo

Se ha seleccionado la Regresión Logística como modelo base (*baseline*) por las siguientes razones extraídas del desarrollo experimental:

- **Eficiencia y Simplicidad:** Es computacionalmente ligero, lo que permite un entrenamiento casi instantáneo con el dataset de 100 muestras.
- **Interpretabilidad Directa:** Al ser un modelo lineal, permite analizar los coeficientes asignados a cada característica acústica para entender su relevancia.
- **Idoneidad para Clasificación Binaria:** El problema presenta clases bien balanceadas (50 muestras reales y 50 sintéticas), donde la regresión logística suele converger de manera óptima.

Planificación del trabajo

El flujo de trabajo documentado en el cuaderno sigue estas fases:

1. **Carga y Fusión:** Consolidación de los archivos `spoof_features.csv` y `bonafide_features.csv`.
2. **Preprocesamiento:** Selección de variables numéricas y normalización estadística.
3. **Entrenamiento:** División del dataset (80/20) y ajuste de hiperparámetros (`random_state=42`).
4. **Evaluación y XAI:** Análisis de métricas y generación de explicaciones locales con SHAP, LIME y DiCE.

Tratamiento de los datos

El proceso de ingeniería de datos incluyó:

- **Dataset:** Un total de 100 muestras de audio.
- **Características (Features):** Se utilizaron 34 variables acústicas, incluyendo *duration*, *rms*, *zcr*, *spectral centroid*, *hnr*, y los 13 primeros coeficientes *MFCC*.

- **Normalización:** Se aplicó `StandardScaler` para estandarizar las características ($mean=0$, $std=1$), paso crítico para asegurar que todas las variables contribuyan equitativamente al modelo lineal.

Creación y entrenamiento del modelo

El proceso de construcción del modelo se basó en la implementación de *Scikit-Learn*, siguiendo una configuración diseñada para la estabilidad en datasets pequeños:

- **Instanciación:** Se utilizó la clase `LogisticRegression` configurando un `random_state=42` para asegurar la consistencia de los coeficientes en diferentes ejecuciones.
- **Algoritmo de Optimización:** Se empleó el optimizador *liblinear*, el cual es especialmente robusto para conjuntos de datos de dimensiones moderadas (100 muestras) y problemas de clasificación binaria.
- **Proceso de Ajuste:** El modelo fue entrenado utilizando el método de máxima verosimilitud, ajustando los pesos (w) para cada una de las 34 características acústicas. Este proceso busca minimizar la función de pérdida de entropía cruzada (*Log-Loss*):

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))] \quad (1)$$

- **Validación:** El entrenamiento se validó inicialmente sobre el 80 % de los datos, verificando que la convergencia del gradiente fuera óptima antes de pasar a la fase de test.

Resultados de la Regresión Logística

Tras la evaluación con el conjunto de prueba (20 muestras), el modelo alcanzó un rendimiento perfecto:

- **Precisión Global (Accuracy):** 100 %.
- **Reporte de Clasificación:** Tanto para la clase *Fake* como *Real*, se obtuvieron valores de 1.00 en precisión, *recall* y F1-score.
- **Matriz de Confusión:** Se clasificaron correctamente las 10 muestras de cada clase sin falsos positivos ni falsos negativos.

Conclusión: La Regresión Logística demuestra que el conjunto de características acústicas seleccionado es altamente discriminativo para este problema, permitiendo una separación lineal perfecta de las clases en el entorno de prueba. Por otro lado es extraño que den resultados tan perfectos, pero al escuchar algunos de los audios generados descubrimos que son muy dicriminatorios y por tanto los puede identificar fácilmente.

Explicabilidad de la Regresión Logística

Se aplicaron tres técnicas para auditar las decisiones del modelo:

- **SHAP:** SHAP permite identificar qué características usa para clasificar cada instancia en una clase u otra, en este caso vemos que la más discriminativa es el spectral flatness seguido del f3 mean y el mfcc 1 mean.
- **LIME:** Se analizó el conjunto entero y se descubrió que los datos que más discriminan para una clase u otra son el spectral flatness y el spectral bandwidth por lo que confirma lo mostrado por shap en una instancia.
- **DiCE:** Se generaron contraejemplos donde vemos que para que una instancia cambie de clase hay que modificar el valor de spectral flatness siguiendo la línea de las otras explicaciones.

Conclusión XAI: como podemos observar las tres técnicas coinciden en que el dato más discriminante para clasificar es el spectral flatness. Al verlo en las tres técnicas confirmamos que no es algo puntual y que el dataset entero se clasifica en base a ese dato.

3.4.8. KNN

El algoritmo K-Nearest Neighbors (KNN) se ha seleccionado como una alternativa no paramétrica para la clasificación de audios. A diferencia de la Regresión Logística, KNN no asume una relación lineal entre las características, sino que clasifica cada muestra basándose en la proximidad geométrica de sus vecinos más cercanos en el espacio de características.

Justificación del modelo

La elección de KNN se fundamenta en:

- **Naturaleza No Lineal:** Es capaz de capturar fronteras de decisión complejas que un modelo lineal podría pasar por alto.
- **Simplicidad Conceptual:** No requiere una fase de entrenamiento pesada, ya que "memoriza" el conjunto de datos, lo que lo hace útil para conjuntos de datos de tamaño moderado.
- **Sensibilidad Local:** Es muy eficaz cuando las muestras de una misma clase tienden a presentar firmas acústicas muy similares entre sí.

Planificación del trabajo

El desarrollo del clasificador KNN siguió estas etapas:

1. **Carga y Limpieza:** Integración de los vectores de características de audios *bonafide* y *spoof*.

2. **Optimización de Hiperparámetros:** Uso de validación cruzada para determinar el número óptimo de vecinos (k).
3. **Entrenamiento y Evaluación:** Ajuste del modelo con la métrica de distancia euclídea y evaluación de su capacidad de generalización.

División de datos El conjunto de datos se particionó en entrenamiento (80 %) y prueba (20 %) utilizando muestreo estratificado para mantener la proporción de clases en ambos conjuntos. Esta estratificación es crucial cuando existe desbalance entre voces reales y generadas.

Modelo baseline Se estableció una configuración inicial con hiperparámetros por defecto para obtener una referencia de rendimiento:

- **n_estimators:** 100.
- **max_depth:** 10.
- **min_samples_split:** 5.
- **min_samples_leaf:** 2.
- **max_features:** sqrt.
- **random_state:** 12.
- **class_weight:** balanced.

Tratamiento de los datos

Debido a que KNN se basa en distancias, el tratamiento de datos fue crítico:

- **Escalado:** Se aplicó `StandardScaler` a las 34 características acústicas. Sin este paso, las variables con rangos mayores (como *spectral_rolloff*) dominarían la métrica de distancia sobre otras como el *RMS*.
- **División Estratificada:** Se mantuvo la proporción de clases en el 80 % de entrenamiento y 20 % de test para evitar sesgos por cercanía.

Creación y entrenamiento del modelo (KNN)

A diferencia de los modelos paramétricos, la creación del modelo KNN se centró en la optimización del espacio de búsqueda y la métrica de proximidad:

- **Búsqueda del Hiperparámetro k :** Se implementó un ciclo de iteración para evaluar el rendimiento del modelo con valores de k entre 1 y 20. Se utilizó la técnica de **Validación Cruzada (Cross-Validation)** con 5 iteraciones ($cv=5$) para garantizar que el valor de k elegido no fuera fruto del azar.
- **Selección de K Óptimo:** Basándose en la puntuación media de precisión, se seleccionó $k = 5$ (o el valor que refleje tu gráfica de error), ya que ofrecía el mejor equilibrio entre sesgo y varianza.

- **Métrica de Distancia:** Se configuró el modelo para utilizar la **distancia Euclídea**, calculada en el espacio n-dimensional de características normalizadas:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (2)$$

- **Almacenamiento:** El modelo final (`KNeighborsClassifier`) se entrenó con el set completo de entrenamiento, indexando las 80 muestras para permitir una búsqueda rápida de vecinos durante la fase de evaluación.

Resultados del KNN

Tras realizar una búsqueda del hiperparámetro óptimo, se determinó que el modelo alcanza su mejor rendimiento con un valor de $k = 5$. Los resultados obtenidos en el conjunto de prueba de 20 muestras son:

- **Precisión Global (Accuracy):** 0.95.
- **Métricas Detalladas:** El modelo alcanzó una puntuación F1 de 0.95 para ambas clases (*Real* y *Fake*).
- **Matriz de Confusión:** Se observó una clasificación perfecta, con 10 verdaderos positivos y 9 verdaderos negativos, dejando solo un falso positivo.

Conclusión: Al igual que la Regresión Logística, KNN obtiene unos números casi perfectos en este dataset, lo que sugiere que al igual que en el apartado anterior discrimina bien los audios a excepción de uno, lo que suponemos que significa que ese audio generado está más logrado.

Explicabilidad del KNN

Para entender el comportamiento de un modelo basado en distancias como KNN, se aplicaron las siguientes técnicas de IA explicable:

- **Análisis de Contribución (SHAP):** Aunque KNN no tiene coeficientes, SHAP permite identificar qué características usa para clasificar cada instancia en una clase u otra, en este caso vemos que la más discriminativa es el spectral flatness seguido del f3 mean y el mfcc 3 mean.
- **Explicación Local (LIME):** Se analizó el conjunto entero y se descubrió que los datos que más discriminan para una clase u otra son el spectral flatness y el spectral bandwidth por lo que confirma lo mostrado por shap en una instancia.
- **Contrafactuales (DiCE):** Se generaron contraejemplos donde vemos que para que una instancia cambie de clase hay que modificar el valor de spectral flatness siguiendo la línea de las otras explicaciones.

Conclusión XAI: como podemos observar las tres técnicas coinciden en que el dato más discriminante para clasificar es el spectral flatness. Al verlo en las tres técnicas

confirmamos que no es algo puntual y que el dataset entero se clasifica en base a ese dato.

3.5. Resultados

3.5.1. Random Forest

En este apartado vamos a mostrar los resultados y comentaremos un poco al respecto, aunque ahondaremos más en la parte de IA explicable (XAI).

Modelo baseline

Métricas principales:

- Accuracy: 1.0000 (Porcentaje total de aciertos)
- Precision: 1.0000 (De los que dije que eran reales, ¿cuántos lo eran?)
- Recall: 1.0000 (De los reales, ¿cuántos detecté?)
- F1-Score: 1.0000 (Balance precision-recall)
- AUC-ROC: 1.0000 (Capacidad discriminativa)
- MCC: 1.0000 (Coeficiente de correlación de Matthews)

Dato	Precisión	Recall	F1-Score	Nº Instancias
Real (1)	1	1	1	10
IA (0)	1	1	1	10
accuracy			1	20
macro avg	1	1	1	20
weighted avg	1	1	1	20

Cuadro 1: Classification report de Random Forest baseline

Análisis de errores:

- Verdaderos Negativos (Reales bien clasificados): 10
- Verdaderos Positivos (IA bien clasificados): 10
- Falsos Positivos (Reales clasificados como IA): 0
- Falsos Negativos (IA clasificados como Reales): 0
- Error tipo I (Falsos Positivos): 0.00
- Error tipo II (Falsos Negativos): 0.00

Podemos ver que, pese a ser un modelo baseline, ya funciona perfectamente. Esto puede deberse a que los audios, cuando se escuchan, se detectan algunos donde no se entiende

lo que está hablando el locutor y otros donde pese a entenderse mejor, por lo que hasta un modelo simple como este ya clasifica bien.

Validación Cruzada Estratificada

Resultados Validación Cruzada (5 folds):

- Accuracy: 1.0000 (+/- 0.0000)
- F1-Score: 1.0000 (+/- 0.0000)
- AUC-ROC: 1.0000 (+/- 0.0000)

Estos resultados nos dicen que el modelo funciona bien en los 5 folds, aunque no podemos descartar que hubiera algún fold más “difícil” en el cual no tuviera 100 % de precisión.

Grid Search

En primer lugar veamos cuáles son los mejores parámetros del grid que hemos definido.

- n_estimators: 100
- max_depth: 5
- min_samples_split: 2
- min_samples_leaf: 1
- max_features: sqrt

Vemos que difieren de los que nosotros definimos previamente en el modelo baseline, y tiene sentido pues la máquina, tras entrenar con todas las posibilidades, ha evaluado este conjunto de parámetros como el mejor, maximizando f1 como vimos. Veamos entonces qué resultados obtenemos con estos parámetros, aunque viendo el resultado del modelo anterior, nos hacemos una idea.

Métricas principales:

- Accuracy: 1.0000 (Porcentaje total de aciertos)
- Precision: 1.0000 (De los que dije que eran reales, ¿cuántos lo eran?)
- Recall: 1.0000 (De los reales, ¿cuántos detecté?)
- F1-Score: 1.0000 (Balance precision-recall)
- AUC-ROC: 1.0000 (Capacidad discriminativa)
- MCC: 1.0000 (Coeficiente de correlación de Matthews)

Dato	Precisión	Recall	F1-Score	Nº Instancias
Real (1)	1	1	1	10
IA (0)	1	1	1	10
accuracy			1	20
macro avg	1	1	1	20
weighted avg	1	1	1	20

Cuadro 2: Classification report de Random Forest óptimo

Análisis de errores:

- Verdaderos Negativos (Reales bien clasificados): 10
- Verdaderos Positivos (IA bien clasificados): 10
- Falsos Positivos (Reales clasificados como IA): 0
- Falsos Negativos (IA clasificados como Reales): 0
- Error tipo I (Falsos Positivos): 0.00
- Error tipo II (Falsos Negativos): 0.00

Como observamos y como la intuición nos decía, los resultados son iguales que los de antes, todo perfecto. Posiblemente la razón sea la misma: una mezcla entre un buen split y pocos datos y/o datos poco representativos.

Implementación de SHAP para la interpretabilidad del modelo Random Forest

Para complementar el análisis predictivo y dotar de interpretabilidad al modelo Random Forest, se implementaron explicaciones basadas en SHAP (SHapley Additive exPlanations). Esta sección describe la implementación práctica realizada sobre el modelo optimizado.

3.5.2. LightGBM

En este apartado vamos a mostrar los resultados y comentaremos un poco al respecto, aunque ahondaremos más en la parte de IA explicable (XAI).

Modelo baseline

Métricas principales:

- Accuracy: 1.0000 (Porcentaje total de aciertos)
- Precision: 1.0000 (De los que dije que eran reales, ¿cuántos lo eran?)
- Recall: 1.0000 (De los reales, ¿cuántos detecté?)
- F1-Score: 1.0000 (Balance precision-recall)

- AUC-ROC: 1.0000 (Capacidad discriminativa)
- MCC: 1.0000 (Coeficiente de correlación de Matthews)

Dato	Precisión	Recall	F1-Score	Nº Instancias
Real (1)	1	1	1	10
IA (0)	1	1	1	10
accuracy			1	20
macro avg	1	1	1	20
weighted avg	1	1	1	20

Cuadro 3: Classification report de LightGBM baseline

Análisis de errores:

- Verdaderos Negativos (Reales bien clasificados): 10
- Verdaderos Positivos (IA bien clasificados): 10
- Falsos Positivos (Reales clasificados como IA): 0
- Falsos Negativos (IA clasificados como Reales): 0
- Error tipo I (Falsos Positivos): 0.00
- Error tipo II (Falsos Negativos): 0.00

Podemos ver que, pese a ser un modelo baseline, ya funciona perfectamente. Esto puede deberse a que los audios, cuando se escuchan, se detectan algunos donde no se entiende lo que está hablando el locutor y otros donde pese a entenderse mejor, por lo que hasta un modelo simple como este ya clasifica bien.

Validación Cruzada Estratificada

Métrica	Media	Desviación típica
Accuracy	0.9875	+/- 0.0500
F1-Score	0.9882	+/- 0.0471
AUC-ROC	1	+/- 0

Cuadro 4: Resultados Validación Cruzada

Estos resultados arrojan una pequeña desviación en exactitud y en f1, lo cual puede indicar que en el modelo baseline el split con el que se entrenó era “fácil” y por eso lo hace tan bien, ya que no en todos los splits lo hace perfecto.

Grid Search

En primer lugar veamos cuáles son los mejores parámetros del grid que hemos definido.

- num_leaves: 15
- learning_rate: 0.01
- n_estimators: 100
- min_child_samples: 20
- subsample: 0.6
- colsample_bytree: 0.6
- reg_alpha: 0
- reg_lambda: 0

Vemos que difieren de los que nosotros definimos previamente en el modelo baseline, y tiene sentido pues la máquina, tras entrenar con todas las posibilidades, ha evaluado este conjunto de parámetros como el mejor, maximizando f1 como vimos. Veamos entonces qué resultados obtenemos con estos parámetros, aunque viendo el resultado del modelo anterior, nos hacemos una idea.

Veamos entonces el rendimiento de dicho modelo.

Métricas principales:

- Accuracy: 1.0000 (Porcentaje total de aciertos)
- Precision: 1.0000 (De los que dije que eran reales, ¿cuántos lo eran?)
- Recall: 1.0000 (De los reales, ¿cuántos detecté?)
- F1-Score: 1.0000 (Balance precision-recall)
- AUC-ROC: 1.0000 (Capacidad discriminativa)
- MCC: 1.0000 (Coeficiente de correlación de Matthews)

Dato	Precisión	Recall	F1-Score	Nº Instancias
Real (1)	1	1	1	10
IA (0)	1	1	1	10
accuracy			1	20
macro avg	1	1	1	20
weighted avg	1	1	1	20

Cuadro 5: Classification report de LightGBM óptimo

Análisis de errores:

- Verdaderos Negativos (Reales bien clasificados): 10

- Verdaderos Positivos (IA bien clasificados): 10
- Falsos Positivos (Reales clasificados como IA): 0
- Falsos Negativos (IA clasificados como Reales): 0
- Error tipo I (Falsos Positivos): 0.00
- Error tipo II (Falsos Negativos): 0.00

Como observamos y como la intuición nos decía, los resultados son iguales que los de antes, todo perfecto. Posiblemente la razón sea la misma: una mezcla entre un buen split y pocos datos y/o datos poco representativos.

3.5.3. Support Vector Machine

En este apartado vamos a mostrar los resultados y comentaremos un poco al respecto, aunque ahondaremos más en la parte de IA explicable (XAI).

Modelo baseline con kernel lineal

EVALUACIÓN: SVM - Lineal

Métricas principales:

- Accuracy: 1.0000 (Porcentaje total de aciertos)
- Precision: 1.0000 (De los que dije que eran reales, ¿cuántos lo eran?)
- Recall: 1.0000 (De los reales, ¿cuántos detecté?)
- F1-Score: 1.0000 (Balance precision-recall)
- AUC-ROC: 1.0000 (Capacidad discriminativa)
- MCC: 1.0000 (Coeficiente de correlación de Matthews)

Dato	Precisión	Recall	F1-Score	Nº Instancias
Real (1)	1	1	1	10
IA (0)	1	1	1	10
accuracy			1	20
macro avg	1	1	1	20
weighted avg	1	1	1	20

Cuadro 6: Classification report de SVM con kernel lineal

Análisis de errores:

- Verdaderos Negativos (Reales bien clasificados): 10
- Verdaderos Positivos (IA bien clasificados): 10

- Falsos Positivos (Reales clasificados como IA): 0
- Falsos Negativos (IA clasificados como Reales): 0
- Error tipo I (Falsos Positivos): 0.00
- Error tipo II (Falsos Negativos): 0.00

Podemos ver que, pese a ser un modelo baseline, y tener un kernel lineal (que suelen ser peores que los no lineales) ya funciona perfectamente. Esto puede deberse a que los audios, cuando se escuchan, se detectan algunos donde no se entiende lo que está hablando el locutor y otros donde pese a entenderse mejor, por lo que hasta un modelo simple como este ya clasifica bien. Vamos a ver si el kernel no lineal consigue los mismos resultados.

Modelo baseline con kernel no lineal

Métricas principales:

- Accuracy: 1.0000 (Porcentaje total de aciertos)
- Precision: 1.0000 (De los que dije que eran reales, ¿cuántos lo eran?)
- Recall: 1.0000 (De los reales, ¿cuántos detecté?)
- F1-Score: 1.0000 (Balance precision-recall)
- AUC-ROC: 1.0000 (Capacidad discriminativa)
- MCC: 1.0000 (Coeficiente de correlación de Matthews)

Dato	Precisión	Recall	F1-Score	Nº Instancias
Real (1)	1	1	1	10
IA (0)	1	1	1	10
accuracy			1	20
macro avg	1	1	1	20
weighted avg	1	1	1	20

Cuadro 7: Classification report de SVM con kernel no lineal

Análisis no errores:

- Verdaderos Negativos (Reales bien clasificados): 10
- Verdaderos Positivos (IA bien clasificados): 10
- Falsos Positivos (Reales clasificados como IA): 0
- Falsos Negativos (IA clasificados como Reales): 0
- Error tipo I (Falsos Positivos): 0.00

- Error tipo II (Falsos Negativos): 0.00

Vemos que sí, ambos modelos baseline obtienen unos resultados perfectos. Vamos a ver la validación cruzada sobre el modelo de kernel no lineal.

Validación Cruzada Estratificada

Métrica	Media	Desviación típica
Accuracy	1	+/- 0
F1-Score	1	+/- 0
AUC-ROC	1	+/- 0

Cuadro 8: Resultados Validación Cruzada

Estos resultados nos dicen que el modelo funciona bien en los 5 folds, aunque no podemos descartar que hubiera algún fold más “difícil” en el cual no tuviera 100 % de precisión.

Grid Search

En primer lugar veamos cuáles son los mejores parámetros del grid que hemos definido.

- C: 1
- gamma: 0.01
- kernel: rbf

Vemos que difieren de los que nosotros definimos previamente en el modelo baseline, y tiene sentido pues la máquina, tras entrenar con todas las posibilidades, ha evaluado este conjunto de parámetros como el mejor, maximizando f1 como vimos. Veamos entonces qué resultados obtenemos con estos parámetros, aunque viendo el resultado del modelo anterior, nos hacemos una idea.

Métricas principales:

- Accuracy: 1.0000 (Porcentaje total de aciertos)
- Precision: 1.0000 (De los que dije que eran reales, ¿cuántos lo eran?)
- Recall: 1.0000 (De los reales, ¿cuántos detecté?)
- F1-Score: 1.0000 (Balance precision-recall)
- AUC-ROC: 1.0000 (Capacidad discriminativa)
- MCC: 1.0000 (Coeficiente de correlación de Matthews)

Dato	Precisión	Recall	F1-Score	Nº Instancias
Real (1)	1	1	1	10
IA (0)	1	1	1	10
accuracy			1	20
macro avg	1	1	1	20
weighted avg	1	1	1	20

Cuadro 9: Classification report de SVM con kernel no lineal

Análisis de errores:

- Verdaderos Negativos (Reales bien clasificados): 10
- Verdaderos Positivos (IA bien clasificados): 10
- Falsos Positivos (Reales clasificados como IA): 0
- Falsos Negativos (IA clasificados como Reales): 0
- Error tipo I (Falsos Positivos): 0.00
- Error tipo II (Falsos Negativos): 0.00

Como observamos y como la intuición nos decía, los resultados son iguales que los de antes, todo perfecto. Posiblemente la razón sea la misma: una mezcla entre un buen split y pocos datos y/o datos poco representativos.

3.5.4. AASIST

3.5.5. Perceptrón Multicapa

3.5.6. Wav2Vec2

3.5.7. Regresión Logística

3.5.8. KNN

3.6. Discusión de los resultados

4. Trabajo Individual

4.0.1. Iván Pastor Sacristán

1. Investigación del estado del arte: Investigué sobre el estado actual de la detección de deepfakes. Durante la investigación leí dos papers. En el primero hablaban sobre adaptación de los modelos a nuevos conjuntos de datos distintos de los que se usaron para entrenarlo y probarlo. En el segundo paper se centraban en un modelo capaz de clasificar correctamente los audios, aún y cuando los generados por IA habían sido modificados tanto en el dominio de la frecuencia como en el

del tiempo para añadirles defectos característicos de los audios humanos como el ruido.

2. Prueba del dataset WaveFake: Hice una primera versión del extractor de características entre las que se incluyen rms, zcr, pitch, mfcc's, duración, transcripción, espectral centroid, espectral rolloff y el espectral bandwidth.
3. Prueba del dataset ASVSpooof2021: Usé el mismo extractor de características e hice un clasificador difuso en el que, basándome en las características extraídas, clasifique los audios por género y edad aparente.
4. Modelo compuesto: El modelo se basa en hacer un embedding de las características con un perceptrón multicapa (MLP), hacer un embedding del espectrograma del audio con una red neuronal convolucional (CNN), concatenarlos, y luego usar esos embeddings como entrada de un MLP + clasificador difuso que es lo que se encargará realmente de la tarea de clasificación.
5. Fine-tuning Wav2Vec2: Usé el modelo desarrollado por Meta Wav2Vec2 y le hice un fine-tuning con nuestro dataset para que se enfocara en la clasificación de audios. Luego procesé la salida del modelo para pasar de la tupla que me devuelve el modelo a un valor entre 0 y 1 que indique la confianza de que un audio sea generado.
6. XAI sobre Wav2Vec2: Sobre el modelo Wav2Vec2, no se puede aplicar directamente IA explicable ya que la entrada son embeddings, para ello lo que he hecho ha sido dividir entre las características y el espectrograma de Mel. Para las características usa Shap y Lime sobre surrogate models que imitan la salida de Wav2Vec2 y para los espectrogramas de Mel use una CNN a la que le apliqué Shap, Lime, Integrated gradients y Grad Cam.

4.0.2. Jorge Aured Zarzoso

- Investigué sobre las motivaciones para investigar sobre la detección de voz generada por IA con dos papers. En estos se hablaba de cómo las personas hemos perdido la capacidad de detectar correctamente cuando un audio es real o no.
- Investigué sobre qué características son relevantes en la voz y cómo extraerlas mediante código. Esto ya que es crucial saber qué representa cada característica para tener una noción de qué puede tener en cuenta los modelos a la hora de predecir si un audio es real o no.
- Investigué parcialmente sobre la extracción de gráficas de la voz, para su uso en redes convolucionales (CNN).
- paper deepShap
- paper peru
- Investigué sobre el estado del arte de los modelos LightGBM, Random Forest y SVM para clasificación. En dicha investigación profundicé en el funcionamiento

de los modelos, viendo qué hiperparámetros tiene cada uno y para qué sirven, y qué ventajas tienen para la clasificación de audios en reales o generados.

- Investigué sobre datasets que nos pudieran servir para la clasificación. Encontré audioMNIST y HABLA, el primero de los números del 0 al 9 y el segundo son voces en español de hispanoamérica. audioMNIST solo cuenta con voces reales, mientras que HABLA tiene tanto clonaciones de voz como ataques (hacer que una voz se parezca a otra).
- He hecho un pipeline completo para cada uno de los tres modelos, entrenándolos de varias formas para ver cuál funcionaba mejor. Este pipeline consta de un modelo baseline, una fase de cross validation y un grid search optimizando los parámetros. En cada paso visualicé los resultados de los modelos viendo su rendimiento. Al final del pipeline guardé como archivo .pkl los mejores modelos
- He aplicado técnicas de Inteligencia Artificial explicable (XAI) a mi modelo óptimo de Random Forest, aunque las pruebas son extrapolables a los demás modelos. Dichas técnicas muestran cómo el modelo hace las predicciones. Las he hecho globales y locales. He aplicado SHAP (local y global), LIME (local) y DiCE (local, contrafactual).

4.0.3. Germán Bravo Quintián

- En cuanto a mi investigación inicial sobre la detección de voz generada por IA, leí tres papers.
 1. Paper sobre AASIST: la motivación principal para desarrollar el modelo es porque algunos ataques de spoofing dejan huellas espectrales, otros temporales; y los modelos generalmente no miran ambos tipos.
 2. Paper sobre RawNet2: aunque Rawnet2 fue diseñado originalmente para la verificación del hablante, en el paper proponen una adaptación de este modelo para el ámbito de la detección de spoofing. La motivación es crear un modelo que trabaje directamente sobre la onda cruda de audio para que pueda aprender características generales, reduciendo su dependencia sobre artefactos ya conocidos.
 3. Paper sobre ASVspoof2021: sobre la tarea Logical Access(LA), el paper introduce este dataset como mejora de los anteriores añadiendo mejoras como condiciones de transmisión, codificación y comprensión.
- Además, del dataset del último paper, investigue otros dos datasets que nos sirvieran para entrenar nuestros modelos. El primero, es “In-the-wild”, dataset en inglés, con audios reales y falsos que incluye voces de 58 personas famosas. El segundo es odss(Open Dataset of Synthetic Speech), que incluye 158 voces en inglés, alemán y español en el que cada audio falso tiene su correspondiente versión real.
- Creación de nuestro propio dataset de prueba teniendo en cuenta los datasets investigados por mis compañeros y los recién mencionados.
- Investigué sobre transcriptores de audio, intentando implementar el paquete de python de Whisper pero debido a dificultades en la tarea lo descarté. Finalmente, implementé “vosk”, creando una función que usando su modelo devolviera la transcripción.
- Paper de AASIST2: se centra en intentar solventar el problema de que al modelo le cuestan los audios cortos, esto se debe porque al haber menos información, hay menos nodos y menos relaciones por tanto. Cambios principales: usan Res2Net blocks, DCS y ALMFT.
- Paper de AASIST3: cambios principales: redes Kolmogorov-Arnold, permiten modelar funciones complejas multivariadas; características de aprendizaje supervisado; más bloques residuales y técnicas de regularización.
- Paper de AASIST con "Speaker-Aware": da contexto sobre el peligro de la suplantación de voz, los distintos tipos de ataques y habla de los datasets de ASVspoof.
- ASVspoof 2019: A large-scale public database of synthesized, converted and replayed speech: ofrece contexto sobre el peligro de la suplantación de voz, los distintos tipos de ataques y habla de los datasets de ASVspoof.

- Paper sobre Integrated Gradients: explican los axiomas en lo que se basa, presentados como fundamentales para cualquier XAI; definen los fundamentos matemáticos de la técnica y ofrece pruebas de IG sobre varias aplicaciones.
- Paper sobre Occlusion: el apartado 4.2 introduce el concepto de occlusion, aunque lo use para imágenes, lo usé como base para aplicarlo a AASIST..
- Paper sobre RISE: propone RISE como un modelo que solo necesita acceder a la entrada y a la salida sin tener en cuenta gradientes, pesos internos... Como para Occlusion, en el paper, se aplica solo a imágenes y he reconvertido la idea.
- En relación al uso de modelos, he creado todo el código para el uso de AASIST, además, de realizar todas las pruebas mencionadas en su apartado de metodologías. También, he desarrollado el código relacionado con su explicabilidad, es decir, la implementación de RISE, Integrated Gradients, Occlusion y el mostrado de ciertos niveles internos de la arquitectura. Por último, realicé el intento fallido de aplicar SHAP a un surrogate que imite a AASIST para intentar dar explicaciones a nivel de características.